



TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Đề tài : Đánh giá và so sánh các thuật toán phân loại trong việc nhận diện sớm bệnh tim mạch

Môn học:Học máy

Giảng viên hướng dẫn: TS. Cao Văn Chung

Nhóm sinh viên thực hiện:

Họ và tên	MSSV	Lớp
Hoàng Danh Dũng	23000103	K68A2
Nguyễn Hữu Dũng	23000104	K68A2

Mục lục

0.1	Giới thiệu tổng quan	4
0.1.1	Đặt vấn đề	4
0.1.2	Mục tiêu của đề tài	4
1	Cơ sở lý thuyết	6
1.1	Tổng quan về quản lý nguy cơ và dự báo tim mạch	6
1.1.1	Khái niệm về nguy cơ tim mạch	6
1.1.2	Dự đoán nguy cơ tim mạch và bài toán phân loại nhị phân	6
1.1.3	Hạn chế của phương pháp truyền thống và nhu cầu ứng dụng học máy	7
1.2	Tổng quan về học máy cho bài toán phân loại	7
1.2.1	Các khái niệm cơ bản	7
1.2.2	Quy trình xây dựng mô hình học máy	8
1.2.3	Bài toán phân loại nhị phân trong dự đoán tim mạch	8
1.3	Các mô hình phân loại sử dụng trong đề tài	8
1.3.1	Hồi quy Logistic (Logistic Regression)	8
1.3.2	Mô hình Naïve Bayes	10
1.4	Kỹ thuật giảm chiều PCA và LDA	10
1.4.1	Lý do cần giảm chiều dữ liệu	10
1.4.2	Phân tích thành phần chính (Principal Component Analysis - PCA)	11
1.4.3	Phân tích biệt thức tuyến tính (Linear Discriminant Analysis - LDA) cho hai lớp	11
1.4.4	So sánh PCA và LDA trong bối cảnh dự đoán vỡ nợ	12
1.5	Các thước đo đánh giá mô hình phân loại	12
1.5.1	Ma trận nhầm lẫn (Confusion Matrix)	12
1.5.2	Accuracy, Precision, Recall, F1-score	13
1.5.3	Đường cong ROC và chỉ số AUC	13
1.5.4	Lựa chọn ngưỡng phân loại	13
1.6	Tóm tắt chương	14
2	Thực nghiệm trên bộ dữ liệu	15
2.1	Dữ liệu nghiên cứu	15
2.1.1	Giới thiệu dữ liệu	15
2.1.2	Mô tả các đặc trưng	15
2.1.3	Thống kê dữ liệu sơ bộ	16
2.1.4	Loại bỏ dữ liệu trùng lặp	17
2.1.5	Trực quan dữ liệu ban đầu	18
2.1.6	Xử lý giá trị ngoại lệ (Outliers)	20
2.1.7	Phân chia dữ liệu (Train-Test Split)	22
2.1.8	Biến đổi đặc trưng (Feature engineering)	23
2.1.9	Biến đổi đặc trưng (Feature engineering)	23

2.2	Phương pháp thí nghiệm giảm chiều	24
2.2.1	Phương pháp 1: PCA (Phân tích thành phần chính)	24
2.2.2	Phương pháp 2: LDA (Phân tích phân biệt tuyến tính)	27
2.3	Phương pháp thí nghiệm phân loại	28
2.3.1	Lựa chọn mô hình	28
2.3.2	Kịch bản thí nghiệm	28
2.3.3	Phương pháp đánh giá mô hình	29
3	So sánh và đánh giá kết quả thực nghiệm	30
3.1	Tổng quan các thí nghiệm	30
3.2	Kết quả phân loại trên dữ liệu gốc	30
3.2.1	Bảng kết quả	30
3.2.2	Nhận xét	31
3.3	Kết quả phân loại trên dữ liệu PCA 2D	31
3.3.1	Bảng kết quả	31
3.3.2	Nhận xét	32
3.4	Kết quả phân loại trên dữ liệu LDA 1D	32
3.4.1	Bảng kết quả	32
3.4.2	Nhận xét	33
3.5	So sánh giữa các kiểu biểu diễn dữ liệu	33
3.5.1	So sánh hiệu năng tổng thể	33
3.5.2	Đánh giá ảnh hưởng của các phương pháp giảm chiều	34
3.5.3	Ảnh hưởng của tỉ lệ chia train/test	34
3.6	Kết luận	34

Danh sách hình vẽ

2.1	Kết quả lệnh <code>df.info()</code>	17
2.2	Kết quả lệnh <code>df.describe()</code> . sau khi xóa lặp	18
2.3	Phân bố biến mục tiêu Heart Disease	19
2.4	Histogram một số biến số quan trọng trong bộ dữ liệu.	20
2.5	Biểu đồ tần suất một số biến phân loại trong bộ dữ liệu.	20
2.6	Boxplot BMI, PhysicalHealth , MentalHealth và SleepTime trước khi xử lý Outliers.	21
2.7	Boxplot BMI, PhysicalHealth , MentalHealth và SleepTime sau khi xử lý Outliers.	22
2.8	Hình mô tả một số thuộc tính của dữ liệu sau khi xử lý.	24
2.9	Mức độ đóng góp của các thành phần PCA	24
2.10	Trực quan hóa phân tích thành phần chính	26
2.11	Trực quan hóa phân phối dữ liệu sau LDA(k=1)	27

0.1 Giới thiệu tổng quan

0.1.1 Đặt vấn đề

Trong các bệnh lý không lây nhiễm, bệnh tim mạch (Cardiovascular Diseases - CVDs) hiện là nguyên nhân gây tử vong hàng đầu trên toàn cầu. Theo Tổ chức Y tế Thế giới (WHO), các biến cố như nhồi máu cơ tim hay đột quỵ thường xảy ra bất ngờ, nhưng thực tế chúng là kết quả của một quá trình diễn tiến âm thầm từ các yếu tố nguy cơ tích lũy theo thời gian.

Việc chẩn đoán bệnh tim mạch truyền thống thường dựa vào các xét nghiệm lâm sàng chuyên sâu như điện tâm đồ (ECG), xét nghiệm máu, hoặc siêu âm tim. Tuy nhiên:

- **Chi phí cao:** Không phải cá nhân nào cũng có điều kiện thực hiện tầm soát định kỳ tại các cơ sở y tế lớn.
- **Tính kịp thời:** Bệnh thường diễn biến âm thầm, nhiều bệnh nhân chỉ phát hiện khi đã ở giai đoạn muộn hoặc xảy ra biến cố cấp tính (đột quỵ, nhồi máu cơ tim).

Sự bùng nổ của Trí tuệ nhân tạo, đặc biệt là Học máy (Machine Learning), cho phép chúng ta xây dựng các công cụ hỗ trợ ra quyết định với chi phí thấp và tốc độ xử lý nhanh. Việc xây dựng một mô hình dự đoán từ các dữ liệu khảo sát không chỉ giúp cá nhân hóa việc chăm sóc sức khỏe mà còn giảm thiểu đáng kể gánh nặng cho hệ thống y tế công cộng thông qua việc can thiệp sớm.

0.1.2 Mục tiêu của đề tài

Mục tiêu tổng quát

Xây dựng thành công mô hình Học máy phân loại nhị phân có khả năng dự đoán sớm nguy cơ mắc bệnh tim mạch của cá nhân dựa trên các chỉ số sức khỏe và thói quen sinh hoạt, đạt độ chính xác và tin cậy cao.

Mục tiêu cụ thể

Để đạt được mục tiêu trên, đề tài tập trung vào các mục tiêu cụ thể sau:

- **Phân tích và Tiền xử lý dữ liệu:** làm sạch dữ liệu, xử lý giá trị thiếu, mã hóa biến phân loại, chuẩn hóa biến số; phân tích mô tả và nhận diện các vấn đề như mất cân bằng lớp, ngoại lệ, nhiễu (Mục ??).
- **So sánh các phương pháp giảm chiều:** áp dụng PCA và LDA để rút gọn số chiều dữ liệu, đánh giá khả năng giữ lại thông tin và hỗ trợ cho bài toán phân loại (Mục ??).
- **Xây dựng và đánh giá mô hình phân loại:** xây dựng, huấn luyện và so sánh hai mô hình Logistic Regression, Naïve Bayes dựa trên các thước đo như Accuracy, Precision, Recall, F1-score, AUC (Mục ??).

Câu hỏi nghiên cứu

Từ các mục tiêu trên, đề tài hướng tới trả lời một số câu hỏi nghiên cứu chính:

- Quy trình tiền xử lý nào phù hợp với bộ dữ liệu *Heart Disease* để chuẩn bị cho các mô hình học máy?

- PCA và LDA khác nhau như thế nào trong việc giảm chiều dữ liệu, và phương pháp nào hỗ trợ tốt hơn cho bài toán phân loại?
- Trong hai mô hình Logistic Regression, Naïve Bayes, mô hình nào cho hiệu năng tốt hơn?

CHƯƠNG 1

Cơ sở lý thuyết

1.1 Tổng quan về quản lý nguy cơ và dự báo tim mạch

1.1.1 Khái niệm về nguy cơ tim mạch

Nguy cơ tim mạch là khả năng một cá nhân gặp phải các biến cố sức khỏe nghiêm trọng (như nhồi máu cơ tim, đột quỵ) do các yếu tố rủi ro không được kiểm soát. Khi các chỉ số sức khỏe và thói quen sinh hoạt không lành mạnh kéo dài, các yếu tố này sẽ dẫn đến các bệnh lý tim mạch mãn tính, được xem là một dạng "rủi ro sức khỏe" cần được quản lý chặt chẽ.

Trong bối cảnh y tế dự phòng, việc phát hiện sớm thông qua sàng lọc định kỳ giúp phân loại bệnh nhân vào các nhóm nguy cơ khác nhau, từ đó áp dụng các biện pháp can thiệp và điều trị dự phòng phù hợp. Việc đo lường, dự báo và kiểm soát nguy cơ tim mạch vì thế là một trong những nhiệm vụ trọng tâm của quản lý sức khỏe cộng đồng.

1.1.2 Dự đoán nguy cơ tim mạch và bài toán phân loại nhị phân

Để hỗ trợ quyết định sàng lọc và chẩn đoán sớm, các hệ thống hỗ trợ quyết định y khoa thường sử dụng hệ thống *dự đoán nguy cơ mắc bệnh*. Về bản chất, dự đoán nguy cơ tim mạch là quá trình sử dụng thông tin về cá nhân (nhân khẩu học, chỉ số sinh học, thói quen sinh hoạt,...) để ước lượng xác suất cá nhân đó sẽ mắc bệnh hoặc gặp biến cố trong tương lai. ước lượng xác suất khách hàng đó sẽ vỡ nợ trong tương lai

Trong ngôn ngữ học máy, đây là một bài toán *phân loại nhị phân*:

$$y \in \{0, 1\},$$

trong đó $y = 1$ biểu thị cá nhân có nguy cơ mắc bệnh, $y = 0$ là cá nhân không có nguy cơ mắc bệnh. Từ dữ liệu lịch sử đã gắn nhãn, mô hình học máy học được một hàm ánh xạ từ vector đặc trưng đầu vào (các thông tin khảo sát cơ bản) sang xác suất hoặc nhãn dự đoán. Dựa trên một ngưỡng quyết định, các chuyên gia y tế có thể đưa ra khuyến nghị điều chỉnh lối sống, chỉ định tầm soát chuyên sâu hoặc áp dụng các biện pháp can thiệp y tế kịp thời.

1.1.3 Hạn chế của phương pháp truyền thống và nhu cầu ứng dụng học máy

Trước đây, nhiều hệ thống đánh giá nguy cơ tim mạch được xây dựng dựa trên các quy tắc do chuyên gia y tế đặt ra (rule-based) hoặc các thang điểm lâm sàng đơn giản như bảng điểm Framingham hay SCORE. Các phương pháp này có ưu điểm là dễ hiểu, dễ triển khai trong điều kiện thăm khám thông thường, nhưng tồn tại nhiều hạn chế:

- **Phụ thuộc mạnh vào kinh nghiệm chủ quan của chuyên gia:** Các quy tắc chẩn đoán thường dựa trên quan sát lâm sàng truyền thống, khó cập nhật kịp thời khi các yếu tố về môi trường sống, thói quen sinh hoạt và đặc điểm nhân khẩu học của quần thể thay đổi.
- **Khả năng mô tả các mối quan hệ phi tuyến, tương tác phức tạp giữa các biến còn hạn chế:** Sự kết hợp giữa các yếu tố như chỉ số BMI, huyết áp và thói quen hút thuốc thường có tính tương tác đa chiều, dễ dẫn đến mô hình đơn giản hóa quá mức khi chỉ sử dụng các phép cộng điểm tuyến tính.
- **Việc điều chỉnh, mở rộng hệ thống quy tắc thường tốn thời gian:** Quá trình cập nhật các hướng dẫn điều trị (guidelines) mới đòi hỏi nhiều năm nghiên cứu thử nghiệm, dẫn đến sự chậm trễ trong việc phản ứng với các xu hướng bệnh lý mới.

Trong bối cảnh dữ liệu sức khỏe cộng đồng ngày càng lớn và đa dạng, các phương pháp học máy cho phép khai thác tốt hơn thông tin trong dữ liệu, tự động cập nhật mô hình khi có dữ liệu mới và cải thiện độ chính xác dự báo. Điều này tạo động lực mạnh mẽ cho việc ứng dụng học máy vào sàng lọc sớm và quản lý nguy cơ tim mạch trong thực tế.

1.2 Tổng quan về học máy cho bài toán phân loại

1.2.1 Các khái niệm cơ bản

Học máy (Machine Learning) là lĩnh vực nghiên cứu các thuật toán cho phép mô hình học từ dữ liệu để đưa ra dự đoán hoặc quyết định mà không cần lập trình cứng từng quy tắc. Trong bài toán phân loại nguy cơ tim mạch, một số khái niệm cơ bản gồm:

- **Đặc trưng (feature):** các biến đầu vào mô tả đối tượng, ví dụ: thông tin nhân khẩu học (giới tính, độ tuổi), thói quen sinh hoạt (hút thuốc, vận động) và các chỉ số sức khỏe (BMI, huyết áp).
- **Nhãn (label):** biến đầu ra cần dự đoán, trong đề tài là trạng thái cá nhân có nguy cơ mắc bệnh tim mạch hay không.
- **Tập huấn luyện (training set):** phần dữ liệu dùng để mô hình học tham số.
- **Tập kiểm thử (test set):** phần dữ liệu tách riêng để đánh giá khả năng tổng quát hóa của mô hình.

Hai hiện tượng quan trọng cần lưu ý là:

- **Overfitting:** mô hình học quá sát dữ liệu huấn luyện (kể cả nhiễu), dẫn đến dự đoán tốt trên tập huấn luyện nhưng kém trên dữ liệu mới.
- **Underfitting:** mô hình quá đơn giản, không nắm bắt được quy luật trong dữ liệu, nên dự đoán kém cả trên tập huấn luyện lẫn kiểm thử.

1.2.2 Quy trình xây dựng mô hình học máy

Quy trình xây dựng một mô hình học máy cho bài toán phân loại thường bao gồm các bước chính:

- Thu thập và hiểu dữ liệu
- Tiền xử lý dữ liệu: làm sạch, mã hoá biến phân loại, chuẩn hoá các biến số, xử lý mất cân bằng lớp (nếu cần)
- Lựa chọn và trích chọn đặc trưng: chọn các đặc trưng quan trọng, có thể kết hợp với các kỹ thuật giảm chiều như PCA, LDA
- Huấn luyện mô hình: sử dụng tập huấn luyện để ước lượng tham số của các mô hình được lựa chọn (Logistic Regression, Naïve Bayes, ...)
- Đánh giá và tinh chỉnh: đánh giá mô hình trên tập kiểm thử bằng các thước đo phù hợp (Accuracy, Precision, Recall, F1, AUC), sau đó điều chỉnh siêu tham số nếu cần.

1.2.3 Bài toán phân loại nhị phân trong dự đoán tim mạch

Trong đề tài này, bài toán dự đoán nguy cơ tim mạch được mô hình hóa dưới dạng bài toán phân loại nhị phân. Mỗi cá nhân được biểu diễn bởi một vector đặc trưng:

$$\mathbf{x} = (x_1, x_2, \dots, x_d),$$

trong đó các thành phần có thể là thông tin nhân khẩu học, chỉ số sức khỏe (BMI), thói quen sinh hoạt,... Biến mục tiêu y nhận một trong hai giá trị: Biến mục tiêu y nhận một trong hai giá trị:

$$y = \begin{cases} 1, & \text{nếu cá nhân có nguy cơ mắc bệnh tim mạch (positive);} \\ 0, & \text{nếu cá nhân không có nguy cơ mắc bệnh tim mạch (negative).} \end{cases}$$

Mục tiêu của mô hình học máy là học được một hàm ánh xạ:

$$f : \mathbf{x} \mapsto \hat{y} \quad \text{hoặc} \quad f : \mathbf{x} \mapsto P(y = 1 \mid \mathbf{x}),$$

giúp ước lượng xác suất mắc bệnh của một cá nhân mới, từ đó hỗ trợ đội ngũ y tế trong việc ra quyết định sàng lọc, điều chỉnh tư vấn lối sống hoặc đề xuất các chính sách quản lý sức khỏe và can thiệp kịp thời.

1.3 Các mô hình phân loại sử dụng trong đề tài

1.3.1 Hồi quy Logistic (Logistic Regression)

Hồi quy Logistic là một mô hình phân loại nhị phân, trong đó nhận đầu ra chỉ nhận hai giá trị $y \in \{0, 1\}$. Mặc dù mang tên “hồi quy”, mô hình này được sử dụng chủ yếu cho bài toán phân lớp. Đây là một mô hình *phân biệt* (discriminative), vì nó mô hình hoá trực tiếp xác suất có điều kiện $P(y \mid \mathbf{x}; \boldsymbol{\theta})$ thay vì mô hình hoá phân bố của dữ liệu đầu vào.

Mô hình và hàm sigmoid

Với mỗi mẫu dữ liệu $\mathbf{x} \in \mathbb{R}^d$, mô hình Logistic Regression giả sử:

$$h_{\boldsymbol{\theta}}(\mathbf{x}) = g(\boldsymbol{\theta}^T \mathbf{x}) = \frac{1}{1 + \exp(-\boldsymbol{\theta}^T \mathbf{x})},$$

trong đó $g(s)$ là *hàm sigmoid* (hay hàm logistic). Hàm này thỏa các tính chất quan trọng: $g(s) \rightarrow 1$ khi $s \rightarrow +\infty$, $g(s) \rightarrow 0$ khi $s \rightarrow -\infty$ và $g(s) \in (0, 1)$ với mọi s . Nhờ đó $h_{\boldsymbol{\theta}}(\mathbf{x})$ có thể được diễn giải như xác suất:

$$P(y = 1 \mid \mathbf{x}; \boldsymbol{\theta}) = h_{\boldsymbol{\theta}}(\mathbf{x}), \quad P(y = 0 \mid \mathbf{x}; \boldsymbol{\theta}) = 1 - h_{\boldsymbol{\theta}}(\mathbf{x}).$$

Xác suất, hàm mất mát và luật quyết định

Ta có thể viết gọn xác suất của nhãn $y \in \{0, 1\}$ dưới dạng:

$$P(y \mid \mathbf{x}; \boldsymbol{\theta}) = (h_{\boldsymbol{\theta}}(\mathbf{x}))^y (1 - h_{\boldsymbol{\theta}}(\mathbf{x}))^{1-y}.$$

Với tập huấn luyện $\{(\mathbf{x}_n, y_n)\}_{n=1}^N$, ta cực đại hoá hàm hợp lý (likelihood) hoặc tương đương là cực đại hoá log-hợp lý:

$$\ell(\boldsymbol{\theta}) = \sum_{n=1}^N [y_n \log h_{\boldsymbol{\theta}}(\mathbf{x}_n) + (1 - y_n) \log(1 - h_{\boldsymbol{\theta}}(\mathbf{x}_n))].$$

Trong thực tế, ta thường *cực tiểu hoá* hàm mất mát âm log-hợp lý (cross-entropy):

$$J(\boldsymbol{\theta}) = -\ell(\boldsymbol{\theta}) = -\sum_{n=1}^N [y_n \log h_{\boldsymbol{\theta}}(\mathbf{x}_n) + (1 - y_n) \log(1 - h_{\boldsymbol{\theta}}(\mathbf{x}_n))].$$

Khi đã ước lượng được $\hat{\boldsymbol{\theta}}$, luật phân loại được sử dụng là:

$$\hat{y} = \begin{cases} 1, & \text{nếu } h_{\hat{\boldsymbol{\theta}}}(\mathbf{x}) \geq 0.5 \ (\Leftrightarrow \hat{\boldsymbol{\theta}}^T \mathbf{x} \geq 0), \\ 0, & \text{ngược lại.} \end{cases}$$

Tối ưu hoá và Regularization

Bài toán tối ưu hoá $J(\boldsymbol{\theta})$ thường được giải bằng các phương pháp lặp, như *Gradient Descent* hoặc *Stochastic Gradient Descent*. Với Gradient Descent toàn phần, ta cập nhật:

$$\boldsymbol{\theta} := \boldsymbol{\theta} - \alpha \nabla J(\boldsymbol{\theta}),$$

trong đó α là tốc độ học. Gradient của hàm mất mát có dạng:

$$\nabla J(\boldsymbol{\theta}) = \sum_{n=1}^N (h_{\boldsymbol{\theta}}(\mathbf{x}_n) - y_n) \mathbf{x}_n.$$

Để tránh quá khớp (overfitting), người ta thường bổ sung *regularization* vào hàm mất mát:

$$J_{\text{reg}}(\boldsymbol{\theta}) = J(\boldsymbol{\theta}) + \lambda \|\boldsymbol{\theta}\|_2^2,$$

với $\lambda \geq 0$ là hệ số điều chuẩn (L2-regularization), giúp khống chế độ lớn của các trọng số, giảm nhạy cảm với nhiễu và cải thiện khả năng tổng quát hoá.

1.3.2 Mô hình Naïve Bayes

Naïve Bayes là một mô hình phân loại *xác suất* dựa trên định lý Bayes với giả thiết mạnh mẽ rằng các đặc trưng là *độc lập có điều kiện* cho trước nhãn lớp. Với biến mục tiêu $y \in \{0, 1\}$ và vector đặc trưng $\mathbf{x} = (x_1, \dots, x_d)$, ta có:

$$P(y | \mathbf{x}) = \frac{P(\mathbf{x} | y)P(y)}{P(\mathbf{x})}.$$

Vì $P(\mathbf{x})$ không phụ thuộc vào y , luật quyết định có thể viết:

$$\hat{y} = \arg \max_{y \in \{0, 1\}} P(\mathbf{x} | y)P(y).$$

Với giả thiết độc lập có điều kiện:

$$P(\mathbf{x} | y) = \prod_{j=1}^d P(x_j | y).$$

Trong *Gaussian Naïve Bayes*, ta giả sử mỗi đặc trưng liên tục x_j (cho từng lớp y) tuân theo phân phối Gauss:

$$P(x_j | y = c) = \mathcal{N}(x_j; \mu_{c,j}, \sigma_{c,j}^2),$$

với $\mu_{c,j}$ và $\sigma_{c,j}^2$ được ước lượng từ dữ liệu huấn luyện của lớp c . Khi đó:

$$P(\mathbf{x} | y = c) = \prod_{j=1}^d \mathcal{N}(x_j; \mu_{c,j}, \sigma_{c,j}^2),$$

và xác suất hậu nghiệm được tính theo định lý Bayes, sau đó chọn lớp có xác suất lớn nhất.

1.4 Kỹ thuật giảm chiều PCA và LDA

1.4.1 Lý do cần giảm chiều dữ liệu

Trong nhiều bài toán thực tế, mỗi đối tượng được mô tả bởi một vector đặc trưng có số chiều rất lớn, trong khi số lượng mẫu cũng có thể rất lớn. Làm việc trực tiếp với dữ liệu có số chiều cao gây ra nhiều vấn đề:

- Chi phí tính toán và lưu trữ tăng mạnh khi số chiều tăng.
- “Lời nguyền chiều” (*curse of dimensionality*): dữ liệu trở nên “thừa”, mô hình dễ bị overfitting nếu không có đủ mẫu.
- Nhiều đặc trưng có thể dư thừa hoặc nhiễu.
- Việc trực quan hoá phân bố dữ liệu thường chỉ thực hiện được trong không gian 2D hoặc 3D.

Do đó, giảm chiều dữ liệu nhằm tìm một ánh xạ:

$$x \in \mathbb{R}^d \mapsto z \in \mathbb{R}^k, \quad k < d,$$

sao cho lượng thông tin quan trọng trong x được bảo toàn càng nhiều càng tốt.

1.4.2 Phân tích thành phần chính (Principal Component Analysis - PCA)

PCA là một phương pháp giảm chiều tuyến tính, không giám sát, tìm một hệ trục toạ độ mới sao cho phần lớn phương sai của dữ liệu được tập trung vào một số ít thành phần đầu tiên. Giả sử dữ liệu có dạng ma trận $X \in \mathbb{R}^{d \times N}$, mỗi cột là một mẫu:

1. Tính vector trung bình:

$$\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n.$$

2. Chuẩn hoá dữ liệu về trung tâm:

$$\hat{x}_n = x_n - \bar{x}, \quad \hat{X} = (\hat{x}_1, \dots, \hat{x}_N).$$

3. Tính ma trận hiệp phương sai:

$$S = \frac{1}{N} \hat{X} \hat{X}^T.$$

4. Tìm các giá trị riêng λ_i và vector riêng u_i của S , sắp xếp $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$.

5. Chọn k vector riêng đầu, tạo thành ma trận $U_k = (u_1, \dots, u_k) \in \mathbb{R}^{d \times k}$.

6. Chiếu dữ liệu:

$$Z = U_k^T \hat{X} \in \mathbb{R}^{k \times N}.$$

Tỷ lệ phương sai được giữ lại khi chọn k thành phần chính:

$$r_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^d \lambda_j}.$$

1.4.3 Phân tích biệt thức tuyến tính (Linear Discriminant Analysis - LDA) cho hai lớp

LDA là phương pháp giảm chiều tuyến tính có giám sát, sử dụng thông tin nhãn lớp để tìm không gian con trong đó các điểm cùng lớp càng tập trung và khoảng cách giữa các lớp càng lớn. Xét bài toán hai lớp X_1, X_2 với kỳ vọng m_1, m_2 . Ta xét phép chiếu tuyến tính:

$$z = w^T x, \quad w \in \mathbb{R}^d.$$

Hình chiếu của kỳ vọng lớp j là $\bar{m}_j = w^T m_j$. Gọi S_j^2 là phương sai của các điểm lớp j sau khi chiếu lên đường thẳng w . LDA tìm véc tơ w sao cho:

$$J(w) = \frac{(\bar{m}_1 - \bar{m}_2)^2}{S_1^2 + S_2^2}$$

đạt cực đại. Có thể viết lại:

$$J(w) = \frac{w^T S_B w}{w^T S_W w},$$

trong đó:

$$S_B = (m_1 - m_2)(m_1 - m_2)^T$$

là ma trận giữa lớp (between-class scatter), và

$$S_W = S_1 + S_2$$

là ma trận trong lớp (within-class scatter), với S_j là ma trận hiệp phương sai trong lớp j :

$$S_j = \sum_{x_n \in X_j} (x_n - m_j)(x_n - m_j)^T.$$

Bài toán tối ưu trở thành:

$$w = \arg \max_w \frac{w^T S_B w}{w^T S_W w},$$

và nghiệm thu được từ bài toán trị riêng tổng quát:

$$S_W^{-1} S_B w = \lambda w.$$

Vector riêng tương ứng với giá trị riêng lớn nhất chính là hướng chiếu LDA tối ưu cho bài toán hai lớp. Dữ liệu sau khi giảm chiều có dạng $z = w^T x$.

1.4.4 So sánh PCA và LDA trong bối cảnh dự đoán võ nộ

Trong dự đoán nguy cơ tim mạch:

- PCA không sử dụng nhãn lớp, phù hợp cho việc nén dữ liệu từ các đặc trưng như chỉ số sức khỏe, thói quen sinh hoạt và trực quan hóa dữ liệu.
- LDA sử dụng nhãn có bệnh/không có bệnh tim mạch, giúp tối ưu trực tiếp khả năng phân biệt giữa hai nhóm đối tượng, do đó thường hữu ích khi dùng làm bước tiền xử lý trước khi huấn luyện bộ phân loại.

1.5 Các thước đo đánh giá mô hình phân loại

1.5.1 Ma trận nhầm lẫn (Confusion Matrix)

Với bài toán phân loại nhị phân (cá nhân mắc bệnh tim mạch là lớp dương), ma trận nhầm lẫn có dạng:

	Dự đoán 0	Dự đoán 1
Thực 0	TN	FP
Thực 1	FN	TP

trong đó:

- TP (True Positive): số cá nhân thực sự mắc bệnh tim mạch và được mô hình dự đoán chính xác là mắc bệnh tim mạch.
- TN (True Negative): số cá nhân không mắc bệnh tim mạch và được mô hình dự đoán chính xác là không mắc bệnh tim mạch.
- FP (False Positive): số cá nhân không mắc bệnh tim mạch nhưng bị mô hình dự đoán nhầm là mắc bệnh tim mạch.
- FN (False Negative): số cá nhân mắc bệnh tim mạch nhưng bị mô hình dự đoán nhầm là không mắc bệnh tim mạch.

1.5.2 Accuracy, Precision, Recall, F1-score

Từ ma trận nhầm lẫn, ta có các thước đo:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN},$$

$$\text{Precision} = \frac{TP}{TP + FP},$$

$$\text{Recall} = \frac{TP}{TP + FN},$$

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

Trong bối cảnh dự đoán bệnh tim mạch, **Recall** của lớp có nguy cơ mắc bệnh đặc biệt quan trọng vì nó phản ánh tỷ lệ bệnh nhân thực tế được mô hình phát hiện, giúp tránh bỏ sót các ca bệnh tiềm ẩn; tuy nhiên, Precision cũng cần được cân nhắc để tránh gây lo lắng dư thừa hoặc chỉ định các xét nghiệm chuyên sâu tốn kém không cần thiết cho người khỏe mạnh.

1.5.3 Đường cong ROC và chỉ số AUC

Đường cong ROC (Receiver Operating Characteristic) biểu diễn mối quan hệ giữa:

$$\text{TPR} = \frac{TP}{TP + FN} \quad (\text{True Positive Rate, hay Recall})$$

và

$$\text{FPR} = \frac{FP}{FP + TN} \quad (\text{False Positive Rate}),$$

khi ta thay đổi ngưỡng phân loại trên xác suất dự đoán. Chỉ số AUC (Area Under the Curve) là diện tích dưới đường cong ROC, có giá trị trong khoảng $[0, 1]$. AUC càng gần 1 thì mô hình càng có khả năng phân biệt tốt giữa người có nguy cơ và người không có nguy cơ mắc bệnh; $\text{AUC} = 0.5$ tương đương với phân loại ngẫu nhiên.

1.5.4 Lựa chọn ngưỡng phân loại

Trong thực tế, ngưỡng mặc định 0.5 không phải lúc nào cũng tối ưu. Đội ngũ y tế hoặc nhà nghiên cứu có thể điều chỉnh ngưỡng nhằm cân bằng giữa:

- **Giảm FN (bỏ sót bệnh nhân có nguy cơ):** Để đảm bảo bệnh nhân được can thiệp và điều trị sớm, giảm thiểu rủi ro biến cố tim mạch.
- **Giữ FP ở mức chấp nhận được:** Để tránh áp lực tâm lý cho người dân và giảm tải chi phí xét nghiệm sàng lọc không cần thiết cho hệ thống y tế.

Việc lựa chọn ngưỡng có thể dựa trên đường ROC, đường Precision-Recall hoặc các tiêu chí y tế cộng đồng cụ thể (chi phí sàng lọc, hiệu quả điều trị dự phòng).

1.6 Tóm tắt chương

Chương này đã trình bày các cơ sở lý thuyết chính cho đề tài: bối cảnh rủi ro tín dụng và chấm điểm tín dụng, các khái niệm cơ bản trong học máy cho bài toán phân loại, mô hình hồi quy Logistic và Naïve Bayes, các kỹ thuật giảm chiều PCA và LDA, phân cụm K-Means, cùng các thước đo đánh giá như Confusion Matrix, Accuracy, Precision, Recall, F1 và ROC–AUC. Đây là nền tảng để các chương sau áp dụng vào xây dựng và đánh giá mô hình dự đoán khả năng vỡ nợ trên bộ dữ liệu thực nghiệm.

CHƯƠNG 2

Thực nghiệm trên bộ dữ liệu

2.1 Dữ liệu nghiên cứu

2.1.1 Giới thiệu dữ liệu

Bộ dữ liệu được sử dụng trong nghiên cứu này là *Heart Disease*, được trích xuất từ Hệ thống Giám sát Rủi ro Sức khỏe Hành vi (Behavioral Risk Factor Surveillance System - BRFSS) năm 2020 của Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh Hoa Kỳ (CDC). Bộ dữ liệu mô tả các thông tin liên quan đến nhân khẩu học, chỉ số sức khỏe hiện tại và các thói quen sinh hoạt hàng ngày của các cá nhân tại Hoa Kỳ.

Bộ dữ liệu gồm tổng cộng khoảng 319.795 bản ghi (mẫu quan sát), với 17 biến đầu vào (đặc trưng) và 1 biến đầu ra (biến mục tiêu). Biến mục tiêu HeartDisease biểu diễn trạng thái mắc bệnh tim mạch của cá nhân (1: Có, 0: Không). Trong số các biến đầu vào, mô hình tập trung khai thác các nhóm đặc trưng chính bao gồm:

- **Chỉ số sức khỏe:** BMI, tình trạng sức khỏe thể chất/tinh thần, thời gian ngủ.
- **Thói quen sinh hoạt:** Hút thuốc, uống rượu, hoạt động thể chất.
- **Tiền sử bệnh lý:** Đột quỵ, hen suyễn, bệnh thận, ung thư da, tiểu đường.
- **Nhân khẩu học:** Giới tính, nhóm tuổi, chủng tộc.

2.1.2 Mô tả các đặc trưng

Bộ dữ liệu sử dụng trong đề tài gồm 18 thuộc tính, trong đó có 17 biến đầu vào (giải thích) và 1 biến mục tiêu (phản hồi). Các thuộc tính có thể được chia thành ba nhóm: biến phân loại, biến số (định lượng) và biến mục tiêu.

Các biến phân loại (Categorical variables):

- **SEX** biến phân loại, cho biết giới tính của cá nhân (Male; Female).
- **AgeCategory:** biến phân loại có thứ bậc, biểu diễn nhóm tuổi của cá nhân (gồm 13 nhóm từ 18-24 đến 80 trở lên).
- **Race:** biến phân loại, cho biết chủng tộc/sắc tộc của cá nhân (White, Black, Asian, American Indian/Alaskan Native, Hispanic, Other).
- **Diabetic:** biến phân loại, biểu diễn tình trạng bệnh tiểu đường (Yes, No).
- **GenHealth:** biến phân loại có thứ bậc, cá nhân tự đánh giá sức khỏe tổng quát (Poor, Fair, Good, Very good, Excellent).

- **Các biến nhị phân (Yes/No):** bao gồm một loạt các biến mô tả thói quen sinh hoạt và tiền sử bệnh lý:
 - **Smoking:** Có hút ít nhất 100 điếu thuốc trong đời hay không.
 - **AlcoholDrinking:** Có uống rượu bia nhiều hay không (Nam >14 ly/tuần, Nữ >7 ly/tuần).
 - **Stroke:** Có từng bị đột quỵ hay không.
 - **DiffWalking:** Có gặp khó khăn nghiêm trọng khi đi bộ hoặc leo cầu thang không.
 - **PhysicalActivity:** Có tham gia hoạt động thể chất hoặc tập thể dục trong 30 ngày qua không.
 - **Asthma:** Có từng bị hen suyễn hay không.
 - **KidneyDisease:** Có từng bị bệnh thận hay không (không bao gồm sỏi thận, nhiễm trùng bàng quang).
 - **SkinCancer:** Có từng bị ung thư da hay không.

Các biến số (định lượng):

- **BMI:** biến số thực, chỉ số khối cơ thể (Body Mass Index), được tính dựa trên chiều cao và cân nặng.
- **PhysicalHealth:** biến số nguyên, số ngày trong 30 ngày gần nhất cá nhân cảm thấy sức khỏe thể chất (bao gồm bệnh tật và chấn thương) không tốt.
- **MentalHealth:** biến số nguyên, số ngày trong 30 ngày gần nhất cá nhân cảm thấy sức khỏe tinh thần không tốt.
- **SleepTime:** biến số nguyên, số giờ ngủ trung bình của cá nhân trong một chu kỳ 24 giờ.

Biến mục tiêu:

- **HeartDisease (Y):** biến nhị phân, đóng vai trò là biến phản hồi (biến mục tiêu) của mô hình. Biến này biểu diễn trạng thái cá nhân có từng được chẩn đoán mắc bệnh mạch vành (CHD) hoặc nhồi máu cơ tim (MI) hay không:
 - **Giá trị Yes:** Cá nhân có nguy cơ/mắc bệnh tim mạch.
 - **Giá trị No:** Cá nhân không có nguy cơ/mắc bệnh tim mạch.

2.1.3 Thống kê dữ liệu sơ bộ

Để có cái nhìn tổng quan về cấu trúc và phân bố dữ liệu, nghiên cứu sử dụng hai lệnh `df.info()` (thông tin kiểu dữ liệu, số giá trị khác rỗng) và `df.describe()` (các thống kê mô tả cơ bản cho các biến số).

```

<class 'pandas.DataFrame'>
RangeIndex: 319795 entries, 0 to 319794
Data columns (total 18 columns):
#   Column                Non-Null Count  Dtype
---  -
0   HeartDisease          319795 non-null  str
1   BMI                   319795 non-null  float64
2   Smoking               319795 non-null  str
3   AlcoholDrinking       319795 non-null  str
4   Stroke                319795 non-null  str
5   PhysicalHealth        319795 non-null  float64
6   MentalHealth          319795 non-null  float64
7   DiffWalking           319795 non-null  str
8   Sex                   319795 non-null  str
9   AgeCategory           319795 non-null  str
10  Race                   319795 non-null  str
11  Diabetic               319795 non-null  str
12  PhysicalActivity       319795 non-null  str
13  GenHealth              319795 non-null  str
14  SleepTime              319795 non-null  float64
15  Asthma                 319795 non-null  str
16  KidneyDisease          319795 non-null  str
17  SkinCancer             319795 non-null  str
dtypes: float64(4), str(14)
memory usage: 43.9 MB

```

Hình 2.1: Kết quả lệnh `df.info()`.

Nhận xét: Tất cả 18 cột đều hiển thị 319.795 non-null. Điều này chứng tỏ bộ dữ liệu không có giá trị thiếu (missing values).

2.1.4 Loại bỏ dữ liệu trùng lặp

Trong quá trình thu thập và trích xuất dữ liệu từ các khảo sát quy mô lớn như BRFSS, việc xuất hiện các bản ghi trùng lặp hoàn toàn (identical records) là điều khó tránh khỏi. Việc tồn tại các dòng trùng lặp có thể gây ra hiện tượng thiên kiến (bias), khiến mô hình học máy đánh giá sai lệch tầm quan trọng của một số nhóm đặc trưng cụ thể, dẫn đến nguy cơ quá khớp (overfitting). Để đảm bảo tính khách quan và duy trì chất lượng dữ liệu, nghiên cứu thực hiện các bước sau:

- **Nhận diện và loại bỏ:** Sử dụng phương thức `drop_duplicates()` để rà soát toàn bộ tập dữ liệu và chỉ giữ lại bản ghi đầu tiên trong số các dòng có giá trị hoàn toàn giống nhau ở tất cả các cột.
- **Đánh lại chỉ số (Reset Index):** Sau khi các dòng trùng lặp bị xóa bỏ, các chỉ số hàng (index) ban đầu sẽ bị gián đoạn. Do đó, hàm `reset_index(drop=True)` được áp dụng để thiết lập lại hệ thống chỉ số bắt đầu từ 0 một cách liên tục, tạo điều

kiện thuận lợi cho các thao tác truy xuất và phân chia dữ liệu (Train-Test Split) về sau.

	BMI	PhysicalHealth	MentalHealth	SleepTime
count	301717.000000	301717.000000	301717.000000	301717.000000
mean	28.441970	3.572298	4.121475	7.084559
std	6.468134	8.140656	8.128288	1.467122
min	12.020000	0.000000	0.000000	1.000000
25%	24.030000	0.000000	0.000000	6.000000
50%	27.410000	0.000000	0.000000	7.000000
75%	31.650000	2.000000	4.000000	8.000000
max	94.850000	30.000000	30.000000	24.000000


Hình 2.2: Kết quả lệnh `df.describe()` sau khi xóa lặp

Từ kết quả `df.describe()` có một số nhận xét quan trọng:

- Đặc trưng rủi ro: Chỉ số **BMI** trung bình của tập dữ liệu (28.44) vượt ngưỡng bình thường (18.5 – 24.9), cho thấy tập mẫu có nguy cơ cao về các bệnh lý liên quan đến cân nặng, trong đó có tim mạch.
- Các biến **PhysicalHealth** **MentalHealth** có độ lệch chuẩn cao (≈ 8.13) cao gấp đôi so với trung bình (≈ 3.57 và 4.12), điều này chứng tỏ sự khác biệt rất lớn về tình trạng sức khỏe giữa các cá nhân trong cộng đồng.
- Thời gian ngủ **SleepTime** có phân phối trông "đẹp" nhất. Trung bình là 7.1 giờ và trung vị là 7.0 giờ, rất sát với khuyến nghị sức khỏe thông thường.


2.1.5 Trực quan dữ liệu ban đầu

Bên cạnh các thống kê mô tả, nghiên cứu còn sử dụng một số biểu đồ trực quan để quan sát phân bố dữ liệu và phát hiện các đặc điểm bất thường. Trước hết, phân bố của biến mục tiêu **HeartDisease** được biểu diễn bằng biểu đồ cột, cho thấy mức độ mất cân bằng giữa lớp có nguy cơ mắc bệnh tim mạch và không mắc bệnh.




Hình 2.3: Phân bố biến mục tiêu **Heart Disease**.

Tiếp theo, các biến số (như BMI, PhysicalHealth, MentalHealth, SleepTime) được trực quan bằng các biểu đồ histogram để quan sát phân bố, độ lệch và sự xuất hiện của các giá trị ngoại lai.



Hình 2.4: Histogram một số biến số quan trọng trong bộ dữ liệu.

Đối với các biến phân loại (như **Sex**, **Smoking**, **DiffWalking**, **Stroke** ...), nghiên cứu sử dụng biểu đồ cột để quan sát tần suất từng giá trị và so sánh phân bố giữa các nhóm.




Hình 2.5: Biểu đồ tần suất một số biến phân loại trong bộ dữ liệu.

2.1.6 Xử lý giá trị ngoại lệ (Outliers)

Dựa trên kết quả thống kê mô tả và trực quan hóa ban đầu, các biến định lượng gồm **BMI**, **PhysicalHealth**, **MentalHealth** và **SleepTime** xuất hiện nhiều giá trị ngoại lệ cực đoan. Việc giữ nguyên các giá trị này có thể gây nhiễu cho quá trình huấn luyện, làm giảm khả năng hội tụ và độ chính xác của các thuật toán nhạy cảm với khoảng cách như Logistic Regression.


Để khắc phục hiện tượng này mà không làm mất đi thông tin của toàn bộ bản ghi, nghiên cứu áp dụng kỹ thuật Capping (Winsorization). Các bước thực hiện cụ thể như sau:

- **Xác định ngưỡng giới hạn:** Sử dụng phương pháp phân vị để xác định ngưỡng dưới tại mức 1% (lower limit) và ngưỡng trên tại mức 99% (upper limit) cho từng đặc trưng số học.
- **Thực hiện kẹp giá trị (Clipping):** hay thế toàn bộ các giá trị nằm ngoài khoảng $[0.01, 0.99]$ bằng chính giá trị tại ngưỡng tương ứng.



Hình 2.6: Boxplot **BMI**, **PhysicalHealth** , **MentalHealth** và **SleepTime** trước khi xử lý Outliers.

Kết quả sau khi xử lý: Việc áp dụng kỹ thuật Capping mang lại sự cải thiện rõ rệt cho phân phối dữ liệu thông qua quan sát biểu đồ hộp (boxplot):



Hình 2.7: Boxplot **BMI**, **PhysicalHealth** , **MentalHealth** và **SleepTime** sau khi xử lý Outliers.

2.1.7 Phân chia dữ liệu (Train–Test Split)

Sau khi làm sạch dữ liệu và xử lý các giá trị ngoại lệ, bộ dữ liệu gồm 319.795 quan sát và 17 đặc trưng đầu vào. Để khảo sát ảnh hưởng của kích thước tập huấn luyện tới chất lượng mô hình dự đoán nguy cơ tim mạch, nghiên cứu thực hiện ba kịch bản chia dữ liệu khác nhau bằng hàm `train_test_split` của thư viện `scikit-learn`, với các tỉ lệ:

- **Kịch bản 1 (80/20):** 80% dữ liệu dùng để huấn luyện, 20% dữ liệu dùng để kiểm tra.
- **Kịch bản 2 (70/30):** 70% dữ liệu dùng để huấn luyện, 30% dữ liệu dùng để kiểm tra.
- **Kịch bản 3 (60/40):** 60% dữ liệu dùng để huấn luyện, 40% dữ liệu dùng để kiểm tra.

Trong cả ba kịch bản, để đảm bảo tỉ lệ giữa hai lớp (Có bệnh tim / Không bệnh tim) được giữ nguyên trong tập huấn luyện và kiểm tra, tham số `stratify = y` được sử dụng khi gọi hàm `train_test_split`.

Kịch bản	Tỉ lệ train:test	Số mẫu train	Số mẫu test
Kịch bản 1	80% : 20%	241 373	60 344
Kịch bản 2	70% : 30%	211 201	90 516
Kịch bản 3	60% : 40%	181 030	120 687

Bảng 2.1: Kích thước các tập dữ liệu với ba kịch bản chia train–test

2.1.8 Biến đổi đặc trưng (Feature engineering)

Bước tiền xử lý đặc trưng bao gồm hai nhóm thao tác chính: chuẩn hoá các biến số và mã hoá các biến phân loại.

2.1.9 Biến đổi đặc trưng (Feature engineering)

Trong toàn bộ các thí nghiệm, quy trình biến đổi đặc trưng được thực hiện thống nhất nhằm chuẩn bị dữ liệu tối ưu cho các kỹ thuật giảm chiều (PCA, LDA) và các mô hình phân loại (Logistic Regression, Naïve Bayes). Quy trình này được thực hiện theo trình tự: mã hóa các biến phân loại trước, sau đó tiến hành chuẩn hóa toàn bộ tập đặc trưng.

Mã hoá (Encoding): Trước tiên, các thuộc tính phân loại bao gồm Sex, AgeCategory, Race, Diabetic, GenHealth và các biến trạng thái (Yes/No) được xử lý bằng mã hóa one-hot thông qua OneHotEncoder (hoặc cài đặt tương đương). Phương pháp này giúp:

- Tránh áp đặt thứ bậc giả tạo giữa các nhãn phân loại, đặc biệt là với các biến không có tính thứ tự tự nhiên như **Race** hay **Sex**.
- Biến mỗi giá trị phân loại thành một biến nhị phân (0/1), giúp các mô hình tuyến tính dễ học hơn.

Bộ mã hóa one-hot được `fit` trên phần dữ liệu huấn luyện, sau đó được dùng để biến đổi cả `X_train` và `X_test` để đảm bảo tính nhất quán.

Chuẩn hoá (Scaling): Các mô hình như hồi quy Logistic, Naïve Bayes với giả thiết Gaussian, cũng như PCA, LDA, đều khá nhạy cảm với thang đo của biến đầu vào. Do đó, nghiên cứu sử dụng `StandardScaler` (hoặc cài đặt tương đương) để chuẩn hoá các đặc trưng số theo công thức:

$$x' = \frac{x - \mu}{\sigma},$$

trong đó μ và σ lần lượt là trung bình và độ lệch chuẩn của từng biến số trên *tập huấn luyện*.

Nhóm đặc trưng được chuẩn hóa bao gồm các biến định lượng gốc (**BMI**, **PhysicalHealth**, **MentalHealth**, **SleepTime**) và toàn bộ các cột đã được mã hóa one-hot. Tương tự bước mã hóa, bộ `StandardScaler` chỉ được `fit` trên `X_train` sau khi đã mã hóa và áp dụng hàm `transform` cho cả `X_train` và `X_test` để tránh hiện tượng rò rỉ thông tin (data leakage).

	mean	std	min	max
BMI	5.216332e-16	1.000002	-2.530001	10.269608
Smoking	-4.715894e-17	1.000002	-0.853203	1.172053
AlcoholDrinking	3.938743e-17	1.000002	-0.277247	3.606895
Stroke	-6.311409e-17	1.000002	-0.204554	4.888682
PhysicalHealth	5.298757e-17	1.000002	-0.439058	3.239070
MentalHealth	-2.531628e-17	1.000002	-0.506526	3.180313
DiffWalking	-8.831262e-17	1.000002	-0.415844	2.404747
Sex	-2.143053e-17	1.000002	-0.944501	1.058760
AgeCategory	-8.230736e-17	1.000002	-1.816830	1.532528
PhysicalActivity	5.969933e-17	1.000002	-1.799826	0.555609


Hình 2.8: Hình mô tả một số thuộc tính của dữ liệu sau khi xử lý.

2.2 Phương pháp thí nghiệm giảm chiều

2.2.1 Phương pháp 1: PCA (Phân tích thành phần chính)

Trong nghiên cứu này, PCA được sử dụng như một bước tiền xử lý nhằm:


- Khai thác các thành phần chính giải thích phần lớn phương sai của dữ liệu, chọn lượng phương sai được giải thích là 90%
- Giảm số chiều đầu vào và hỗ trợ trực quan hoá cấu trúc dữ liệu trong không gian 2 chiều.



Hình 2.9: Mức độ đóng góp của các thành phần PCA

PCA được áp dụng trên ma trận `X_train_processed` (sau khi đã chuẩn hoá và mã hoá) cho kịch bản (80/20). Quy trình thực nghiệm như sau:

- Với mỗi kịch bản chia dữ liệu, PCA được `fit` trên `X_train_processed` và sau đó được dùng để biến đổi cả `X_train_processed` và `X_test_processed`.
 - Trực quan hoá dữ liệu trên mặt phẳng 2D, với màu sắc biểu diễn hai lớp (có bệnh / không có bệnh), giúp quan sát khả năng phân tách của dữ liệu sau khi giảm chiều.
 - Làm đầu vào cho một số mô hình phân loại (Logistic Regression, Gaussian Naïve Bayes, ...) nhằm so sánh hiệu quả giữa mô hình dùng toàn bộ đặc trưng và mô hình dùng đặc trưng đã giảm chiều.
- Tỷ lệ phương sai được giải thích bởi hai thành phần chính đầu tiên cũng được thống kê cho từng kịch bản chia dữ liệu, để đánh giá mức độ thông tin được giữ lại khi giảm chiều xuống 2.



Hình 2.10: Trực quan hóa phân tích thành phần chính

Nhận xét từ kết quả thực nghiệm:

- Cặp thành phần PC_1 và PC_2 :** Đây là mặt phẳng chiếu cho thấy sự phân tán của dữ liệu rộng nhất do PC_1 đóng góp tỷ lệ phương sai giải thích cao nhất (khoảng 12.12%). Tuy nhiên, quan sát trực quan cho thấy hai nhãn dữ liệu vẫn chồng lấn lên nhau một cách đáng kể, không tạo ra ranh giới phân tách rõ rệt.
- Các cặp PC tiếp theo ($PC_3 - PC_4$, $PC_5 - PC_6$):** Tỷ lệ phương sai giải thích giảm dần (chỉ còn khoảng 4% – 6% cho mỗi thành phần). Cấu trúc cụm dữ liệu trên các mặt phẳng này có xu hướng "tròn" hơn, cho thấy ít có sự biến thiên đặc trưng theo một hướng cụ thể, khiến khả năng phân tách nhãn càng trở nên khó khăn hơn so với cặp đầu tiên.
- Đánh giá chung:** Kết quả này giải thích lý do tại sao việc chỉ sử dụng một vài thành phần chính đầu tiên là chưa đủ để xây dựng mô hình phân loại chính xác. Thông tin đặc trưng của tập dữ liệu bị phân tán ở rất nhiều chiều khác nhau; cụ thể, hệ thống cần giữ lại tới 19 thành phần chính mới có thể bảo tồn được 90% lượng thông tin ban đầu. Điều này minh chứng cho tính chất phức tạp và đa chiều của dữ liệu bệnh tim đang xét.

2.2.2 Phương pháp 2: LDA (Phân tích phân biệt tuyến tính)

Song song với PCA, nghiên cứu áp dụng LDA như một phương pháp giảm chiều có giám sát, nhằm:


- Tối đa hoá khả năng phân tách giữa hai lớp (có bệnh / không có bệnh).
- So sánh trực quan kết quả giảm chiều có giám sát (LDA) với kết quả giảm chiều không giám sát (PCA với $k = 2$).

Vì bài toán chỉ có hai lớp, số chiều tối đa sau LDA là 1. Do đó, nghiên cứu xét kịch bản duy nhất:

- $k = 1$: LDA biến đổi `X_train_processed` và `X_test_processed` về một trục duy nhất. Trên trục này, phân bố các điểm thuộc hai lớp được trực quan bằng Scatter1D hoặc mật độ (density plot), cho phép đánh giá trực quan mức độ chồng lấn giữa hai lớp sau khi giảm chiều.

Tương tự PCA, các đặc trưng một chiều thu được từ LDA cũng được sử dụng làm đầu vào cho các mô hình phân loại, nhằm so sánh hiệu quả giữa:

- Mô hình huấn luyện trên toàn bộ đặc trưng ban đầu.
- Mô hình huấn luyện trên dữ liệu đã giảm chiều bởi PCA ($k = 2$).
- Mô hình huấn luyện trên dữ liệu đã giảm chiều bởi LDA ($k = 1$).



Hình 2.11: Trực quan hóa phân phối dữ liệu sau LDA($k=1$)

Nhận xét và đánh giá:

- **Khả năng phân tách lớp:** LDA đã thành công trong việc tìm ra một trục chiều (LD1) giúp phân tách tương đối hai nhóm đối tượng nghiên cứu. Quan sát biểu đồ cho thấy phân phối của Lớp 0 (Không bệnh) tập trung chủ yếu ở vùng giá trị âm với mật độ cao nhất tại khoảng -0.5, trong khi Lớp 1 (Có bệnh) dịch chuyển rõ rệt sang phía giá trị dương với đỉnh phân phối nằm quanh mức 0.7.

- **Mức độ chồng lấn (Overlap):** Mặc dù hai đỉnh phân phối đã có sự tách biệt về vị trí, biểu đồ cho thấy một vùng chồng lấn đáng kể giữa hai lớp, đặc biệt là trong khoảng giá trị LD1 từ -1.0 đến 3.0. Điều này phản ánh thực tế y tế rằng các yếu tố rủi ro hành vi và chỉ số sinh học có sự giao thoa lớn; nhiều cá nhân không mắc bệnh vẫn sở hữu các đặc điểm tương đồng với nhóm có bệnh và ngược lại.
- **Đặc điểm phân phối:** Lớp 0 có phân phối nhọn và tập trung hơn, trong khi lớp 1 có phân phối trải rộng hơn về phía bên phải (giá trị dương lớn). Điều này cho thấy nhóm có nguy cơ mắc bệnh tim mạch có sự biến thiên lớn hơn về các đặc trưng đầu vào so với nhóm khỏe mạnh.
- **Đánh giá hiệu quả giảm chiều:** Kết quả trực quan này xác nhận rằng LDA đã tối ưu hóa hướng chiếu để phân biệt hai lớp tốt hơn so với các phương pháp không giám sát. Tuy nhiên, sự chồng lấn dữ liệu gợi ý rằng việc phân loại chỉ dựa trên một chiều LD1 sẽ gặp thách thức tại các vùng giao thoa, đòi hỏi sự kết hợp của các thuật toán phân loại mạnh mẽ ở bước tiếp theo để tối ưu hóa ranh giới quyết định.

2.3 Phương pháp thí nghiệm phân loại

2.3.1 Lựa chọn mô hình

Để giải bài toán dự đoán tim mạch, nghiên cứu sử dụng hai mô hình phân loại cơ bản nhưng tiêu biểu:

- **Gaussian Naïve Bayes (GNB):** mô hình sinh (generative), giả định các đặc trưng (sau khi chuẩn hoá) độc lập có phân bố chuẩn theo từng lớp. Mô hình đơn giản, huấn luyện nhanh và có khả năng khái quát tương đối tốt trong môi trường dữ liệu nhiễu.
- **Hồi quy Logistic:** mô hình phân biệt tuyến tính (discriminative), mô hình hoá trực tiếp xác suất $P(y = 1 | \mathbf{x})$ thông qua hàm sigmoid. Đây là mô hình chuẩn mực cho bài toán phân loại nhị phân và cho phép diễn giải thông qua hệ số của các đặc trưng.

Trong các thí nghiệm, Logistic Regression được xem là mô hình tuyến tính tham chiếu, còn Gaussian Naïve Bayes là mô hình đơn giản dựa trên giả thiết xác suất; việc so sánh hai mô hình giúp đánh giá mức độ phù hợp của giả thiết độc lập/Gaussian so với mô hình phân biệt tuyến tính trên cùng một bộ đặc trưng.

2.3.2 Kịch bản thí nghiệm

Để đánh giá ảnh hưởng của dạng biểu diễn dữ liệu và tỉ lệ train/test, nghiên cứu xây dựng các kịch bản thí nghiệm dựa trên ba loại đầu vào và ba cách chia dữ liệu.

Ba loại dữ liệu đầu vào Với mỗi cách chia dữ liệu, các mô hình được huấn luyện và đánh giá trên ba phiên bản đặc trưng khác nhau:

1. **Dữ liệu gốc đã tiền xử lý:** sử dụng trực tiếp ma trận đặc trưng $X_{processed}$ (sau các bước chuẩn hoá và mã hoá one-hot) làm đầu vào cho mô hình.

2. **Dữ liệu sau PCA 2 chiều:** áp dụng PCA với $k = 2$ trên `X_train_processed` để thu được hai thành phần chính đầu tiên; các mô hình được huấn luyện và đánh giá trên dữ liệu đã giảm chiều này (`X_pca_2d`). Kịch bản này chủ yếu nhằm xem xét khả năng phân loại khi chỉ giữ lại hai chiều dùng cho trực quan.
3. **Dữ liệu sau LDA 1 chiều:** áp dụng LDA nhị phân trên `X_train_processed` để thu được một đặc trưng mới duy nhất (`X_lda_1d`) tối đa hoá khả năng phân biệt hai lớp; hai mô hình được huấn luyện trên trục LDA này để so sánh với trường hợp dùng toàn bộ đặc trưng hoặc PCA.

Ba tỉ lệ chia train/test Mỗi loại dữ liệu trên được thử nghiệm dưới ba kịch bản chia train/test khác nhau:

- **Chia 70/30:** 70% mẫu dùng để huấn luyện, 30% mẫu dùng để kiểm tra.
- **Chia 80/20:** 80% mẫu dùng để huấn luyện, 20% mẫu dùng để kiểm tra.
- **Chia 60/40:** 60% mẫu dùng để huấn luyện, 40% mẫu dùng để kiểm tra.

Trong tất cả các trường hợp, tham số `stratify = y` của hàm `train_test_split` được sử dụng để giữ nguyên tỉ lệ hai lớp (có bệnh / không có bệnh) giữa tập huấn luyện và tập kiểm tra. Các biến đổi PCA và LDA luôn được `fit` trên tập huấn luyện, sau đó áp dụng cho tập kiểm tra tương ứng để tránh rò rỉ thông tin(data leakage).

2.3.3 Phương pháp đánh giá mô hình

Hiệu năng của Gaussian Naïve Bayes và Logistic Regression được đánh giá bằng các độ đo chuẩn trong phân loại nhị phân:

- **Ma trận nhầm lẫn** (Confusion Matrix) và các thành phần TP, TN, FP, FN.
- **Accuracy:** độ chính xác tổng thể.
- **Precision:** độ chính xác của các dự đoán có bệnh (lớp dương).
- **Recall:** tỉ lệ phát hiện đúng các cá nhân có bệnh.
- **F1-Score:** trung bình điều hoà giữa Precision và Recall.
- **ROC–AUC:** diện tích dưới đường cong ROC, phản ánh khả năng phân tách hai lớp dưới nhiều ngưỡng khác nhau.

Do dữ liệu bị mất cân bằng (tỉ lệ khách có bệnh thấp), các chỉ số Recall, F1-Score và ROC–AUC được ưu tiên xem xét hơn so với Accuracy, nhằm đánh giá đúng hơn khả năng mô hình nhận diện các cá nhân có nguy cơ mắc bệnh tim mạch trong từng kịch bản dữ liệu và từng mô hình phân loại.

CHƯƠNG 3

So sánh và đánh giá kết quả thực nghiệm

3.1 Tổng quan các thí nghiệm

Dựa trên khung phương pháp đã trình bày ở Chương 2, chương này trình bày và phân tích các kết quả thực nghiệm trên bộ dữ liệu Heart Disease. Các thí nghiệm tập trung vào:

- So sánh hai mô hình phân loại **Gaussian Naïve Bayes** (GNB) và **Hồi quy Logistic** trên các dạng biểu diễn dữ liệu khác nhau.
- Đánh giá tác động của **tỉ lệ chia train/test** (70/30, 80/20, 60/40) tới chất lượng mô hình.
- Phân tích ảnh hưởng của **giảm chiều** bằng PCA (2D) và LDA (1D) đối với hiệu năng phân loại.

Trong từng kịch bản, các mô hình được huấn luyện trên tập huấn luyện (đã tiền xử lý) và đánh giá trên tập kiểm tra tương ứng bằng các độ đo: Accuracy, Precision, Recall, F1-Score, ROC-AUC và ma trận nhầm lẫn

3.2 Kết quả phân loại trên dữ liệu gốc

3.2.1 Bảng kết quả

Trước hết, hai mô hình GNB và Logistic Regression được huấn luyện trên **dữ liệu gốc đã tiền xử lý** ($X_{processed}$), không giảm chiều, với ba tỉ lệ chia dữ liệu khác nhau. Các kết quả chi tiết (Accuracy, Precision, Recall, F1, ROC-AUC) cho từng mô hình và từng tỉ lệ được tóm tắt trong Bảng 3.1.

Mô hình	Train:Test	Accuracy	Precision	Recall	F1	ROC-AUC
Gaussian NB	80:20	0.8033	0.2415	0.5495	0.3355	0.7865
Gaussian NB	70:30	0.8042	0.2435	0.5538	0.3383	0.7882
Gaussian NB	60:40	0.8047	0.2445	0.5560	0.3396	0.7900
Logistic Regression	80:20	0.7429	0.2274	0.7698	0.3511	0.8324
Logistic Regression	70:30	0.7427	0.2272	0.7691	0.3508	0.8324
Logistic Regression	60:40	0.7428	0.2272	0.7694	0.3509	0.8321

Bảng 3.1: Kết quả phân loại trên dữ liệu gốc đã tiền xử lý với các tỉ lệ chia khác nhau

3.2.2 Nhận xét

1. So sánh hiệu năng giữa hai mô hình:

- **Về Accuracy (Độ chính xác tổng thể):** Mô hình **Gaussian NB** đạt kết quả tốt hơn với giá trị dao động từ **0.8033** đến **0.8047**, trong khi **Logistic Regression** chỉ đạt khoảng **0.7428**.
- **Về Recall (Độ nhạy):** Đây là chỉ số quan trọng nhất trong y tế để tránh bỏ sót bệnh nhân. **Logistic Regression** vượt trội hoàn toàn với ≈ 0.769 , cao hơn rất nhiều so với mức ≈ 0.55 của **Gaussian NB**.
- **Về ROC-AUC:** **Logistic Regression** đạt chỉ số ấn tượng hơn ≈ 0.832 so với **Gaussian NB** ≈ 0.79 , cho thấy khả năng phân biệt giữa người có bệnh và người không có bệnh của hồi quy **Logistic** tốt hơn.

2. Đánh giá trong bối cảnh chẩn đoán tim mạch: Mặc dù **Gaussian NB** có độ chính xác (Accuracy) cao hơn, nhưng trong bài toán sàng lọc bệnh lý, **Logistic Regression** lại là lựa chọn tối ưu hơn.

- Việc **Logistic Regression** có Recall cao $\approx 77\%$ đồng nghĩa với việc mô hình phát hiện được phần lớn những người thực sự mắc bệnh.
- **Precision** của cả hai mô hình đều thấp $\approx (0.22 - 0.24)$, cho thấy dữ liệu có sự mất cân bằng lớn giữa hai lớp (lớp bệnh nhân chiếm tỉ lệ nhỏ), dẫn đến việc mô hình dự đoán nhầm nhiều ca lành tính thành có nguy cơ (False Positive).

3. Nhận xét:

Logistic Regression là mô hình hiệu quả hơn cho mục tiêu dự báo sớm nguy cơ tim mạch nhờ chỉ số Recall và ROC-AUC cao, giúp tối thiểu hóa việc bỏ sót các bệnh nhân có nguy cơ thực sự.

3.3 Kết quả phân loại trên dữ liệu PCA 2D

3.3.1 Bảng kết quả

Trong kịch bản thứ hai, dữ liệu đặc trưng sau tiền xử lý được giảm chiều bằng PCA về **2 thành phần chính** (PCA 2D). Hai mô hình GNB và Logistic Regression được huấn luyện trên `X_pca_2d` và đánh giá tương tự như trên dữ liệu gốc. Các kết quả cho ba tỉ lệ chia được tóm tắt trong Bảng 3.2.

Mô hình	Train:Test	Accuracy	Precision	Recall	F1	ROC-AUC
Gaussian NB	80:20	0.8506	0.2636	0.3646	0.3060	0.7600
Gaussian NB	70:30	0.8500	0.2631	0.3666	0.3064	0.7624
Gaussian NB	60:40	0.8536	0.2700	0.3639	0.3100	0.7631
Logistic Regression	80:20	0.7567	0.2273	0.7056	0.3439	0.8114
Logistic Regression	70:30	0.7564	0.2269	0.7046	0.3432	0.8116
Logistic Regression	60:40	0.7552	0.2259	0.7548	0.3422	0.8109

Bảng 3.2: Kết quả phân loại trên dữ liệu PCA 2D với các tỉ lệ chia khác nhau

3.3.2 Nhận xét

1. So sánh hiệu năng giữa hai mô hình:

- **Về Accuracy (Độ chính xác tổng thể):** Mô hình **Gaussian NB** duy trì độ chính xác cao vượt trội (khoảng 0.85) so với **Logistic Regression** (khoảng 0.75). Tuy nhiên, cần lưu ý rằng độ chính xác cao trong bối cảnh dữ liệu y tế mất cân bằng thường không phản ánh đúng khả năng phát hiện bệnh.
- **Về Recall (Độ nhạy):** **Logistic Regression** tiếp tục là mô hình "nhạy" hơn hẳn với chỉ số **Recall** đạt từ 0.7046 đến 0.7548. Trong khi đó, **Gaussian NB** chỉ đạt khoảng 0.36, nghĩa là nó bỏ sót tới gần 2/3 số ca thực sự có nguy cơ mắc bệnh.
- **Về ROC-AUC:** **Logistic Regression** đạt chỉ số phân tách lớp tốt hơn (khoảng 0.81) so với **Gaussian NB** (khoảng 0.76).

2. Ảnh hưởng của việc giảm chiều dữ liệu (PCA 2D):

- **Đánh đổi thông tin:** Khi so sánh với kết quả trên tập dữ liệu gốc (Bảng 3.1), hiệu năng của Logistic Regression có sự sụt giảm nhẹ (Recall giảm từ ~ 0.77 xuống ~ 0.70 – 0.75 ; ROC-AUC giảm từ ~ 0.83 xuống ~ 0.81). Điều này cho thấy việc nén dữ liệu về chỉ còn 2 thành phần chính đã làm mất đi một phần thông tin đặc trưng có giá trị dự báo.
- **Sự thay đổi của Gaussian NB:** Khá thú vị là Accuracy của Gaussian Naive Bayes tăng lên (khoảng ~ 0.85) so với dữ liệu gốc (khoảng ~ 0.80), nhưng Recall lại giảm sâu (từ ~ 0.55 xuống ~ 0.36). Mô hình này có xu hướng dự đoán an toàn (thiên về lớp "không bệnh") nhiều hơn khi không gian đặc trưng bị thu hẹp.

3. Nhận xét:

Dù đã giảm chiều dữ liệu xuống không gian 2D, **Logistic Regression** vẫn chứng minh được ưu thế trong việc sàng lọc nguy cơ tim mạch nhờ chỉ số **Recall** và **ROC-AUC** ổn định. Việc sử dụng dữ liệu PCA 2D giúp giảm bớt độ phức tạp tính toán nhưng phải chấp nhận một mức sai số nhỏ so với việc sử dụng đầy đủ các đặc trưng ban đầu.

3.4 Kết quả phân loại trên dữ liệu LDA 1D

3.4.1 Bảng kết quả

Mô hình	Train:Test	Accuracy	Precision	Recall	F1	ROC-AUC
Gaussian NB	80:20	0.9041	0.4395	0.2212	0.2943	0.8246
Gaussian NB	70:30	0.9034	0.4323	0.2216	0.2930	0.8246
Gaussian NB	60:40	0.9030	0.4284	0.2217	0.2922	0.8247
Logistic Regression	80:20	0.7732	0.2412	0.7041	0.3593	0.8246
Logistic Regression	70:30	0.7722	0.2405	0.7051	0.3587	0.8246
Logistic Regression	60:40	0.7716	0.2405	0.7076	0.3590	0.8247

Bảng 3.3: Kết quả phân loại trên dữ liệu LDA 1D với các tỉ lệ chia khác nhau

3.4.2 Nhận xét

1. Sự đối lập giữa Accuracy và Recall:

- **Gaussian Naive Bayes (GNB):** Đạt Accuracy rất cao (khoảng ~ 0.90), nhưng Recall lại cực kỳ thấp (khoảng ~ 0.22). Điều này cho thấy mô hình bị ảnh hưởng bởi mất cân bằng dữ liệu, có xu hướng dự đoán phần lớn là “không bệnh”, dẫn đến bỏ sót gần 80% bệnh nhân thực sự mắc bệnh.
- **Logistic Regression (LR):** Mặc dù Accuracy thấp hơn (khoảng ~ 0.77), nhưng Recall duy trì tốt ở mức ~ 0.70 . Trong bài toán y khoa, mô hình này phù hợp hơn do ưu tiên giảm thiểu việc bỏ sót bệnh nhân.

2. Hiện tượng ROC–AUC đồng nhất:

- Cả hai mô hình đều có ROC–AUC xấp xỉ 0.8246.
- **Lý giải:** Do LDA nén dữ liệu về một chiều, tất cả điểm dữ liệu nằm trên cùng một trục. Cả GNB và LR đều là mô hình tuyến tính, nên việc sắp xếp thứ tự các điểm gần như tương đồng. Sự khác biệt về Precision và Recall chủ yếu đến từ việc lựa chọn ngưỡng phân loại (threshold).

3. Nhận xét:

Logistic Regression trên không gian LDA 1D là phương án cân bằng nhất. Dù chỉ sử dụng một chiều dữ liệu, mô hình vẫn đạt ROC–AUC cao tương đương khi dùng nhiều chiều, đồng thời giúp giảm chi phí tính toán và tăng tốc độ xử lý.

3.5 So sánh giữa các kiểu biểu diễn dữ liệu

3.5.1 So sánh hiệu năng tổng thể

Tổng hợp kết quả trên ba dạng dữ liệu (gốc, PCA 2D, LDA 1D) cho thấy:

Mô hình Logistic Regression (LR)

- **Tính ổn định cao:** LR duy trì chỉ số Recall ở mức rất tốt (0.70 – 0.77) trên tất cả các tập dữ liệu. Điều này cực kỳ quan trọng trong bài toán sàng lọc y tế vì nó giúp hạn chế tối đa việc bỏ sót bệnh nhân mắc bệnh tim mạch.
- **Khả năng phân biệt lớp:** Chỉ số ROC-AUC của LR luôn dẫn đầu (đạt mức cao nhất 0.83 trên dữ liệu gốc), chứng minh khả năng phân loại hiệu quả giữa người khỏe mạnh và người có bệnh.

Mô hình Gaussian Naive Bayes (GNB)

- **Sự đánh đổi về chỉ số:** GNB cho thấy một xu hướng ngược lại; khi chiều dữ liệu càng giảm (từ gốc sang LDA 1D), Accuracy tăng mạnh (từ 0.80 lên 0.90) nhưng Recall lại sụt giảm nghiêm trọng (từ 0.55 xuống 0.22).
- **Hạn chế:** Với Recall chỉ đạt khoảng 22% trên LDA 1D, mô hình GNB thực tế không hiệu quả trong việc chẩn đoán vì nó bỏ sót tới gần 80% người mắc bệnh, dù con số Accuracy trông rất "đẹp".

3.5.2 Đánh giá ảnh hưởng của các phương pháp giảm chiều

- **Dữ liệu gốc:** Cung cấp hiệu năng tốt nhất cho mô hình Logistic Regression về cả khả năng nhận diện (Recall) và phân tách lớp (AUC).
- **PCA 2D:** Làm giảm nhẹ hiệu năng của cả hai mô hình do việc nén thông tin không giám sát gây mất mát một phần đặc trưng rủi ro.
- **LDA 1D:** Là phương pháp giảm chiều ấn tượng nhất. Dù chỉ sử dụng duy nhất 1 đặc trưng, nó giúp cả hai mô hình đạt được ROC-AUC xấp xỉ 0.82 — rất sát với kết quả trên toàn bộ 17-18 đặc trưng ban đầu. Đây là minh chứng cho thấy LDA đã trích xuất được "trục rủi ro" cốt lõi của bệnh tim mạch.

3.5.3 Ảnh hưởng của tỉ lệ chia train/test

Dựa trên các bảng kết quả thực nghiệm (Bảng 3.1, 3.2 và 3.3), chúng ta có thể rút ra những nhận xét quan trọng về tác động của việc phân chia dữ liệu huấn luyện và kiểm tra:

- **Tính ổn định của mô hình:** Hiệu năng của cả mô hình Gaussian Naive Bayes và Logistic Regression cực kỳ ổn định qua cả ba kịch bản chia dữ liệu là 80:20, 70:30 và 60:40.
- **Sự biến động tối thiểu:** Các chỉ số đánh giá như Accuracy, Recall và ROC-AUC chỉ có sự thay đổi rất nhỏ ở hàng thập phân thứ 3 hoặc thứ 4 khi thay đổi tỉ lệ chia.
- **Vai trò của quy mô dữ liệu:** Với bộ dữ liệu khảo sát sức khỏe (BRFSS) gồm hơn 300.000 bản ghi sau khi làm sạch, kích thước mẫu này đủ lớn để mô hình học được các đặc trưng cốt lõi mà không phụ thuộc quá nhiều vào lượng dữ liệu huấn luyện cụ thể.
- **Độ tin cậy của kết quả:** Sự nhất quán này khẳng định rằng cấu trúc dữ liệu vẫn giữ được tính đồng nhất trên quy mô lớn, giúp các kết luận về ưu thế của mô hình Logistic Regression đạt được độ tin cậy cao về mặt thống kê.

3.6 Kết luận

Chương này đã trình bày và phân tích:

- Hiệu năng của hai mô hình Gaussian Naive Bayes và Hồi quy Logistic trên ba kiểu biểu diễn dữ liệu và ba tỉ lệ chia train/test khác nhau. Regression trên Dữ liệu gốc là lựa chọn tốt nhất về mặt chuyên môn y khoa nhờ chỉ số Recall (0.77) và AUC (0.83) cao nhất.
- Nếu cần một hệ thống xử lý cực nhanh và đơn giản, Logistic Regression trên LDA 1D là sự thay thế tuyệt vời khi vẫn giữ được khả năng phân loại (AUC 0.82) và độ nhạy (Recall 0.70) ổn định trên một không gian dữ liệu tối giản.

Những kết quả này là cơ sở để chương tiếp theo đưa ra kết luận tổng quát và đề xuất các hướng phát triển tiếp theo cho bài toán dự đoán mắc bệnh tim mạch.