

Đánh giá và so sánh các thuật toán phân loại trong việc nhận diện sớm bệnh tim mạch

Môn học: Học máy

Hoàng Danh Dũng (23000103)

Nguyễn Hữu Dũng (23000104)

Trường Đại học Khoa học Tự nhiên - ĐHQGHN

Giảng viên hướng dẫn: TS. Cao Văn Chung

Ngày 2 tháng 5 năm 2026

Nội dung báo cáo

- 1 Tổng quan về bài toán
- 2 Tiền xử lý dữ liệu
- 3 Giảm chiều và trực quan hóa
- 4 Mô hình và Kết quả thực nghiệm
- 5 Đánh giá và So sánh
- 6 Kết luận

1. Tổng quan về bài toán

- **Đặt vấn đề:** Bệnh tim mạch (CVDs) là nguyên nhân gây tử vong hàng đầu thế giới[cite: 1]. Việc chẩn đoán truyền thống tốn kém và thường phát hiện muộn
- **Mục tiêu đề tài:**
 - Xây dựng mô hình phân loại nhị phân dự báo sớm nguy cơ mắc bệnh
 - So sánh hiệu năng giữa **Logistic Regression** và **Gaussian Naïve Bayes**
 - Đánh giá tác động của kỹ thuật giảm chiều **PCA** và **LDA**
- **Câu hỏi:** Phương pháp giảm chiều nào hỗ trợ tốt hơn cho bài toán phân loại y tế?

2 Tiền xử lý dữ liệu

- **Đặc điểm bộ dữ liệu:**

- 319.795 bản ghi, 18 biến.
- Không có giá trị thiếu (Missing values).

- **Làm sạch dữ liệu:**


- Loại bỏ các bản ghi trùng lặp hoàn toàn để tránh hiện tượng *Bias* và *Overfitting*.
- Sử dụng `reset_index` để đồng bộ hóa chỉ số hàng.

- **Thông kê mô tả:** BMI trung bình (28.44) vượt ngưỡng bình thường, cho thấy rủi ro tim mạch cao trong mẫu

```
<class 'pandas.DataFrame'>
RangeIndex: 319795 entries, 0 to 319794
Data columns (total 18 columns):
#   Column                Non-Null Count  Dtype
---  -
0   HeartDisease          319795 non-null  str
1   BMI                   319795 non-null  float64
2   Smoking               319795 non-null  str
3   AlcoholDrinking       319795 non-null  str
4   Stroke                319795 non-null  str
5   PhysicalHealth         319795 non-null  float64
6   MentalHealth           319795 non-null  float64
7   DiffWalking           319795 non-null  str
8   Sex                   319795 non-null  str
9   AgeCategory            319795 non-null  str
10  Race                   319795 non-null  str
11  Diabetic                319795 non-null  str
12  PhysicalActivity        319795 non-null  str
13  GenHealth               319795 non-null  str
14  SleepTime              319795 non-null  float64
15  Asthma                  319795 non-null  str
16  KidneyDisease           319795 non-null  str
17  SkinCancer              319795 non-null  str
dtypes: float64(4), str(14)
memory usage: 43.9 MB
```

Kiểm tra cấu trúc dữ liệu qua `df.info()`

Trực quan hóa và Vấn đề mất cân bằng dữ liệu



Phân bố biến mục tiêu Heart Disease

- **Thực trạng dữ liệu:**

- Lớp **No** (Không bệnh): 274.456 mẫu.
- Lớp **Yes** (Có bệnh): 27.261 mẫu.

- **Thách thức:**

- Tỷ lệ chênh lệch xấp xỉ **10:1**.
- Mô hình dễ bị "học vẹt" lớp đa số để đạt Accuracy cao nhưng bỏ sót hoàn toàn lớp thiểu số.

Hệ quả

Chỉ số Accuracy không còn là thước đo tin cậy duy nhất; cần tập trung vào các chỉ số phản ánh khả năng nhận diện lớp thiểu số (Recall).

Các thước đo đánh giá

- **Ma trận nhầm lẫn (Confusion Matrix):** Là nền tảng để tính toán các chỉ số hiệu năng.

	Dự đoán: No	Dự đoán: Yes
Thực tế: No	TN (True Negative)	FP (False Positive)
Thực tế: Yes	FN (False Negative)	TP (True Positive)

- Trong y tế:
 - **FP:** Người khỏe bị dự đoán nhầm là có bệnh (Gây lo lắng, tốn chi phí xét nghiệm lại).
 - **FN:** Người bệnh bị bỏ sót (Hệ quả nghiêm trọng nhất vì mất cơ hội điều trị sớm).

Chi tiết các chỉ số đánh giá

Công thức tính toán

- **Accuracy** = $\frac{TP+TN}{TP+TN+FP+FN}$ (Độ chính xác tổng thể)
- **Recall** = $\frac{TP}{TP+FN}$ (Độ nhạy - Khả năng bắt được bệnh nhân)
- **Precision** = $\frac{TP}{TP+FP}$ (Độ chính xác trên các ca dự đoán dương tính)
- **F1-score** = $2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$ (Trung bình điều hòa).
- **ROC-AUC**: Diện tích dưới đường cong ROC, thể hiện khả năng phân biệt giữa hai nhóm đối tượng ở các ngưỡng quyết định khác nhau.
- Giá trị AUC càng gần 1.0 thể hiện khả năng phân tách của mô hình càng tốt.

- **Tại sao chọn Recall thay vì Accuracy?**

- Với tỉ lệ bệnh nhân thấp, một mô hình luôn dự đoán "No" sẽ đạt Accuracy 90% nhưng Recall bằng 0.
- Mục tiêu y tế là **giảm thiểu FN**, do đó mô hình có Recall cao (như Logistic Regression 0.77) được ưu tiên hơn.

- **Sự đánh đổi (Trade-off):**


- Tăng Recall thường làm giảm Precision (dự báo nhầm nhiều người khỏe hơn).
- Nghiên cứu chấp nhận Precision thấp (0.22 - 0.24) để đổi lấy khả năng sàng lọc bệnh nhân tối ưu.

Xử lý giá trị ngoại lệ (Outliers)


Kỹ thuật Capping (Winsorization)

Giới hạn các giá trị biến định lượng trong khoảng phân vị [1%, 99%]:

$$x_{new} = \max(P_1, \min(x, P_{99}))$$



Trước khi xử lý



Sau khi xử lý

- Giảm nhiễu cho các thuật toán nhạy cảm với khoảng cách (như Logistic Regression)
- Bảo toàn số lượng mẫu quan sát so với phương pháp loại bỏ (Removal)

Biến đổi đặc trưng (Feature Engineering)

• Bước 1: One-Hot Encoding

- Áp dụng cho các biến phân loại: *Sex, Race, GenHealth, Diabetic*
- Biến mỗi giá trị thành cột nhị phân (0/1), tránh áp đặt thứ bậc giả cho các biến không thứ tự

• Bước 2: Chuẩn hóa (StandardScaler)

- Đưa toàn bộ đặc trưng về cùng thang đo μ, σ
- Công thức: $x' = \frac{x - \mu}{\sigma}$
- **Quan trọng:** Chỉ *fit* trên tập Train để ngăn chặn *Data Leakage*

Phân chia dữ liệu (Train-Test Split)

Nghiên cứu khảo sát 3 kịch bản để đánh giá tính ổn định của mô hình:

Kịch bản	Tỉ lệ	Mẫu Huấn luyện	Mẫu Kiểm tra
Kịch bản 1	80 : 20	241.373	60.344
Kịch bản 2	70 : 30	211.201	90.516
Kịch bản 3	60 : 40	181.030	120.687

- **Chiến lược:** Sử dụng `stratify=y` để duy trì tỉ lệ mất cân bằng lớp (Có bệnh/Không bệnh) đồng nhất giữa hai tập dữ liệu.

3. Giảm chiều và trực quan hóa

PCA (Không giám sát):


- Tập trung nén thông tin dựa trên phương sai
- Cần tới **19 thành phần chính** để giữ 90% thông tin
- Trực quan 2D: Hai lớp dữ liệu chồng lẫn nhau

LDA (Có giám sát):

- Tìm trục chiều tối ưu hóa khả năng tách lớp
- Giảm về **1 chiều duy nhất** ($k = 1$) cho bài toán 2 lớp
- Trực quan: Thấy rõ sự dịch chuyển phân phối giữa hai lớp


Giảm chiều và trực quan hóa

- **Mục tiêu:** Giữ lại 90% phương sai của dữ liệu gốc.
- **Scree Plot:**
 - Phương sai bị phân tán trên rất nhiều chiều.
 - Thành phần chính đầu tiên (PC_1) chỉ chiếm khoảng **12.12%**.
 - Hệ thống cần tới **19 thành phần chính** để đạt ngưỡng 90% thông tin
- **Nhận xét:** Dữ liệu bệnh tim có tính đa chiều cao, không tập trung vào một vài biến đơn lẻ.



Mức độ đóng góp của các PCA


PCA: Phân tích thành phần chính



Trực quan hóa PCA trên các cặp thành phần chính

- **PC1 vs PC2:** Cho thấy độ phân tán rộng nhất nhưng hai nhãn dữ liệu (Bệnh/Không bệnh) **chồng lẫn hoàn toàn**, không tạo ra ranh giới.
- **Cặp PC tiếp theo (PC3-PC6):** Cấu trúc cụm có xu hướng tròn hơn, ít biến thiên đặc trưng theo hướng cụ thể, khiến việc phân loại khó khăn.
- **Kết luận:** PCA (không giám sát) chưa đủ để xây dựng ranh giới phân loại chính xác.

LDA: Phân tích phân biệt tuyến tính



Phân phối dữ liệu sau LDA (1D)

- **Trục LD1:** Tìm ra hướng chiều tối ưu để tách biệt hai nhóm
- **Vị trí đỉnh phân phối:**
 - Lớp 0 (Không bệnh): Tập trung quanh mức **-0.5**
 - Lớp 1 (Có bệnh): Dịch chuyển về phía dương, quanh mức **0.7**
- **Vùng chồng lấn (Overlap):** Vẫn tồn tại sự giao thoa từ -1.0 đến 3.0, phản ánh sự tương đồng chỉ số giữa một số người khỏe và người bệnh

So sánh PCA và LDA

Tiêu chí	PCA (Không giám sát)	LDA (Có giám sát)
Thông tin sử dụng	Chỉ sử dụng ma trận đặc trưng X .	Sử dụng cả đặc trưng X và nhãn lớp y
Mục tiêu toán học	Tối đa hóa phương sai (giữ thông tin).	Tối đa hóa khoảng cách giữa các lớp.
Hiệu quả phân loại	Thấp khi các lớp chồng lấn về phương sai.	Cao, giúp mô hình tìm ranh giới dễ dàng hơn.
Ứng dụng	Trực quan hóa cấu trúc tổng thể.	Tiền xử lý tối ưu cho bài toán phân loại.

4 Mô hình và Kết quả thực nghiệm

Hồi quy Logistic (LR):

- Mô hình phân biệt (*Discriminative*).
- Sử dụng hàm Sigmoid để ánh xạ đặc trưng sang xác suất $P(y = 1|x)$.
- Ưu điểm: Phù hợp cho bài toán phân loại nhị phân, dễ diễn giải trọng số đặc trưng.

Gaussian Naïve Bayes (GNB):

- Mô hình sinh (*Generative*).
- Giả định các đặc trưng độc lập có điều kiện và tuân theo phân phối chuẩn.
- Ưu điểm: Huấn luyện nhanh, hiệu quả trên dữ liệu lớn và nhiễu.

Chiến lược đánh giá

Ưu tiên **Recall** (hạn chế bỏ sót bệnh nhân) và **ROC-AUC** (khả năng phân tách lớp) do dữ liệu mất cân bằng.

Kết quả trên tập dữ liệu gốc

Mô hình	Train:Test	Accuracy	Precision	Recall	F1	ROC-AUC
Gaussian NB	80:20	0.8033	0.2415	0.5495	0.3355	0.7865
Gaussian NB	70:30	0.8042	0.2435	0.5538	0.3383	0.7882
Gaussian NB	60:40	0.8047	0.2445	0.5560	0.3396	0.7900
Logistic Regression	80:20	0.7429	0.2274	0.7698	0.3511	0.8324
Logistic Regression	70:30	0.7427	0.2272	0.7691	0.3508	0.8324
Logistic Regression	60:40	0.7428	0.2272	0.7694	0.3509	0.8321

Kết quả trên dữ liệu gốc

⇒ LR là lựa chọn tối ưu để tránh bỏ sót các ca bệnh tiềm ẩn

Nhận xét (Tỉ lệ 80:20):

- **Accuracy:** GNB (0.8033) cao hơn LR (0.7429) [.
- **Recall:** LR đạt **0.7698**, vượt trội hoàn toàn so với GNB (0.5495).
- **ROC-AUC:** LR (0.8324) ổn định hơn GNB (0.7865).

Kết quả trên dữ liệu PCA 2D

Mô hình	Train:Test	Accuracy	Precision	Recall	F1	ROC-AUC
Gaussian NB	80:20	0.8506	0.2636	0.3646	0.3060	0.7600
Gaussian NB	70:30	0.8500	0.2631	0.3666	0.3064	0.7624
Gaussian NB	60:40	0.8536	0.2700	0.3639	0.3100	0.7631
Logistic Regression	80:20	0.7567	0.2273	0.7056	0.3439	0.8114
Logistic Regression	70:30	0.7564	0.2269	0.7046	0.3432	0.8116
Logistic Regression	60:40	0.7552	0.2259	0.7548	0.3422	0.8109

Kết quả trên dữ liệu PCA 2D

⇒ Việc giảm chiều xuống 2D giúp giảm tính toán nhưng gây sai số nhỏ so với dữ liệu gốc.

Phân tích ảnh hưởng:

- **Đánh đổi:** Hiệu năng LR sụt giảm nhẹ (Recall từ 0.77 $\rightarrow$ 0.70) do nén thông tin không giám sát làm mất đặc trưng rủi ro
- **Biến động GNB:** Accuracy tăng lên $\approx$ 0.85 nhưng Recall giảm sâu xuống $\approx$ 0.36

Kết quả trên dữ liệu LDA 1D

Mô hình	Train:Test	Accuracy	Precision	Recall	F1	ROC-AUC
Gaussian NB	80:20	0.9041	0.4395	0.2212	0.2943	0.8246
Gaussian NB	70:30	0.9034	0.4323	0.2216	0.2930	0.8246
Gaussian NB	60:40	0.9030	0.4284	0.2217	0.2922	0.8247
Logistic Regression	80:20	0.7732	0.2412	0.7041	0.3593	0.8246
Logistic Regression	70:30	0.7722	0.2405	0.7051	0.3587	0.8246
Logistic Regression	60:40	0.7716	0.2405	0.7076	0.3590	0.8247

Kết quả trên dữ liệu LDA 1D

⇒ LR trên LDA 1D là phương án cân bằng nhất giữa hiệu năng và chi phí

Điểm đặc biệt:

- **AUC đồng nhất:** Cả hai mô hình đều đạt **0.8246** do cùng phân loại trên một trục chiều duy nhất.
- **Sự đối lập:** GNB đạt Accuracy cao nhất (0.90) nhưng Recall cực thấp (0.22) → Thiên về lớp đa số.

5 Đánh giá và So sánh

- **Thực nghiệm:** Khảo sát trên 3 tỉ lệ: 80 : 20, 70 : 30, và 60 : 40.
- **Kết quả:** Các chỉ số Accuracy, Recall, AUC gần như **bất biến** (biến động hàng thập phân thứ 4).
- **Kết luận:**
 - Bộ dữ liệu quy mô lớn (> 300.000 bản ghi) giúp mô hình học được các đặc trưng bền vững.
 - Cấu trúc dữ liệu sau LDA và PCA giữ được tính nhất quán rất cao, không phụ thuộc vào cách lấy mẫu kiểm tra.

- **Độ ổn định:** Hiệu năng mô hình gần như không thay đổi khi thay đổi tỉ lệ chia train/test nhờ quy mô dữ liệu lớn.
- **Ảnh hưởng giảm chiều:**
 - Dữ liệu gốc cho AUC cao nhất (≈ 0.83)
 - LDA 1D cho AUC (≈ 0.82), tiệm cận dữ liệu gốc dù chỉ dùng 1 chiều dữ liệu
- **Đánh đổi:** PCA 2D làm sụt giảm nhẹ hiệu năng do nén thông tin không quan tâm đến nhãn lớp.

Kết luận tổng quát

- ❶ **Về Tiền xử lý:** Kỹ thuật Capping (Winsorization) và StandardScaler là nền tảng giúp mô hình hội tụ ổn định trên dữ liệu nhiễu.
- ❷ **Về Mô hình:** Logistic Regression vượt trội Gaussian NB trong bài toán y tế nhờ duy trì độ nhạy (Recall) cao, đảm bảo mục tiêu sàng lọc.
- ❸ **Về Kỹ thuật giảm chiều:** LDA chứng minh ưu thế tuyệt đối trong việc trích xuất "trục rủi ro" tim mạch, giúp tinh gọn hệ thống mà không hy sinh quá nhiều hiệu năng.
- ❹ **Tính ổn định:** Kết quả thực nghiệm cho thấy sự nhất quán qua các tỉ lệ chia dữ liệu khác nhau (80/20, 70/30, 60/40).

- **Ứng dụng thực tiễn:** Sử dụng mô hình Logistic Regression kết hợp LDA 1D để xây dựng các ứng dụng di động theo dõi sức khỏe nhanh, nhẹ và hiệu quả.
- **Hướng phát triển tương lai:**
 - Thử nghiệm các kỹ thuật cân bằng dữ liệu như **SMOTE** để cải thiện thêm chỉ số Precision và F1-score.
 - Mở rộng so sánh với các thuật toán phi tuyến tính mạnh hơn như **Random Forest** hoặc **XGBoost**.
 - Tối ưu hóa ngưỡng phân loại (*Threshold Tuning*) dựa trên chi phí thực tế của các ca FN trong bệnh viện.

TRÂN TRỌNG CẢM ƠN!

Q&A