



TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Đề tài : Đánh giá và so sánh các thuật toán phân loại trong việc nhận diện sớm bệnh tim mạch

Môn học:Học máy

Giảng viên hướng dẫn: TS. Cao Văn Chung

Nhóm sinh viên thực hiện:

Họ và tên	MSSV	Lớp
Hoàng Danh Dũng	23000103	K68A2
Nguyễn Hữu Dũng	23000104	K68A2

Mục lục

0.1	Giới thiệu tổng quan	4
0.1.1	Đặt vấn đề	4
0.1.2	Mục tiêu của đề tài	4
1	Cơ sở lý thuyết	6
1.1	Tổng quan về quản lý nguy cơ và dự báo tim mạch	6
1.1.1	Khái niệm về nguy cơ tim mạch	6
1.1.2	Dự đoán nguy cơ tim mạch và bài toán phân loại nhị phân	6
1.1.3	Hạn chế của phương pháp truyền thống và nhu cầu ứng dụng học máy	7
1.2	Tổng quan về học máy cho bài toán phân loại	7
1.2.1	Các khái niệm cơ bản	7
1.2.2	Quy trình xây dựng mô hình học máy	8
1.2.3	Bài toán phân loại nhị phân trong dự đoán tim mạch	8
1.3	Các mô hình phân loại sử dụng trong đề tài	8
1.3.1	Hồi quy Logistic (Logistic Regression)	8
1.3.2	Mô hình K-Nearest Neighbors	10
1.3.3	Mô hình Linear Soft-Margin SVM	10
1.4	Kỹ thuật giảm chiều PCA và LDA	11
1.4.1	Lý do cần giảm chiều dữ liệu	11
1.4.2	Phân tích thành phần chính (Principal Component Analysis - PCA)	12
1.4.3	Phân tích biệt thức tuyến tính (Linear Discriminant Analysis - LDA) cho hai lớp	12
1.4.4	So sánh PCA và LDA trong bối cảnh dự đoán tim mạch	13
1.5	Phân cụm dữ liệu với DBSCAN	13
1.5.1	Học không giám sát và ý nghĩa của phân cụm	13
1.5.2	Thuật toán DBSCAN	14
1.5.3	Lựa chọn số cụm và đánh giá chất lượng cụm	15
1.6	Các thước đo đánh giá mô hình phân loại	15
1.6.1	Ma trận nhầm lẫn (Confusion Matrix)	15
1.6.2	Accuracy, Precision, Recall, F1-score	16
1.6.3	Đường cong ROC và chỉ số AUC	16
1.6.4	Lựa chọn ngưỡng phân loại	16
1.7	Tóm tắt chương	17
2	Thực nghiệm trên bộ dữ liệu	18
2.1	Dữ liệu nghiên cứu	18
2.1.1	Giới thiệu dữ liệu	18
2.1.2	Mô tả các đặc trưng	18
2.1.3	Thống kê dữ liệu sơ bộ	19

2.1.4	Loại bỏ dữ liệu trùng lặp	20
2.1.5	Trực quan dữ liệu ban đầu	21
2.1.6	Xử lý giá trị ngoại lệ (Outliers)	23
2.1.7	Phân chia dữ liệu (Train–Test Split)	26
2.1.8	Biến đổi đặc trưng (Feature engineering)	26
2.2	Phương pháp thí nghiệm giảm chiều	27
2.2.1	Phương pháp 1: PCA (Phân tích thành phần chính)	27
2.2.2	Phương pháp 2: LDA (Phân tích phân biệt tuyến tính)	29
2.2.3	So sánh kết quả giảm chiều giữa PCA và LDA	32
2.2.4	Phân cụm dữ liệu bằng DBSCAN	33
2.3	Phương pháp thí nghiệm phân loại	37
2.3.1	Lựa chọn mô hình	37
2.3.2	Kịch bản thí nghiệm	37
2.3.3	Phương pháp đánh giá mô hình	39
3	So sánh và đánh giá kết quả thực nghiệm	40
3.1	Tổng quan các thí nghiệm	40
3.2	Kết quả phân loại trên dữ liệu gốc đã tiền xử lý	41
3.2.1	Bảng kết quả	41
3.2.2	Nhận xét	41
3.3	Kết quả phân loại trên dữ liệu sau PCA	41
3.3.1	Bảng kết quả	41
3.3.2	Nhận xét	42
3.4	Kết quả phân loại trên dữ liệu sau LDA	42
3.4.1	Bảng kết quả	42
3.4.2	Nhận xét	42
3.5	So sánh tổng hợp giữa các mô hình	43
3.5.1	Bảng các mô hình có ROC–AUC cao nhất	43
3.5.2	Bảng đánh giá overfit	43
3.5.3	Ma trận nhầm lẫn	43
3.5.4	Nhận xét tổng hợp	44
3.6	Hồi quy trên điểm số dự đoán	44
3.6.1	Mục tiêu	44
3.6.2	Bảng kết quả hồi quy	45
3.6.3	Trực quan hóa hồi quy score	45
3.6.4	Nhận xét	45
3.7	Kết luận chương	46

Danh sách hình vẽ

2.1	Kết quả lệnh <code>df.info()</code>	20
2.2	Kết quả lệnh <code>df.describe()</code> . sau khi xóa lặp	21
2.3	Phân bố biến mục tiêu Heart Disease	22
2.4	Histogram một số biến số quan trọng trong bộ dữ liệu.	23
2.5	Biểu đồ tần suất một số biến phân loại trong bộ dữ liệu.	23
2.6	Số lượng và tỉ lệ các giá trị Outliers.	24
2.7	Boxplot BMI, PhysicalHealth , MentalHealth và SleepTime trước khi xử lý Outliers.	25
2.8	Boxplot BMI, PhysicalHealth , MentalHealth và SleepTime sau khi xử lý Outliers.	25
2.9	Hình mô tả một số thuộc tính dữ liệu trên tập train 80/20 sau chuẩn hóa.	27
2.10	Tỉ lệ phương sai được giải thích bởi các thành phần chính PCA	28
2.11	Trực quan hóa dữ liệu trên các cặp thành phần chính PCA	29
2.12	Trực quan hóa phân phối dữ liệu sau LDA với $n_components = 1$	30
2.13	Bảng so sánh	32
2.14	Biểu đồ k-distance hỗ trợ lựa chọn tham số ϵ cho DBSCAN	34
2.15	Trực quan hóa các cụm DBSCAN trên không gian PCA hai chiều	36
2.16	Tỉ lệ nhãn HeartDisease trong từng cụm DBSCAN	37
3.1	Ma trận nhầm lẫn của KNN, Logistic Regression và Soft Margin SVM trên dữ liệu RAW với tỉ lệ 80/20	43
3.2	So sánh score thực tế và score dự đoán của các mô hình hồi quy	45

0.1 Giới thiệu tổng quan

0.1.1 Đặt vấn đề

Trong các bệnh lý không lây nhiễm, bệnh tim mạch (Cardiovascular Diseases - CVDs) hiện là nguyên nhân gây tử vong hàng đầu trên toàn cầu. Theo Tổ chức Y tế Thế giới (WHO), các biến cố như nhồi máu cơ tim hay đột quỵ thường xảy ra bất ngờ, nhưng thực tế chúng là kết quả của một quá trình diễn tiến âm thầm từ các yếu tố nguy cơ tích lũy theo thời gian.

Việc chẩn đoán bệnh tim mạch truyền thống thường dựa vào các xét nghiệm lâm sàng chuyên sâu như điện tâm đồ (ECG), xét nghiệm máu, hoặc siêu âm tim. Tuy nhiên:

- **Chi phí cao:** Không phải cá nhân nào cũng có điều kiện thực hiện tầm soát định kỳ tại các cơ sở y tế lớn.
- **Tính kịp thời:** Bệnh thường diễn biến âm thầm, nhiều bệnh nhân chỉ phát hiện khi đã ở giai đoạn muộn hoặc xảy ra biến cố cấp tính (đột quỵ, nhồi máu cơ tim).

Sự bùng nổ của Trí tuệ nhân tạo, đặc biệt là Học máy (Machine Learning), cho phép chúng ta xây dựng các công cụ hỗ trợ ra quyết định với chi phí thấp và tốc độ xử lý nhanh. Việc xây dựng một mô hình dự đoán từ các dữ liệu khảo sát không chỉ giúp cá nhân hóa việc chăm sóc sức khỏe mà còn giảm thiểu đáng kể gánh nặng cho hệ thống y tế công cộng thông qua việc can thiệp sớm.

0.1.2 Mục tiêu của đề tài

Mục tiêu tổng quát

Xây dựng thành công mô hình Học máy phân loại nhị phân có khả năng dự đoán sớm nguy cơ mắc bệnh tim mạch của cá nhân dựa trên các chỉ số sức khỏe và thói quen sinh hoạt, đạt độ chính xác và tin cậy cao.

Mục tiêu cụ thể

Để đạt được mục tiêu trên, đề tài tập trung vào các mục tiêu cụ thể sau:

- **Phân tích và Tiền xử lý dữ liệu:** làm sạch dữ liệu, xử lý giá trị thiếu, mã hóa biến phân loại, chuẩn hóa biến số; phân tích mô tả và nhận diện các vấn đề như mất cân bằng lớp, ngoại lệ, nhiễu (Mục ??).
- **So sánh các phương pháp giảm chiều:** áp dụng PCA và LDA để rút gọn số chiều dữ liệu, đánh giá khả năng giữ lại thông tin và hỗ trợ cho bài toán phân loại (Mục ??).
- **Xây dựng và đánh giá mô hình phân loại:** xây dựng, huấn luyện và so sánh mô hình Logistic Regression, K-NN, SVM dựa trên các thước đo như Accuracy, Precision, Recall, F1-score, AUC (Mục ??).

Câu hỏi nghiên cứu

Từ các mục tiêu trên, đề tài hướng tới trả lời một số câu hỏi nghiên cứu chính:

- Quy trình tiền xử lý nào phù hợp với bộ dữ liệu *Heart Disease* để chuẩn bị cho các mô hình học máy?

- PCA và LDA khác nhau như thế nào trong việc giảm chiều dữ liệu, và phương pháp nào hỗ trợ tốt hơn cho bài toán phân loại?
- Trong hai mô hình Logistic Regression, K-NN, mô hình nào cho hiệu năng tốt hơn?

CHƯƠNG 1

Cơ sở lý thuyết

1.1 Tổng quan về quản lý nguy cơ và dự báo tim mạch

1.1.1 Khái niệm về nguy cơ tim mạch

Nguy cơ tim mạch là khả năng một cá nhân gặp phải các biến cố sức khỏe nghiêm trọng (như nhồi máu cơ tim, đột quỵ) do các yếu tố rủi ro không được kiểm soát. Khi các chỉ số sức khỏe và thói quen sinh hoạt không lành mạnh kéo dài, các yếu tố này sẽ dẫn đến các bệnh lý tim mạch mãn tính, được xem là một dạng "rủi ro sức khỏe" cần được quản lý chặt chẽ.

Trong bối cảnh y tế dự phòng, việc phát hiện sớm thông qua sàng lọc định kỳ giúp phân loại bệnh nhân vào các nhóm nguy cơ khác nhau, từ đó áp dụng các biện pháp can thiệp và điều trị dự phòng phù hợp. Việc đo lường, dự báo và kiểm soát nguy cơ tim mạch vì thế là một trong những nhiệm vụ trọng tâm của quản lý sức khỏe cộng đồng.

1.1.2 Dự đoán nguy cơ tim mạch và bài toán phân loại nhị phân

Để hỗ trợ quyết định sàng lọc và chẩn đoán sớm, các hệ thống hỗ trợ quyết định y khoa thường sử dụng hệ thống *dự đoán nguy cơ mắc bệnh*. Về bản chất, dự đoán nguy cơ tim mạch là quá trình sử dụng thông tin về cá nhân (nhân khẩu học, chỉ số sinh học, thói quen sinh hoạt,...) để ước lượng xác suất cá nhân đó sẽ mắc bệnh hoặc gặp biến cố trong tương lai.

Trong ngôn ngữ học máy, đây là một bài toán *phân loại nhị phân*:

$$y \in \{0, 1\},$$

trong đó $y = 1$ biểu thị cá nhân có nguy cơ mắc bệnh, $y = 0$ là cá nhân không có nguy cơ mắc bệnh. Từ dữ liệu lịch sử đã gán nhãn, mô hình học máy học được một hàm ánh xạ từ vector đặc trưng đầu vào (các thông tin khảo sát cơ bản) sang xác suất hoặc nhãn dự đoán. Dựa trên một ngưỡng quyết định, các chuyên gia y tế có thể đưa ra khuyến nghị điều chỉnh lối sống, chỉ định tầm soát chuyên sâu hoặc áp dụng các biện pháp can thiệp y tế kịp thời.

1.1.3 Hạn chế của phương pháp truyền thống và nhu cầu ứng dụng học máy

Trước đây, nhiều hệ thống đánh giá nguy cơ tim mạch được xây dựng dựa trên các quy tắc do chuyên gia y tế đặt ra (rule-based) hoặc các thang điểm lâm sàng đơn giản như bảng điểm Framingham hay SCORE. Các phương pháp này có ưu điểm là dễ hiểu, dễ triển khai trong điều kiện thăm khám thông thường, nhưng tồn tại nhiều hạn chế:

- **Phụ thuộc mạnh vào kinh nghiệm chủ quan của chuyên gia:** Các quy tắc chẩn đoán thường dựa trên quan sát lâm sàng truyền thống, khó cập nhật kịp thời khi các yếu tố về môi trường sống, thói quen sinh hoạt và đặc điểm nhân khẩu học của quần thể thay đổi.
- **Khả năng mô tả các mối quan hệ phi tuyến, tương tác phức tạp giữa các biến còn hạn chế:** Sự kết hợp giữa các yếu tố như chỉ số BMI, huyết áp và thói quen hút thuốc thường có tính tương tác đa chiều, dễ dẫn đến mô hình đơn giản hóa quá mức khi chỉ sử dụng các phép cộng điểm tuyến tính.
- **Việc điều chỉnh, mở rộng hệ thống quy tắc thường tốn thời gian:** Quá trình cập nhật các hướng dẫn điều trị (guidelines) mới đòi hỏi nhiều năm nghiên cứu thử nghiệm, dẫn đến sự chậm trễ trong việc phản ứng với các xu hướng bệnh lý mới.

Trong bối cảnh dữ liệu sức khỏe cộng đồng ngày càng lớn và đa dạng, các phương pháp học máy cho phép khai thác tốt hơn thông tin trong dữ liệu, tự động cập nhật mô hình khi có dữ liệu mới và cải thiện độ chính xác dự báo. Điều này tạo động lực mạnh mẽ cho việc ứng dụng học máy vào sàng lọc sớm và quản lý nguy cơ tim mạch trong thực tế.

1.2 Tổng quan về học máy cho bài toán phân loại

1.2.1 Các khái niệm cơ bản

Học máy (Machine Learning) là lĩnh vực nghiên cứu các thuật toán cho phép mô hình học từ dữ liệu để đưa ra dự đoán hoặc quyết định mà không cần lập trình cứng từng quy tắc. Trong bài toán phân loại nguy cơ tim mạch, một số khái niệm cơ bản gồm:

- **Đặc trưng (feature):** các biến đầu vào mô tả đối tượng, ví dụ: thông tin nhân khẩu học (giới tính, độ tuổi), thói quen sinh hoạt (hút thuốc, vận động) và các chỉ số sức khỏe (BMI, huyết áp).
- **Nhãn (label):** biến đầu ra cần dự đoán, trong đề tài là trạng thái cá nhân có nguy cơ mắc bệnh tim mạch hay không.
- **Tập huấn luyện (training set):** phần dữ liệu dùng để mô hình học tham số.
- **Tập kiểm thử (test set):** phần dữ liệu tách riêng để đánh giá khả năng tổng quát hóa của mô hình.

Hai hiện tượng quan trọng cần lưu ý là:

- **Overfitting:** mô hình học quá sát dữ liệu huấn luyện (kể cả nhiễu), dẫn đến dự đoán tốt trên tập huấn luyện nhưng kém trên dữ liệu mới.
- **Underfitting:** mô hình quá đơn giản, không nắm bắt được quy luật trong dữ liệu, nên dự đoán kém cả trên tập huấn luyện lẫn kiểm thử.

1.2.2 Quy trình xây dựng mô hình học máy

Quy trình xây dựng một mô hình học máy cho bài toán phân loại thường bao gồm các bước chính:

- Thu thập và hiểu dữ liệu
- Tiền xử lý dữ liệu: làm sạch, mã hoá biến phân loại, chuẩn hoá các biến số, xử lý mất cân bằng lớp (nếu cần)
- Lựa chọn và trích chọn đặc trưng: chọn các đặc trưng quan trọng, có thể kết hợp với các kỹ thuật giảm chiều như PCA, LDA.
- Huấn luyện mô hình: sử dụng tập huấn luyện để ước lượng tham số của các mô hình được lựa chọn (Logistic Regression, K-NN, ...)
- Đánh giá và tinh chỉnh: đánh giá mô hình trên tập kiểm thử bằng các thước đo phù hợp (Accuracy, Precision, Recall, F1, AUC), sau đó điều chỉnh siêu tham số nếu cần.

1.2.3 Bài toán phân loại nhị phân trong dự đoán tim mạch

Trong đề tài này, bài toán dự đoán nguy cơ tim mạch được mô hình hóa dưới dạng bài toán phân loại nhị phân. Mỗi cá nhân được biểu diễn bởi một vector đặc trưng:

$$\mathbf{x} = (x_1, x_2, \dots, x_d),$$

trong đó các thành phần có thể là thông tin nhân khẩu học, chỉ số sức khỏe (BMI), thói quen sinh hoạt,... Biến mục tiêu y nhận một trong hai giá trị: Biến mục tiêu y nhận một trong hai giá trị:

$$y = \begin{cases} 1, & \text{nếu cá nhân có nguy cơ mắc bệnh tim mạch (positive);} \\ 0, & \text{nếu cá nhân không có nguy cơ mắc bệnh tim mạch (negative).} \end{cases}$$

Mục tiêu của mô hình học máy là học được một hàm ánh xạ:

$$f : \mathbf{x} \mapsto \hat{y} \quad \text{hoặc} \quad f : \mathbf{x} \mapsto P(y = 1 \mid \mathbf{x}),$$

giúp ước lượng xác suất mắc bệnh của một cá nhân mới, từ đó hỗ trợ đội ngũ y tế trong việc ra quyết định sàng lọc, điều chỉnh tư vấn lối sống hoặc đề xuất các chính sách quản lý sức khỏe và can thiệp kịp thời.

1.3 Các mô hình phân loại sử dụng trong đề tài

1.3.1 Hồi quy Logistic (Logistic Regression)

Hồi quy Logistic là một mô hình phân loại nhị phân, trong đó nhận đầu ra chỉ nhận hai giá trị $y \in \{0, 1\}$. Mặc dù mang tên “hồi quy”, mô hình này được sử dụng chủ yếu cho bài toán phân lớp. Đây là một mô hình *phân biệt* (discriminative), vì nó mô hình hoá trực tiếp xác suất có điều kiện $P(y \mid \mathbf{x}; \boldsymbol{\theta})$ thay vì mô hình hoá phân bố của dữ liệu đầu vào.

Mô hình và hàm sigmoid

Với mỗi mẫu dữ liệu $\mathbf{x} \in \mathbb{R}^d$, mô hình Logistic Regression giả sử:

$$h_{\boldsymbol{\theta}}(\mathbf{x}) = g(\boldsymbol{\theta}^T \mathbf{x}) = \frac{1}{1 + \exp(-\boldsymbol{\theta}^T \mathbf{x})},$$

trong đó $g(s)$ là *hàm sigmoid* (hay hàm logistic). Hàm này thỏa các tính chất quan trọng: $g(s) \rightarrow 1$ khi $s \rightarrow +\infty$, $g(s) \rightarrow 0$ khi $s \rightarrow -\infty$ và $g(s) \in (0, 1)$ với mọi s . Nhờ đó $h_{\boldsymbol{\theta}}(\mathbf{x})$ có thể được diễn giải như xác suất:

$$P(y = 1 \mid \mathbf{x}; \boldsymbol{\theta}) = h_{\boldsymbol{\theta}}(\mathbf{x}), \quad P(y = 0 \mid \mathbf{x}; \boldsymbol{\theta}) = 1 - h_{\boldsymbol{\theta}}(\mathbf{x}).$$

Xác suất, hàm mất mát và luật quyết định

Ta có thể viết gọn xác suất của nhãn $y \in \{0, 1\}$ dưới dạng:

$$P(y \mid \mathbf{x}; \boldsymbol{\theta}) = (h_{\boldsymbol{\theta}}(\mathbf{x}))^y (1 - h_{\boldsymbol{\theta}}(\mathbf{x}))^{1-y}.$$

Với tập huấn luyện $\{(\mathbf{x}_n, y_n)\}_{n=1}^N$, ta cực đại hoá hàm hợp lý (likelihood) hoặc tương đương là cực đại hoá log-hợp lý:

$$\ell(\boldsymbol{\theta}) = \sum_{n=1}^N [y_n \log h_{\boldsymbol{\theta}}(\mathbf{x}_n) + (1 - y_n) \log(1 - h_{\boldsymbol{\theta}}(\mathbf{x}_n))].$$

Trong thực tế, ta thường *cực tiểu hoá* hàm mất mát âm log-hợp lý (cross-entropy):

$$J(\boldsymbol{\theta}) = -\ell(\boldsymbol{\theta}) = -\sum_{n=1}^N [y_n \log h_{\boldsymbol{\theta}}(\mathbf{x}_n) + (1 - y_n) \log(1 - h_{\boldsymbol{\theta}}(\mathbf{x}_n))].$$

Khi đã ước lượng được $\hat{\boldsymbol{\theta}}$, luật phân loại được sử dụng là:

$$\hat{y} = \begin{cases} 1, & \text{nếu } h_{\hat{\boldsymbol{\theta}}}(\mathbf{x}) \geq 0.5 \ (\Leftrightarrow \hat{\boldsymbol{\theta}}^T \mathbf{x} \geq 0), \\ 0, & \text{ngược lại.} \end{cases}$$

Tối ưu hoá và Regularization

Bài toán tối ưu hoá $J(\boldsymbol{\theta})$ thường được giải bằng các phương pháp lặp, như *Gradient Descent* hoặc *Stochastic Gradient Descent*. Với Gradient Descent toàn phần, ta cập nhật:

$$\boldsymbol{\theta} := \boldsymbol{\theta} - \alpha \nabla J(\boldsymbol{\theta}),$$

trong đó α là tốc độ học. Gradient của hàm mất mát có dạng:

$$\nabla J(\boldsymbol{\theta}) = \sum_{n=1}^N (h_{\boldsymbol{\theta}}(\mathbf{x}_n) - y_n) \mathbf{x}_n.$$

Để tránh quá khớp (overfitting), người ta thường bổ sung *regularization* vào hàm mất mát:

$$J_{\text{reg}}(\boldsymbol{\theta}) = J(\boldsymbol{\theta}) + \lambda \|\boldsymbol{\theta}\|_2^2,$$

với $\lambda \geq 0$ là hệ số điều chuẩn (L2-regularization), giúp khống chế độ lớn của các trọng số, giảm nhạy cảm với nhiễu và cải thiện khả năng tổng quát hoá.

1.3.2 Mô hình K-Nearest Neighbors

K-Nearest Neighbors (KNN) là một mô hình phân loại *phi tham số*, trong đó nhãn của một mẫu mới được xác định dựa trên các mẫu huấn luyện gần nó nhất trong không gian đặc trưng.

Với biến mục tiêu $y \in \{0, 1\}$ và vector đặc trưng

$$\mathbf{x} = (x_1, \dots, x_d),$$

khoảng cách giữa hai mẫu $\mathbf{x}$ và $\mathbf{x}^{(i)}$ thường được tính bằng khoảng cách Euclid:

$$d(\mathbf{x}, \mathbf{x}^{(i)}) = \sqrt{\sum_{j=1}^d (x_j - x_j^{(i)})^2}.$$

Với một điểm dữ liệu mới $\mathbf{x}$, thuật toán tìm tập

$$\mathcal{N}_k(\mathbf{x})$$

gồm k điểm huấn luyện gần $\mathbf{x}$ nhất.

Trong bài toán phân loại, nhãn dự đoán được xác định theo nguyên tắc bỏ phiếu đa số:

$$\hat{y} = \arg \max_{c \in \{0,1\}} \sum_{\mathbf{x}^{(i)} \in \mathcal{N}_k(\mathbf{x})} \mathbb{I}(y^{(i)} = c),$$

trong đó $\mathbb{I}(\cdot)$ là hàm chỉ báo, nhận giá trị 1 nếu điều kiện đúng và 0 nếu sai.

Xác suất một mẫu thuộc về lớp c có thể được ước lượng bởi:

$$P(y = c | \mathbf{x}) = \frac{1}{k} \sum_{\mathbf{x}^{(i)} \in \mathcal{N}_k(\mathbf{x})} \mathbb{I}(y^{(i)} = c).$$

Sau đó, mô hình chọn lớp có xác suất ước lượng lớn nhất:

$$\hat{y} = \arg \max_{c \in \{0,1\}} P(y = c | \mathbf{x}).$$

Tham số k có ảnh hưởng quan trọng đến chất lượng mô hình. Nếu k quá nhỏ, mô hình dễ nhạy cảm với nhiễu; nếu k quá lớn, mô hình có thể làm mất thông tin cục bộ và giảm khả năng phân biệt giữa các lớp.

1.3.3 Mô hình Linear Soft-Margin SVM

Linear Soft-Margin Support Vector Machine (SVM) là mô hình phân loại tuyến tính nhằm tìm ra siêu phẳng phân tách hai lớp dữ liệu với khoảng cách lề lớn nhất, đồng thời cho phép một số điểm dữ liệu bị phân loại sai hoặc nằm trong vùng lề.

Với biến mục tiêu

$$y_i \in \{-1, 1\}$$

và vector đặc trưng

$$\mathbf{x}_i = (x_{i1}, \dots, x_{id}),$$

siêu phẳng phân tách được biểu diễn bởi:

$$\mathbf{w}^T \mathbf{x} + b = 0,$$

trong đó $\mathbf{w}$ là vector trọng số và b là hệ số chệch.

Hàm quyết định của mô hình có dạng:

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b.$$

Nhân dự đoán được xác định bởi:

$$\hat{y} = \text{sign}(f(\mathbf{x})) = \text{sign}(\mathbf{w}^T \mathbf{x} + b).$$

Do dữ liệu thực tế thường không thể phân tách tuyến tính hoàn toàn, Linear Soft-Margin SVM đưa vào các biến trượt

$$\xi_i \geq 0,$$

nhằm cho phép một số điểm dữ liệu vi phạm điều kiện phân tách. Khi đó, ràng buộc của mô hình được viết:

$$y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, n.$$

Bài toán tối ưu của Linear Soft-Margin SVM là:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i,$$

với các ràng buộc:

$$y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, n.$$

Trong đó, tham số $C > 0$ điều chỉnh sự đánh đổi giữa hai mục tiêu: tối đa hóa khoảng cách lề và giảm số điểm vi phạm hoặc bị phân loại sai. Nếu C lớn, mô hình ưu tiên giảm lỗi phân loại nhưng có thể làm lề hẹp hơn. Ngược lại, nếu C nhỏ, mô hình chấp nhận nhiều sai số hơn để đạt được lề rộng hơn. Các điểm dữ liệu nằm trên biên lề hoặc vi phạm lề được gọi là *support vectors*. Đây là những điểm có vai trò quyết định vị trí của siêu phẳng phân tách.

Trong triển khai thực nghiệm, nhãn dữ liệu có thể được mã hóa dưới dạng 0/1, ví dụ 0 tương ứng với lớp *No* và 1 tương ứng với lớp *Yes*. Tuy nhiên, trong công thức lý thuyết chuẩn của SVM, nhãn thường được biểu diễn dưới dạng -1 và 1 để phù hợp với hàm dấu $\text{sign}(\cdot)$.

1.4 Kỹ thuật giảm chiều PCA và LDA

1.4.1 Lý do cần giảm chiều dữ liệu

Trong nhiều bài toán thực tế, mỗi đối tượng được mô tả bởi một vector đặc trưng có số chiều rất lớn, trong khi số lượng mẫu cũng có thể rất lớn. Làm việc trực tiếp với dữ liệu có số chiều cao gây ra nhiều vấn đề:

- Chi phí tính toán và lưu trữ tăng mạnh khi số chiều tăng.
- “Lời nguyền chiều” (*curse of dimensionality*): dữ liệu trở nên “thừa”, mô hình dễ bị overfitting nếu không có đủ mẫu.
- Nhiều đặc trưng có thể dư thừa hoặc nhiễu.

- Việc trực quan hoá phân bố dữ liệu thường chỉ thực hiện được trong không gian 2D hoặc 3D.

Do đó, giảm chiều dữ liệu nhằm tìm một ánh xạ:

$$x \in \mathbb{R}^d \mapsto z \in \mathbb{R}^k, \quad k < d,$$

sao cho lượng thông tin quan trọng trong x được bảo toàn càng nhiều càng tốt.

1.4.2 Phân tích thành phần chính (Principal Component Analysis - PCA)

PCA là một phương pháp giảm chiều tuyến tính, không giám sát, tìm một hệ trục toạ độ mới sao cho phần lớn phương sai của dữ liệu được tập trung vào một số ít thành phần đầu tiên. Giả sử dữ liệu có dạng ma trận $X \in \mathbb{R}^{d \times N}$, mỗi cột là một mẫu:

1. Tính vector trung bình:

$$\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n.$$

2. Chuẩn hoá dữ liệu về trung tâm:

$$\hat{x}_n = x_n - \bar{x}, \quad \hat{X} = (\hat{x}_1, \dots, \hat{x}_N).$$

3. Tính ma trận hiệp phương sai:

$$S = \frac{1}{N} \hat{X} \hat{X}^T.$$

4. Tìm các giá trị riêng λ_i và vector riêng u_i của S , sắp xếp $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$.

5. Chọn k vector riêng đầu, tạo thành ma trận $U_k = (u_1, \dots, u_k) \in \mathbb{R}^{d \times k}$.

6. Chiếu dữ liệu:

$$Z = U_k^T \hat{X} \in \mathbb{R}^{k \times N}.$$

Tỷ lệ phương sai được giữ lại khi chọn k thành phần chính:

$$r_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^d \lambda_j}.$$

1.4.3 Phân tích biệt thức tuyến tính (Linear Discriminant Analysis - LDA) cho hai lớp

LDA là phương pháp giảm chiều tuyến tính có giám sát, sử dụng thông tin nhãn lớp để tìm không gian con trong đó các điểm cùng lớp càng tập trung và khoảng cách giữa các lớp càng lớn. Xét bài toán hai lớp X_1, X_2 với kỳ vọng m_1, m_2 . Ta xét phép chiếu tuyến tính:

$$z = w^T x, \quad w \in \mathbb{R}^d.$$

Hình chiếu của kỳ vọng lớp j là $\bar{m}_j = w^T m_j$. Gọi S_j^2 là phương sai của các điểm lớp j sau khi chiếu lên đường thẳng w . LDA tìm véc tơ w sao cho:

$$J(w) = \frac{(\bar{m}_1 - \bar{m}_2)^2}{S_1^2 + S_2^2}$$

đạt cực đại. Có thể viết lại:

$$J(w) = \frac{w^T S_B w}{w^T S_W w},$$

trong đó:

$$S_B = (m_1 - m_2)(m_1 - m_2)^T$$

là ma trận giữa lớp (between-class scatter), và

$$S_W = S_1 + S_2$$

là ma trận trong lớp (within-class scatter), với S_j là ma trận hiệp phương sai trong lớp j :

$$S_j = \sum_{x_n \in X_j} (x_n - m_j)(x_n - m_j)^T.$$

Bài toán tối ưu trở thành:

$$w = \arg \max_w \frac{w^T S_B w}{w^T S_W w},$$

và nghiệm thu được từ bài toán trị riêng tổng quát:

$$S_W^{-1} S_B w = \lambda w.$$

Vector riêng tương ứng với giá trị riêng lớn nhất chính là hướng chiếu LDA tối ưu cho bài toán hai lớp. Dữ liệu sau khi giảm chiều có dạng $z = w^T x$.

1.4.4 So sánh PCA và LDA trong bối cảnh dự đoán tim mạch

Trong dự đoán nguy cơ tim mạch:

- PCA không sử dụng nhãn lớp, phù hợp cho việc nén dữ liệu từ các đặc trưng như chỉ số sức khỏe, thói quen sinh hoạt và trực quan hóa dữ liệu.
- LDA sử dụng nhãn có bệnh/không có bệnh tim mạch, giúp tối ưu trực tiếp khả năng phân biệt giữa hai nhóm đối tượng, do đó thường hữu ích khi dùng làm bước tiền xử lý trước khi huấn luyện bộ phân loại.

1.5 Phân cụm dữ liệu với DBSCAN

1.5.1 Học không giám sát và ý nghĩa của phân cụm

Học không giám sát (*Unsupervised Learning*) là nhóm phương pháp học máy làm việc với dữ liệu không có nhãn mục tiêu. Mục tiêu của phương pháp này là khám phá các cấu trúc hoặc quy luật tiềm ẩn trong dữ liệu.

Cho tập dữ liệu:

$$X = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\},$$

trong đó mỗi mẫu dữ liệu được biểu diễn bởi:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id}) \in \mathbb{R}^d.$$

Một nhiệm vụ phổ biến của học không giám sát là phân cụm dữ liệu (*clustering*). Phân cụm nhằm chia dữ liệu thành các nhóm sao cho các điểm trong cùng một cụm có mức độ tương đồng cao, còn các điểm thuộc các cụm khác nhau có sự khác biệt rõ rệt.

Về bản chất, phân cụm hướng tới:

Tăng độ tương đồng trong cùng cụm

và

Tăng sự khác biệt giữa các cụm.

Phân cụm thường được sử dụng để khám phá cấu trúc dữ liệu, nhận diện các nhóm mẫu có đặc điểm tương tự nhau và hỗ trợ phát hiện các điểm bất thường hoặc nhiễu.

1.5.2 Thuật toán DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) là thuật toán phân cụm dựa trên mật độ. Thuật toán gom các điểm nằm trong vùng có mật độ cao vào cùng một cụm và xem các điểm tách biệt là nhiễu.

DBSCAN sử dụng hai tham số chính:

$$\varepsilon > 0$$

là bán kính lân cận, và

$$MinPts$$

là số lượng điểm tối thiểu cần có để một vùng được xem là đủ mật độ.

Với một điểm $\mathbf{x}_i$, vùng lân cận bán kính ε được xác định:

$$N_\varepsilon(\mathbf{x}_i) = \{\mathbf{x}_j \in X \mid d(\mathbf{x}_i, \mathbf{x}_j) \leq \varepsilon\},$$

trong đó khoảng cách thường dùng là khoảng cách Euclidean:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{k=1}^d (x_{ik} - x_{jk})^2}.$$

DBSCAN phân loại các điểm thành ba nhóm:

- **Điểm lõi** (*core point*):

$$|N_\varepsilon(\mathbf{x}_i)| \geq MinPts.$$

- **Điểm biên** (*border point*): không phải điểm lõi nhưng nằm trong vùng lân cận của một điểm lõi.
- **Điểm nhiễu** (*noise point*): không phải điểm lõi và không thuộc vùng lân cận của bất kỳ điểm lõi nào.

Thuật toán bắt đầu từ một điểm chưa xét. Nếu điểm đó là điểm lõi, DBSCAN hình thành một cụm mới và mở rộng cụm bằng các điểm có thể kết nối theo mật độ. Các điểm không thuộc cụm nào được xem là nhiễu và thường được gán nhãn -1 .

DBSCAN có ưu điểm là không cần xác định trước số cụm, có thể phát hiện cụm với hình dạng bất kỳ và nhận diện được nhiễu. Tuy nhiên, kết quả phụ thuộc đáng kể vào việc lựa chọn ε và $MinPts$.

1.5.3 Lựa chọn số cụm và đánh giá chất lượng cụm

Khác với K-Means, DBSCAN không yêu cầu xác định trước số cụm. Số cụm được hình thành tự động dựa trên hai tham số ε và $MinPts$. Sau khi phân cụm, số cụm có thể được xác định bằng số nhãn cụm khác nhau, không tính nhãn nhiễu -1 :

$$K = |\{c_i \mid c_i \neq -1\}|.$$

Việc lựa chọn tham số ảnh hưởng trực tiếp đến kết quả phân cụm. Nếu ε quá nhỏ, nhiều điểm có thể bị gán là nhiễu; nếu ε quá lớn, các cụm riêng biệt có thể bị gộp lại. Một cách thường dùng để hỗ trợ chọn ε là biểu đồ khoảng cách k -láng giềng gần nhất (k -distance plot), trong đó:

$$k = MinPts.$$

Sau khi phân cụm, chất lượng cụm có thể được đánh giá bằng các độ đo nội tại như:

- **Silhouette Score**: đánh giá mức độ phù hợp của một điểm với cụm hiện tại so với các cụm khác.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}.$$

- **Davies-Bouldin Score**: đo mức độ phân tách giữa các cụm; giá trị càng thấp thì kết quả phân cụm càng tốt.
- **Calinski-Harabasz Score**: so sánh độ phân tán giữa các cụm và trong từng cụm; giá trị càng cao thường cho thấy cụm được phân tách rõ hơn.

Nếu dữ liệu có nhãn tham chiếu, có thể sử dụng thêm các độ đo bên ngoài như **Adjusted Rand Index** (ARI), **Normalized Mutual Information** (NMI) và **Cluster Purity** để so sánh kết quả phân cụm với nhãn thật.

1.6 Các thước đo đánh giá mô hình phân loại

1.6.1 Ma trận nhầm lẫn (Confusion Matrix)

Với bài toán phân loại nhị phân (cá nhân mắc bệnh tim mạch là lớp dương), ma trận nhầm lẫn có dạng:

	Dự đoán 0	Dự đoán 1
Thực 0	TN	FP
Thực 1	FN	TP

trong đó:

- **TP (True Positive)**: số cá nhân thực sự mắc bệnh tim mạch và được mô hình dự đoán chính xác là mắc bệnh tim mạch.
- **TN (True Negative)**: số cá nhân không mắc bệnh tim mạch và được mô hình dự đoán chính xác là không mắc bệnh tim mạch.
- **FP (False Positive)**: số cá nhân không mắc bệnh tim mạch nhưng bị mô hình dự đoán nhầm là mắc bệnh tim mạch.
- **FN (False Negative)**: số cá nhân mắc bệnh tim mạch nhưng bị mô hình dự đoán nhầm là không mắc bệnh tim mạch.

1.6.2 Accuracy, Precision, Recall, F1-score

Từ ma trận nhầm lẫn, ta có các thước đo:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN},$$

$$\text{Precision} = \frac{TP}{TP + FP},$$

$$\text{Recall} = \frac{TP}{TP + FN},$$

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

Trong bối cảnh dự đoán bệnh tim mạch, **Recall** của lớp có nguy cơ mắc bệnh đặc biệt quan trọng vì nó phản ánh tỷ lệ bệnh nhân thực tế được mô hình phát hiện, giúp tránh bỏ sót các ca bệnh tiềm ẩn; tuy nhiên, Precision cũng cần được cân nhắc để tránh gây lo lắng dư thừa hoặc chỉ định các xét nghiệm chuyên sâu tốn kém không cần thiết cho người khỏe mạnh.

1.6.3 Đường cong ROC và chỉ số AUC

Đường cong ROC (Receiver Operating Characteristic) biểu diễn mối quan hệ giữa:

$$\text{TPR} = \frac{TP}{TP + FN} \quad (\text{True Positive Rate, hay Recall})$$

và

$$\text{FPR} = \frac{FP}{FP + TN} \quad (\text{False Positive Rate}),$$

khi ta thay đổi ngưỡng phân loại trên xác suất dự đoán. Chỉ số AUC (Area Under the Curve) là diện tích dưới đường cong ROC, có giá trị trong khoảng $[0, 1]$. AUC càng gần 1 thì mô hình càng có khả năng phân biệt tốt giữa người có nguy cơ và người không có nguy cơ mắc bệnh; $\text{AUC} = 0.5$ tương đương với phân loại ngẫu nhiên.

1.6.4 Lựa chọn ngưỡng phân loại

Trong thực tế, ngưỡng mặc định 0.5 không phải lúc nào cũng tối ưu. Đội ngũ y tế hoặc nhà nghiên cứu có thể điều chỉnh ngưỡng nhằm cân bằng giữa:

- **Giảm FN (bỏ sót bệnh nhân có nguy cơ):** Để đảm bảo bệnh nhân được can thiệp và điều trị sớm, giảm thiểu rủi ro biến cố tim mạch.
- **Giữ FP ở mức chấp nhận được:** Để tránh áp lực tâm lý cho người dân và giảm tải chi phí xét nghiệm sàng lọc không cần thiết cho hệ thống y tế.

Việc lựa chọn ngưỡng có thể dựa trên đường ROC, đường Precision-Recall hoặc các tiêu chí y tế cộng đồng cụ thể (chi phí sàng lọc, hiệu quả điều trị dự phòng).

1.7 Tóm tắt chương

Chương này đã trình bày các cơ sở lý thuyết chính cho đề tài: bối cảnh rủi ro mắc bệnh tim mạch, các khái niệm cơ bản trong học máy cho bài toán phân loại, mô hình hồi quy Logistic và K-NN, các kỹ thuật giảm chiều PCA và LDA, phân cụm DBSCAN cùng các thước đo đánh giá như Confusion Matrix, Accuracy, Precision, Recall, F1 và ROC-AUC. Đây là nền tảng để các chương sau áp dụng vào xây dựng và đánh giá mô hình dự đoán khả năng mắc bệnh trên bộ dữ liệu thực nghiệm.

CHƯƠNG 2

Thực nghiệm trên bộ dữ liệu

2.1 Dữ liệu nghiên cứu

2.1.1 Giới thiệu dữ liệu

Bộ dữ liệu được sử dụng trong nghiên cứu này là *Heart Disease*, được trích xuất từ Hệ thống Giám sát Rủi ro Sức khỏe Hành vi (Behavioral Risk Factor Surveillance System - BRFSS) năm 2020 của Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh Hoa Kỳ (CDC). Bộ dữ liệu mô tả các thông tin liên quan đến nhân khẩu học, chỉ số sức khỏe hiện tại và các thói quen sinh hoạt hàng ngày của các cá nhân tại Hoa Kỳ.

Bộ dữ liệu gồm tổng cộng khoảng 319.795 bản ghi (mẫu quan sát), với 17 biến đầu vào (đặc trưng) và 1 biến đầu ra (biến mục tiêu). Biến mục tiêu HeartDisease biểu diễn trạng thái mắc bệnh tim mạch của cá nhân (1: Có, 0: Không). Trong số các biến đầu vào, mô hình tập trung khai thác các nhóm đặc trưng chính bao gồm:

- **Chỉ số sức khỏe:** BMI, tình trạng sức khỏe thể chất/tinh thần, thời gian ngủ.
- **Thói quen sinh hoạt:** Hút thuốc, uống rượu, hoạt động thể chất.
- **Tiền sử bệnh lý:** Đột quỵ, hen suyễn, bệnh thận, ung thư da, tiểu đường.
- **Nhân khẩu học:** Giới tính, nhóm tuổi, chủng tộc.

2.1.2 Mô tả các đặc trưng

Bộ dữ liệu sử dụng trong đề tài gồm 18 thuộc tính, trong đó có 17 biến đầu vào (giải thích) và 1 biến mục tiêu (phản hồi). Các thuộc tính có thể được chia thành ba nhóm: biến phân loại, biến số (định lượng) và biến mục tiêu.

Các biến phân loại (Categorical variables):

- **SEX** biến phân loại, cho biết giới tính của cá nhân (Male; Female).
- **AgeCategory:** biến phân loại có thứ bậc, biểu diễn nhóm tuổi của cá nhân (gồm 13 nhóm từ 18-24 đến 80 trở lên).
- **Race:** biến phân loại, cho biết chủng tộc/sắc tộc của cá nhân (White, Black, Asian, American Indian/Alaskan Native, Hispanic, Other).
- **Diabetic:** biến phân loại, biểu diễn tình trạng bệnh tiểu đường (Yes, No).
- **GenHealth:** biến phân loại có thứ bậc, cá nhân tự đánh giá sức khỏe tổng quát (Poor, Fair, Good, Very good, Excellent).

- **Các biến nhị phân (Yes/No):** bao gồm một loạt các biến mô tả thói quen sinh hoạt và tiền sử bệnh lý:
 - **Smoking:** Có hút ít nhất 100 điếu thuốc trong đời hay không.
 - **AlcoholDrinking:** Có uống rượu bia nhiều hay không (Nam >14 ly/tuần, Nữ >7 ly/tuần).
 - **Stroke:** Có từng bị đột quỵ hay không.
 - **DiffWalking:** Có gặp khó khăn nghiêm trọng khi đi bộ hoặc leo cầu thang không.
 - **PhysicalActivity:** Có tham gia hoạt động thể chất hoặc tập thể dục trong 30 ngày qua không.
 - **Asthma:** Có từng bị hen suyễn hay không.
 - **KidneyDisease:** Có từng bị bệnh thận hay không (không bao gồm sỏi thận, nhiễm trùng bàng quang).
 - **SkinCancer:** Có từng bị ung thư da hay không.

Các biến số (định lượng):

- **BMI:** biến số thực, chỉ số khối cơ thể (Body Mass Index), được tính dựa trên chiều cao và cân nặng.
- **PhysicalHealth:** biến số nguyên, số ngày trong 30 ngày gần nhất cá nhân cảm thấy sức khỏe thể chất (bao gồm bệnh tật và chấn thương) không tốt.
- **MentalHealth:** biến số nguyên, số ngày trong 30 ngày gần nhất cá nhân cảm thấy sức khỏe tinh thần không tốt.
- **SleepTime:** biến số nguyên, số giờ ngủ trung bình của cá nhân trong một chu kỳ 24 giờ.

Biến mục tiêu:

- **HeartDisease (Y):** biến nhị phân, đóng vai trò là biến phản hồi (biến mục tiêu) của mô hình. Biến này biểu diễn trạng thái cá nhân có từng được chẩn đoán mắc bệnh mạch vành (CHD) hoặc nhồi máu cơ tim (MI) hay không:
 - **Giá trị Yes:** Cá nhân có nguy cơ/mắc bệnh tim mạch.
 - **Giá trị No:** Cá nhân không có nguy cơ/mắc bệnh tim mạch.

2.1.3 Thống kê dữ liệu sơ bộ

Để có cái nhìn tổng quan về cấu trúc và phân bố dữ liệu, nghiên cứu sử dụng hai lệnh `df.info()` (thông tin kiểu dữ liệu, số giá trị khác rỗng) và `df.describe()` (các thống kê mô tả cơ bản cho các biến số).

```

<class 'pandas.DataFrame'>
RangeIndex: 319795 entries, 0 to 319794
Data columns (total 18 columns):
#   Column                Non-Null Count  Dtype
---  -
0   HeartDisease          319795 non-null  str
1   BMI                   319795 non-null  float64
2   Smoking               319795 non-null  str
3   AlcoholDrinking       319795 non-null  str
4   Stroke                319795 non-null  str
5   PhysicalHealth        319795 non-null  float64
6   MentalHealth          319795 non-null  float64
7   DiffWalking           319795 non-null  str
8   Sex                   319795 non-null  str
9   AgeCategory           319795 non-null  str
10  Race                  319795 non-null  str
11  Diabetic               319795 non-null  str
12  PhysicalActivity       319795 non-null  str
13  GenHealth              319795 non-null  str
14  SleepTime              319795 non-null  float64
15  Asthma                 319795 non-null  str
16  KidneyDisease          319795 non-null  str
17  SkinCancer             319795 non-null  str
dtypes: float64(4), str(14)
memory usage: 43.9 MB

```

Hình 2.1: Kết quả lệnh `df.info()`.

Nhận xét: Tất cả 18 cột đều hiển thị 319.795 non-null. Điều này chứng tỏ bộ dữ liệu không có giá trị thiếu (missing values).

2.1.4 Loại bỏ dữ liệu trùng lặp

Trong quá trình thu thập và trích xuất dữ liệu từ các khảo sát quy mô lớn như BRFSS, việc xuất hiện các bản ghi trùng lặp hoàn toàn (identical records) là điều khó tránh khỏi. Việc tồn tại các dòng trùng lặp có thể gây ra hiện tượng thiên kiến (bias), khiến mô hình học máy đánh giá sai lệch tầm quan trọng của một số nhóm đặc trưng cụ thể, dẫn đến nguy cơ quá khớp (overfitting). Để đảm bảo tính khách quan và duy trì chất lượng dữ liệu, nghiên cứu thực hiện các bước sau:

- **Nhận diện và loại bỏ:** Sử dụng phương thức `drop_duplicates()` để rà soát toàn bộ tập dữ liệu và chỉ giữ lại bản ghi đầu tiên trong số các dòng có giá trị hoàn toàn giống nhau ở tất cả các cột.
- **Đánh lại chỉ số (Reset Index):** Sau khi các dòng trùng lặp bị xóa bỏ, các chỉ số hàng (index) ban đầu sẽ bị gián đoạn. Do đó, hàm `reset_index(drop=True)` được áp dụng để thiết lập lại hệ thống chỉ số bắt đầu từ 0 một cách liên tục, tạo điều

kiện thuận lợi cho các thao tác truy xuất và phân chia dữ liệu (Train-Test Split) về sau.

	BMI	PhysicalHealth	MentalHealth	SleepTime
count	301717.000000	301717.000000	301717.000000	301717.000000
mean	28.441970	3.572298	4.121475	7.084559
std	6.468134	8.140656	8.128288	1.467122
min	12.020000	0.000000	0.000000	1.000000
25%	24.030000	0.000000	0.000000	6.000000
50%	27.410000	0.000000	0.000000	7.000000
75%	31.650000	2.000000	4.000000	8.000000
max	94.850000	30.000000	30.000000	24.000000


Hình 2.2: Kết quả lệnh `df.describe()` sau khi xóa lặp

Từ kết quả `df.describe()` có một số nhận xét quan trọng:

- Đặc trưng rủi ro: Chỉ số **BMI** trung bình của tập dữ liệu (28.44) vượt ngưỡng bình thường (18.5 – 24.9), cho thấy tập mẫu có nguy cơ cao về các bệnh lý liên quan đến cân nặng, trong đó có tim mạch.
- Các biến **PhysicalHealth** **MentalHealth** có độ lệch chuẩn cao (≈ 8.13) cao gấp đôi so với trung bình (≈ 3.57 và 4.12), điều này chứng tỏ sự khác biệt rất lớn về tình trạng sức khỏe giữa các cá nhân trong cộng đồng.
- Thời gian ngủ **SleepTime** có phân phối trông "đẹp" nhất. Trung bình là 7.1 giờ và trung vị là 7.0 giờ, rất sát với khuyến nghị sức khỏe thông thường.


2.1.5 Trực quan dữ liệu ban đầu

Bên cạnh các thống kê mô tả, nghiên cứu còn sử dụng một số biểu đồ trực quan để quan sát phân bố dữ liệu và phát hiện các đặc điểm bất thường. Trước hết, phân bố của biến mục tiêu **HeartDisease** được biểu diễn bằng biểu đồ cột, cho thấy mức độ mất cân bằng giữa lớp có nguy cơ mắc bệnh tim mạch và không mắc bệnh.




Hình 2.3: Phân bố biến mục tiêu **Heart Disease**.

Tiếp theo, các biến số (như BMI, PhysicalHealth, MentalHealth, SleepTime) được trực quan bằng các biểu đồ histogram để quan sát phân bố, độ lệch và sự xuất hiện của các giá trị ngoại lai.



Hình 2.4: Histogram một số biến số quan trọng trong bộ dữ liệu.

Đối với các biến phân loại (như **Sex**, **Smoking**, **DiffWalking**, **Stroke** ...), nghiên cứu sử dụng biểu đồ cột để quan sát tần suất từng giá trị và so sánh phân bố giữa các nhóm.



Hình 2.5: Biểu đồ tần suất một số biến phân loại trong bộ dữ liệu.

2.1.6 Xử lý giá trị ngoại lệ (Outliers)

Dựa trên kết quả thống kê mô tả và trực quan hóa ban đầu, các biến định lượng gồm **BMI**, **PhysicalHealth**, **MentalHealth** và **SleepTime** xuất hiện nhiều giá trị ngoại lệ cực đoan. Việc giữ nguyên các giá trị này có thể gây nhiễu cho quá trình huấn luyện, làm giảm khả năng hội tụ và độ chính xác của các thuật toán nhạy cảm với khoảng cách như KNN, Logistic Regression.

Để khắc phục hiện tượng này mà không làm mất đi thông tin của toàn bộ bản ghi, nghiên cứu áp dụng kỹ thuật Capping (Winsorization). Các bước thực hiện cụ thể như sau:

- **Xác định ngưỡng giới hạn:** Sử dụng phương pháp phân vị để xác định ngưỡng dưới tại mức 1% (lower limit) và ngưỡng trên tại mức 99% (upper limit) cho từng đặc trưng số học.
- **Thực hiện kẹp giá trị (Clipping):** hay thế toàn bộ các giá trị nằm ngoài khoảng $[0.01, 0.99]$ bằng chính giá trị tại ngưỡng tương ứng.

Bên cạnh việc xác định và xử lý các giá trị ngoại lệ, nhóm cũng tiến hành thống kê số lượng và tỉ lệ ngoại lệ trên từng thuộc tính số. Cụ thể, với mỗi đặc trưng số X_j , một giá trị x_{ij} được xem là ngoại lệ nếu nhỏ hơn ngưỡng phân vị 1% hoặc lớn hơn ngưỡng phân vị 99%:

$$x_{ij} < Q_{0.01}^{(j)} \quad \text{hoặc} \quad x_{ij} > Q_{0.99}^{(j)}.$$

Số lượng giá trị ngoại lệ của đặc trưng X_j được tính như sau:

$$\text{outlier_count}_j = \sum_{i=1}^n \mathbb{I} \left(x_{ij} < Q_{0.01}^{(j)} \text{ hoặc } x_{ij} > Q_{0.99}^{(j)} \right),$$

trong đó $\mathbb{I}(\cdot)$ là hàm chỉ báo, nhận giá trị 1 nếu điều kiện đúng và nhận giá trị 0 nếu điều kiện sai.

Tỉ lệ ngoại lệ của từng đặc trưng được xác định bởi:

$$\text{outlier_ratio}_j = \frac{\text{outlier_count}_j}{n},$$


trong đó n là tổng số mẫu dữ liệu sau khi loại bỏ các dòng trùng lặp. Chỉ số **outlier_count** cho biết số lượng giá trị ngoại lệ tuyệt đối, trong khi **outlier_ratio** cho biết mức độ phổ biến của ngoại lệ so với toàn bộ dữ liệu. Việc thống kê hai chỉ số này giúp nhóm đánh giá mức độ ảnh hưởng của outlier trên từng biến trước khi áp dụng kỹ thuật Capping.

	column	lower_1pct	upper_99pct	outlier_count	outlier_ratio
0	BMI	17.76	48.82	5966	0.019773
1	PhysicalHealth	0.00	30.00	0	0.000000
2	MentalHealth	0.00	30.00	0	0.000000
3	SleepTime	3.00	12.00	2338	0.007749

Tổng số giá trị outlier: 8304


Hình 2.6: Số lượng và tỉ lệ các giá trị Outliers.

Sau khi xem xét số lượng và tỉ lệ các giá trị Outliers của từng cột, tiến hành trực quan hóa Box-Plot các giá trị Outliers trước và sau khi xử lý theo lý thuyết nêu trên:



Hình 2.7: Boxplot **BMI**, **PhysicalHealth** , **MentalHealth** và **SleepTime** trước khi xử lý Outliers.

Kết quả sau khi xử lý: Việc áp dụng kỹ thuật Capping mang lại sự cải thiện rõ rệt cho phân phối dữ liệu thông qua quan sát biểu đồ hộp (boxplot):



Hình 2.8: Boxplot **BMI**, **PhysicalHealth** , **MentalHealth** và **SleepTime** sau khi xử lý Outliers.

2.1.7 Phân chia dữ liệu (Train–Test Split)

Sau khi làm sạch dữ liệu và xử lý các giá trị ngoại lệ, bộ dữ liệu gồm 319.795 quan sát và 17 đặc trưng đầu vào. Để khảo sát ảnh hưởng của kích thước tập huấn luyện tới chất lượng mô hình dự đoán nguy cơ tim mạch, nghiên cứu thực hiện ba kịch bản chia dữ liệu khác nhau bằng hàm `train_test_split` của thư viện `scikit-learn`, với các tỉ lệ:

- **Kịch bản 1 (80/20):** 80% dữ liệu dùng để huấn luyện, 20% dữ liệu dùng để kiểm tra.
- **Kịch bản 2 (70/30):** 70% dữ liệu dùng để huấn luyện, 30% dữ liệu dùng để kiểm tra.
- **Kịch bản 3 (60/40):** 60% dữ liệu dùng để huấn luyện, 40% dữ liệu dùng để kiểm tra.

Trong cả ba kịch bản, để đảm bảo tỉ lệ giữa hai lớp (Có bệnh tim / Không bệnh tim) được giữ nguyên trong tập huấn luyện và kiểm tra, tham số `stratify = y` được sử dụng khi gọi hàm `train_test_split`.

Kịch bản	Tỉ lệ train:test	Số mẫu train	Số mẫu test
Kịch bản 1	80% : 20%	241 373	60 344
Kịch bản 2	70% : 30%	211 201	90 516
Kịch bản 3	60% : 40%	181 030	120 687

Bảng 2.1: Kích thước các tập dữ liệu với ba kịch bản chia train–test

2.1.8 Biến đổi đặc trưng (Feature engineering)

Trong toàn bộ các thí nghiệm, quy trình biến đổi đặc trưng được thực hiện thống nhất nhằm chuẩn bị dữ liệu phù hợp cho các kỹ thuật giảm chiều như PCA, LDA và các mô hình phân loại như Logistic Regression, K-NN, SVM. Quy trình này được thực hiện theo trình tự: chuẩn hóa các biến số, sau đó mã hóa các biến phân loại.

Chuẩn hoá (Scaling): Trước tiên, các đặc trưng số được chuẩn hóa nhằm đưa các biến về cùng một thang đo. Điều này đặc biệt quan trọng đối với các mô hình nhạy cảm với khoảng cách hoặc độ lớn của biến đầu vào như K-NN, SVM, Logistic Regression, PCA và LDA.

Nghiên cứu sử dụng `StandardScaler` hoặc cài đặt tương đương để chuẩn hóa các đặc trưng số theo công thức:

$$x' = \frac{x - \mu}{\sigma},$$

trong đó μ và σ lần lượt là trung bình và độ lệch chuẩn của từng biến số trên *tập huấn luyện*.

Nhóm đặc trưng được chuẩn hóa bao gồm các biến định lượng gốc:

BMI, PhysicalHealth, MentalHealth, SleepTime.

Bộ chuẩn hóa chỉ được `fit` trên `X_train`, sau đó dùng để `transform` cho cả `X_train` và `X_test`. Cách làm này giúp tránh hiện tượng rò rỉ thông tin (*data leakage*) từ tập kiểm tra vào quá trình huấn luyện.

Mã hoá (Encoding): Sau khi chuẩn hóa các biến số, các thuộc tính phân loại được xử lý bằng mã hóa one-hot thông qua `OneHotEncoder` hoặc cài đặt tương đương. Các thuộc tính phân loại bao gồm **Sex**, **AgeCategory**, **Race**, **Diabetic**, **GenHealth** và các biến trạng thái dạng **Yes/No**.

Phương pháp mã hóa one-hot giúp:

- Tránh áp đặt thứ bậc giả tạo giữa các nhãn phân loại, đặc biệt với các biến không có tính thứ tự tự nhiên như **Race** hay **Sex**.
- Biến mỗi giá trị phân loại thành một biến nhị phân nhận giá trị 0 hoặc 1, giúp dữ liệu phù hợp hơn với các mô hình học máy.

Bộ mã hóa one-hot được `fit` trên phần dữ liệu huấn luyện, sau đó được dùng để biến đổi cả `X_train` và `X_test`. Điều này đảm bảo rằng tập huấn luyện và tập kiểm tra có cùng cấu trúc đặc trưng sau khi mã hóa.

Cuối cùng, các đặc trưng số đã chuẩn hóa được kết hợp với các đặc trưng phân loại đã mã hóa để tạo thành bộ dữ liệu đầu vào hoàn chỉnh cho các mô hình.

	BMI	PhysicalHealth	MentalHealth	SleepTime
mean	0.0000	0.0000	-0.0000	-0.0000
std	1.0000	1.0000	1.0000	1.0000
min	-1.7203	-0.4391	-0.5065	-2.9618
max	3.3065	3.2391	3.1803	3.5760

Hình 2.9: Hình mô tả một số thuộc tính dữ liệu trên tập train 80/20 sau chuẩn hóa.

2.2 Phương pháp thí nghiệm giảm chiều

2.2.1 Phương pháp 1: PCA (Phân tích thành phần chính)

Trong nghiên cứu này, PCA (*Principal Component Analysis*) được sử dụng như một phương pháp giảm chiều không giám sát nhằm phân tích cấu trúc dữ liệu sau tiền xử lý. Dữ liệu đầu vào của PCA là tập đặc trưng đã được làm sạch, xử lý ngoại lệ, chuẩn hóa các cột số và mã hóa các biến phân loại.

PCA được sử dụng với ba mục đích chính:

- Đánh giá mức độ phương sai được giải thích bởi từng thành phần chính.
- Xác định số lượng thành phần chính cần thiết để bảo tồn ít nhất 90% phương sai của dữ liệu.
- Trực quan hóa dữ liệu trên các cặp thành phần chính nhằm quan sát khả năng phân tách giữa hai lớp **HeartDisease**.

Về mặt thực nghiệm, PCA được áp dụng trên tập huấn luyện sau tiền xử lý của kịch bản chia dữ liệu train/test là 80/20. Cụ thể, PCA được `fit` trên `X_train` sau khi đã chuẩn hóa và mã hóa. Sau đó, phép biến đổi PCA học được từ tập huấn luyện được

dùng để biến đổi cả tập huấn luyện và tập kiểm tra. Cách thực hiện này giúp tránh hiện tượng rò rỉ dữ liệu (*data leakage*), vì thông tin từ tập kiểm tra không được sử dụng trong quá trình học các thành phần chính.

Với tập huấn luyện sau tiền xử lý, dữ liệu có 25 đặc trưng đầu vào. PCA thực hiện biến đổi các đặc trưng này thành các thành phần chính mới, sao cho các thành phần đầu tiên giữ lại nhiều phương sai nhất của dữ liệu.

Tỉ lệ phương sai được giải thích bởi các thành phần chính được biểu diễn bởi:

$$\text{Explained Variance Ratio} = [\lambda_1, \lambda_2, \dots, \lambda_d],$$


trong đó λ_i là tỉ lệ phương sai được giải thích bởi thành phần chính thứ i . Tổng phương sai tích lũy đến thành phần chính thứ k được tính bởi:

$$\text{Cumulative Variance}_k = \sum_{i=1}^k \lambda_i.$$

Từ kết quả thực nghiệm, nhóm xác định số lượng thành phần chính cần thiết để giữ lại ít nhất 90% phương sai của dữ liệu. Trong bài toán này, chỉ cần giữ lại 6 thành phần chính là có thể bảo toàn được khoảng 91.35% phương sai của dữ liệu ban đầu. Điều này cho thấy PCA có thể giảm số chiều từ 25 đặc trưng sau tiền xử lý xuống còn 6 thành phần chính mà vẫn giữ lại phần lớn thông tin.

Cụ thể, phương sai tích lũy của các thành phần chính đầu tiên có xu hướng như sau:

$$\begin{aligned} PC_1 &\approx 65.61\%, & PC_1 - PC_2 &\approx 75.19\%, & PC_1 - PC_3 &\approx 80.17\%, \\ PC_1 - PC_4 &\approx 85.01\%, & PC_1 - PC_5 &\approx 88.70\%, & PC_1 - PC_6 &\approx 91.35\%. \end{aligned}$$




Hình 2.10: Tỉ lệ phương sai được giải thích bởi các thành phần chính PCA

Để phục vụ trực quan hóa, nhóm tiếp tục sử dụng 6 thành phần chính đầu tiên và biểu diễn dữ liệu theo từng cặp:

$$(PC_1, PC_2), \quad (PC_3, PC_4), \quad (PC_5, PC_6).$$

Mỗi điểm dữ liệu trên biểu đồ được tô màu theo nhãn **HeartDisease**, gồm hai lớp: **No** và **Yes**. Việc trực quan hóa này giúp quan sát xem dữ liệu sau khi chiếu lên không gian PCA có hình thành ranh giới phân tách rõ ràng giữa hai lớp hay không.



Hình 2.11: Trực quan hóa dữ liệu trên các cặp thành phần chính PCA

Ngoài mục đích phân tích và trực quan hóa, PCA còn được sử dụng để tạo bộ dữ liệu giảm chiều cho các mô hình phân loại. Với mỗi kịch bản chia dữ liệu, PCA được cấu hình với:

$$n_components = 0.90,$$

nghĩa là thuật toán tự động chọn số lượng thành phần chính sao cho tổng phương sai được giữ lại đạt ít nhất 90%. Bộ dữ liệu sau PCA được sử dụng làm đầu vào cho các mô hình phân loại như KNN, Logistic Regression và Soft Margin SVM, nhằm so sánh hiệu quả giữa dữ liệu gốc sau tiền xử lý và dữ liệu đã giảm chiều.

Nhận xét từ kết quả thực nghiệm:

- **Cặp thành phần PC_1 và PC_2 :** Đây là mặt phẳng biểu diễn hai hướng biến thiên lớn nhất của dữ liệu. Hai thành phần này giữ lại khoảng 75.19% phương sai. Tuy nhiên, quan sát trực quan cho thấy hai lớp `HeartDisease = No` và `HeartDisease = Yes` vẫn chồng lẫn đáng kể, chưa tạo ra ranh giới phân tách rõ ràng.
- **Các cặp thành phần tiếp theo (PC_3, PC_4) và (PC_5, PC_6):** Các thành phần này bổ sung thêm phần phương sai còn lại để tổng cộng 6 thành phần chính giữ được khoảng 91.35% phương sai. Tuy nhiên, trên các mặt phẳng trực quan hóa này, hai nhãn vẫn chưa thể hiện sự tách biệt rõ ràng. Điều này cho thấy hướng biến thiên lớn của dữ liệu không hoàn toàn trùng với hướng phân biệt nhãn bệnh tim.
- **Đánh giá chung:** PCA giúp giảm số chiều dữ liệu từ 25 đặc trưng xuống còn 6 thành phần chính trong khi vẫn giữ được trên 90% phương sai. Tuy nhiên, do PCA là phương pháp không giám sát nên nó chỉ tối ưu theo phương sai của dữ liệu, không trực tiếp tối ưu khả năng phân tách nhãn. Vì vậy, dù PCA hữu ích trong việc giảm chiều và trực quan hóa, việc chỉ dựa vào một vài thành phần chính đầu tiên chưa đủ để phân tách rõ hai lớp `HeartDisease = No` và `HeartDisease = Yes`.

2.2.2 Phương pháp 2: LDA (Phân tích phân biệt tuyến tính)

Song song với PCA, nghiên cứu áp dụng LDA (*Linear Discriminant Analysis*) như một phương pháp giảm chiều có giám sát. Khác với PCA chỉ dựa trên phương sai của dữ liệu đầu vào, LDA sử dụng cả đặc trưng X và nhãn mục tiêu y nhằm tìm ra trục chiếu giúp phân tách các lớp tốt nhất.

Trong bài toán này, biến mục tiêu `HeartDisease` gồm hai lớp:

$$0 = \text{No}, \quad 1 = \text{Yes}.$$

Do bài toán chỉ có hai lớp, số chiều tối đa sau khi áp dụng LDA là:

$$C - 1 = 2 - 1 = 1,$$

trong đó C là số lớp. Vì vậy, nghiên cứu sử dụng LDA với:

$$n_components = 1.$$

Mục tiêu của LDA trong nghiên cứu này gồm:

- Tìm một trục chiếu duy nhất, ký hiệu là LD_1 , sao cho hai lớp `HeartDisease = No` và `HeartDisease = Yes` được phân tách tốt nhất có thể.
- Trục quan hóa phân phối dữ liệu trên trục LD_1 để đánh giá mức độ chồng lấn giữa hai lớp.
- Tạo bộ dữ liệu giảm chiều có giám sát để sử dụng làm đầu vào cho các mô hình phân loại như KNN, Logistic Regression và Soft Margin SVM.

Về mặt thực nghiệm, LDA được áp dụng trên dữ liệu sau tiền xử lý, tức là dữ liệu đã được làm sạch, xử lý ngoại lệ, chuẩn hóa các cột số và mã hóa các biến phân loại. Với kích bản chia dữ liệu train/test là 80/20, LDA được `fit` trên tập huấn luyện:

$$X_{\text{train}}, y_{\text{train}}.$$


Sau đó, phép biến đổi LDA đã học từ tập huấn luyện được sử dụng để biến đổi cả tập huấn luyện và tập kiểm tra:

$$X_{\text{train}}^{LDA} = LDA(X_{\text{train}}),$$

$$X_{\text{test}}^{LDA} = LDA(X_{\text{test}}).$$

Cách thực hiện này giúp tránh hiện tượng rò rỉ dữ liệu (*data leakage*), do tập kiểm tra không được sử dụng trong quá trình học trục chiếu LDA.

Sau khi biến đổi, mỗi mẫu dữ liệu được biểu diễn bởi một giá trị duy nhất trên trục LD_1 . Phân phối của LD_1 theo từng lớp được trục quan hóa bằng biểu đồ mật độ (*density plot*), qua đó cho phép quan sát mức độ tách biệt giữa nhóm không mắc bệnh tim và nhóm mắc bệnh tim.



Hình 2.12: Trục quan hóa phân phối dữ liệu sau LDA với $n_components = 1$

Từ kết quả thực nghiệm trên tập huấn luyện của kích bản 80/20, thống kê giá trị LD_1 theo từng lớp cho thấy:

$$\mu_{No} \approx -0.1274, \quad \mu_{Yes} \approx 1.2830,$$

trong đó μ_{No} là giá trị trung bình của lớp `HeartDisease = No`, còn μ_{Yes} là giá trị trung bình của lớp `HeartDisease = Yes`. Độ chênh lệch trung bình giữa hai lớp trên trục LD_1 là:

$$|\mu_{Yes} - \mu_{No}| \approx 1.4104.$$

Ngoài ra, trung vị của hai lớp lần lượt là:

$$\text{Median}_{No} \approx -0.2716, \quad \text{Median}_{Yes} \approx 1.0639.$$

Điều này cho thấy lớp `Yes` có xu hướng dịch chuyển sang vùng giá trị LD_1 lớn hơn so với lớp `No`.

Tương tự PCA, dữ liệu một chiều thu được từ LDA cũng được sử dụng làm đầu vào cho các mô hình phân loại. Trong báo cáo thực nghiệm, các mô hình được huấn luyện và đánh giá trên ba dạng dữ liệu:

- Dữ liệu gốc sau tiền xử lý (**RAW**).
- Dữ liệu giảm chiều bằng PCA với số thành phần được chọn sao cho giữ lại ít nhất 90% phương sai.
- Dữ liệu giảm chiều bằng LDA với $n_components = 1$.

Nhận xét và đánh giá:

- **Khả năng phân tách lớp:** LDA đã tìm được một trục chiếu LD_1 giúp hai lớp có sự khác biệt rõ hơn về mặt phân phối. Lớp `HeartDisease = No` có giá trị trung bình khoảng -0.1274 , trong khi lớp `HeartDisease = Yes` có giá trị trung bình khoảng 1.2830 . Điều này cho thấy nhóm có bệnh có xu hướng nằm lệch về phía giá trị LD_1 dương hơn so với nhóm không có bệnh.
- **Mức độ chồng lấn:** Mặc dù trung bình và trung vị của hai lớp có sự khác biệt, phân phối của hai lớp vẫn còn chồng lấn đáng kể trên trục LD_1 . Điều này phản ánh đặc điểm thực tế của dữ liệu bệnh tim: các đặc trưng sức khỏe và hành vi giữa hai nhóm có bệnh và không có bệnh không hoàn toàn tách biệt, mà tồn tại nhiều vùng giao thoa.
- **So sánh với PCA:** PCA là phương pháp giảm chiều không giám sát, chỉ tối ưu theo phương sai của dữ liệu nên không trực tiếp tối ưu khả năng phân tách nhãn. Ngược lại, LDA sử dụng thông tin nhãn trong quá trình học trục chiếu, do đó trục LD_1 có xu hướng thể hiện sự khác biệt giữa hai lớp rõ hơn. Tuy nhiên, do dữ liệu vẫn có sự chồng lấn, LDA một chiều chưa thể phân tách hoàn toàn hai lớp.
- **Đánh giá chung:** LDA phù hợp để phân tích khả năng phân tách hai lớp trong bài toán `HeartDisease`. Với bài toán nhị phân, LDA chỉ tạo ra một thành phần duy nhất nhưng thành phần này có ý nghĩa quan trọng vì được xây dựng nhằm tối đa hóa sự khác biệt giữa hai lớp. Dữ liệu sau LDA được sử dụng trong phần phân loại để so sánh với dữ liệu gốc và dữ liệu PCA, từ đó đánh giá hiệu quả của phương pháp giảm chiều có giám sát.

2.2.3 So sánh kết quả giảm chiều giữa PCA và LDA

Sau khi thực hiện giảm chiều bằng PCA và LDA, nhóm xây dựng một bảng tổng hợp nhằm so sánh hai phương pháp theo các tiêu chí khác nhau. Mục đích của bảng này là đánh giá lượng thông tin được bảo toàn bởi PCA và mức độ phân tách lớp mà LDA đạt được.

	method	supervised	n_components_used	information_metric	value
0	PCA	No	6	explained_variance_sum	0.913540
1	PCA	No	6	components_for_90pct_variance	6.000000
2	LDA	Yes	1	class_separation_mean_diff	1.410406

Hình 2.13: Bảng so sánh

Bảng so sánh gồm các thông tin chính:

- **method**: phương pháp giảm chiều được sử dụng, gồm PCA và LDA.
- **supervised**: cho biết phương pháp có sử dụng nhãn trong quá trình học hay không.
- **n_components_used**: số thành phần hoặc số chiều được sử dụng sau khi giảm chiều.
- **information_metric**: chỉ số dùng để đánh giá phương pháp.
- **value**: giá trị tương ứng của chỉ số đánh giá.

Đối với PCA, đây là phương pháp giảm chiều không giám sát, do đó quá trình tìm các thành phần chính chỉ dựa trên ma trận đặc trưng đầu vào X mà không sử dụng nhãn **HeartDisease**. Hiệu quả của PCA được đánh giá thông qua lượng phương sai được giải thích bởi các thành phần chính.

Với 6 thành phần chính đầu tiên, tổng phương sai được giải thích được tính bởi:

$$\sum_{i=1}^6 \lambda_i,$$

trong đó λ_i là tỉ lệ phương sai được giải thích bởi thành phần chính thứ i . Trong bài toán này, 6 thành phần chính đầu tiên giữ được khoảng 91.35% phương sai của dữ liệu sau tiền xử lý. Điều này cho thấy PCA có thể giảm số chiều từ 25 đặc trưng ban đầu xuống còn 6 thành phần chính mà vẫn bảo toàn được phần lớn thông tin của dữ liệu.

Ngoài ra, nhóm cũng xác định số lượng thành phần chính nhỏ nhất cần thiết để đạt ít nhất 90% phương sai tích lũy:

$$n_{90} = \min \left\{ k : \sum_{i=1}^k \lambda_i \geq 0.90 \right\}.$$

Kết quả thực nghiệm cho thấy:

$$n_{90} = 6.$$

Điều này có nghĩa là chỉ cần 6 thành phần chính để bảo toàn trên 90% lượng phương sai của dữ liệu.

Đối với LDA, đây là phương pháp giảm chiều có giám sát vì sử dụng cả dữ liệu đầu vào X và nhãn mục tiêu y . Do bài toán **HeartDisease** chỉ có hai lớp **No** và **Yes**, số chiều tối đa sau LDA là:

$$C - 1 = 2 - 1 = 1,$$

trong đó C là số lớp. Vì vậy, LDA chỉ tạo ra một thành phần duy nhất, ký hiệu là LD_1 .

Để đánh giá khả năng phân tách lớp của LDA, nhóm sử dụng độ chênh lệch trung bình giữa hai lớp trên trục LD_1 :

$$\Delta_{\text{LDA}} = |\mu_{\text{Yes}} - \mu_{\text{No}}|,$$

trong đó:

$$\mu_{\text{Yes}} = \frac{1}{n_{\text{Yes}}} \sum_{i:y_i=1} LD_1^{(i)}$$

là giá trị trung bình của lớp `HeartDisease = Yes` trên trục LD_1 , và

$$\mu_{\text{No}} = \frac{1}{n_{\text{No}}} \sum_{i:y_i=0} LD_1^{(i)}$$

là giá trị trung bình của lớp `HeartDisease = No` trên trục LD_1 .

Trong thực nghiệm, nhóm thu được:

$$\mu_{\text{No}} \approx -0.1274, \quad \mu_{\text{Yes}} \approx 1.2830.$$

Do đó:

$$\Delta_{\text{LDA}} = |1.2830 - (-0.1274)| \approx 1.4104.$$

Giá trị này cho thấy trên trục LD_1 , trung bình của hai lớp có sự tách biệt rõ hơn so với dữ liệu gốc. Tuy nhiên, độ chênh lệch trung bình không đồng nghĩa với việc hai lớp được phân tách hoàn toàn, vì phân phối của hai lớp vẫn có thể chồng lấn trên cùng một khoảng giá trị.

Nhận xét:

- PCA là phương pháp không giám sát, tập trung vào việc bảo toàn phương sai của dữ liệu. Kết quả cho thấy PCA cần 6 thành phần chính để giữ lại trên 90% phương sai, giúp giảm số chiều từ 25 xuống còn 6.
- LDA là phương pháp có giám sát, sử dụng nhãn `HeartDisease` để tìm hướng chiếu giúp phân biệt hai lớp. Với bài toán nhị phân, LDA chỉ tạo ra một trục LD_1 , nhưng trục này cho thấy trung bình hai lớp cách nhau khoảng 1.4104 đơn vị.
- PCA phù hợp để phân tích lượng thông tin được bảo toàn và giảm số chiều, trong khi LDA phù hợp để đánh giá khả năng tách lớp khi có nhãn. Do đó, hai phương pháp cung cấp hai góc nhìn khác nhau về dữ liệu sau tiền xử lý.

2.2.4 Phân cụm dữ liệu bằng DBSCAN

Sau khi hoàn thành bước tiền xử lý dữ liệu, nghiên cứu tiếp tục thực hiện phân cụm nhằm khám phá cấu trúc tự nhiên của các mẫu dữ liệu đầu vào. Phương pháp được sử dụng là DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*), một thuật toán phân cụm dựa trên mật độ.

Khác với bài toán phân loại, phân cụm là phương pháp học không giám sát. Vì vậy, trong quá trình phân cụm, biến mục tiêu `HeartDisease` không được sử dụng làm đầu vào cho thuật toán. Thuật toán chỉ sử dụng các đặc trưng sau tiền xử lý để tìm ra các nhóm dữ liệu có mật độ cao trong không gian đặc trưng. Sau khi phân cụm xong, nhãn `HeartDisease` mới được sử dụng để đánh giá mối quan hệ giữa các cụm và nhãn thực tế.

Dữ liệu đầu vào cho DBSCAN được tạo bằng cách ghép tập train và test của kịch bản chia dữ liệu 80/20:

$$X_{\text{cluster}} = X_{\text{train}} \cup X_{\text{test}}.$$

Tập nhãn tương ứng **HeartDisease** được lưu riêng và chỉ dùng cho bước đánh giá sau phân cụm:

$$y_{\text{cluster}} = y_{\text{train}} \cup y_{\text{test}}.$$

Do bộ dữ liệu có kích thước lớn, để cân bằng giữa chi phí tính toán và lượng thông tin sử dụng, nghiên cứu giới hạn số mẫu dùng cho DBSCAN là:

$$n_{\text{sample}} = 50000.$$

Việc sử dụng 50000 mẫu giúp thuật toán chạy ổn định hơn trên máy cá nhân, đồng thời vẫn giữ được số lượng mẫu đủ lớn để quan sát cấu trúc cụm tổng quát của dữ liệu.

Trước khi áp dụng DBSCAN, dữ liệu được giảm xuống không gian hai chiều bằng PCA:


$$X_{\text{PCA-2D}} \in \mathbb{R}^{n \times 2}.$$

Việc giảm chiều về hai thành phần chính giúp trực quan hóa kết quả phân cụm trên mặt phẳng hai chiều và giảm chi phí tính toán khi chạy DBSCAN. Sau đó, dữ liệu PCA hai chiều tiếp tục được chuẩn hóa bằng **StandardScaler** trước khi đưa vào thuật toán DBSCAN.

DBSCAN sử dụng hai tham số chính là ε và **min_samples**. Trong đó, ε là bán kính lân cận, còn **min_samples** là số lượng điểm tối thiểu cần có trong vùng lân cận để một điểm được xem là điểm lõi (*core point*). Trong thực nghiệm này, nghiên cứu đặt:

$$\text{min_samples} = 20.$$

Để hỗ trợ lựa chọn tham số ε , nghiên cứu sử dụng biểu đồ *k-distance plot*. Với mỗi điểm dữ liệu, khoảng cách đến láng giềng gần thứ 20 được tính toán và sắp xếp tăng dần. Vị trí mà đường cong bắt đầu tăng mạnh có thể được xem là vùng gợi ý để lựa chọn giá trị ε phù hợp.



Hình 2.14: Biểu đồ k-distance hỗ trợ lựa chọn tham số ε cho DBSCAN

Sau đó, nghiên cứu thử nghiệm nhiều giá trị ε khác nhau:

$$\varepsilon \in \{0.15, 0.20, 0.25, 0.30, 0.35, 0.40, 0.50, 0.60\}.$$

Với mỗi giá trị ε , DBSCAN được huấn luyện và đánh giá thông qua các độ đo định lượng gồm:

- Số cụm được tạo ra.
- Tỷ lệ điểm nhiễu (*noise ratio*).
- Silhouette Score.
- Davies-Bouldin Score.
- Calinski-Harabasz Score.
- Adjusted Rand Index so với nhãn **HeartDisease**.
- Normalized Mutual Information so với nhãn **HeartDisease**.
- Cluster Purity so với nhãn **HeartDisease**.

Trong đó, Silhouette Score, Davies-Bouldin Score và Calinski-Harabasz Score được dùng để đánh giá chất lượng cụm dựa trên cấu trúc dữ liệu. Adjusted Rand Index, Normalized Mutual Information và Cluster Purity được dùng để đánh giá mức độ liên hệ giữa nhãn cụm do DBSCAN sinh ra và nhãn thực tế **HeartDisease**.

Giá trị ε tốt nhất được lựa chọn dựa trên các điều kiện:

- Số cụm tạo ra phải lớn hơn hoặc bằng 2.
- Tỷ lệ điểm nhiễu không vượt quá 60%.
- Silhouette Score phải xác định được.
- Trong các ứng viên thỏa mãn điều kiện trên, ưu tiên giá trị có Silhouette Score cao hơn và noise ratio thấp hơn.

Sau khi lựa chọn được giá trị ε phù hợp, DBSCAN được chạy lại trên dữ liệu PCA hai chiều để tạo nhãn cụm cuối cùng:


$$c_i \in \{-1, 0, 1, 2, \dots, K-1\},$$

trong đó $c_i = -1$ biểu diễn điểm nhiễu, còn các giá trị $0, 1, \dots, K-1$ biểu diễn các cụm được phát hiện bởi DBSCAN.

Kết quả phân cụm được tổng hợp bằng ba bảng chính. Thứ nhất là bảng số lượng mẫu trong từng cụm, cho biết mỗi cụm có bao nhiêu điểm dữ liệu và có bao nhiêu điểm bị xem là nhiễu. Thứ hai là bảng chéo giữa nhãn cụm và nhãn **HeartDisease**, cho biết trong từng cụm có bao nhiêu mẫu thuộc lớp **No** và bao nhiêu mẫu thuộc lớp **Yes**. Thứ ba là bảng tỷ lệ nhãn trong từng cụm, giúp đánh giá cụm nào có tỷ lệ mẫu mắc bệnh tim cao hơn.

Để trực quan hóa kết quả, nghiên cứu biểu diễn các mẫu dữ liệu trên mặt phẳng PCA hai chiều. Trong biểu đồ, màu sắc thể hiện nhãn cụm do DBSCAN sinh ra, còn hình dạng điểm thể hiện nhãn thực tế **HeartDisease**. Cách biểu diễn này cho phép quan sát đồng thời cấu trúc cụm và sự phân bố của hai lớp bệnh tim trong từng cụm.


Ngoài ra, nghiên cứu cũng sử dụng heatmap biểu diễn tỷ lệ **HeartDisease** trong từng cụm. Biểu đồ này giúp đánh giá cụm nào có xu hướng chứa nhiều mẫu **HeartDisease = Yes** hơn so với các cụm còn lại.



Hình 2.15: Trực quan hóa các cụm DBSCAN trên không gian PCA hai chiều

Nhận xét và đánh giá:

- DBSCAN được sử dụng trong nghiên cứu này nhằm khám phá cấu trúc nhóm tự nhiên của dữ liệu sau tiền xử lý, không nhằm thay thế trực tiếp các mô hình phân loại có giám sát.
- Việc loại bỏ biến **HeartDisease** khỏi dữ liệu đầu vào đảm bảo rằng quá trình phân cụm được thực hiện đúng theo bản chất học không giám sát. Nhãn **HeartDisease** chỉ được dùng sau khi phân cụm để đánh giá mối quan hệ giữa cụm và đầu ra thực tế.
- PCA hai chiều giúp giảm chi phí tính toán và hỗ trợ trực quan hóa kết quả phân cụm. Tuy nhiên, do PCA chỉ giữ lại hai chiều đầu tiên, một phần thông tin từ không gian đặc trưng gốc có thể bị mất đi.
- Các độ đo như Silhouette Score, Davies-Bouldin Score và Calinski-Harabasz Score giúp đánh giá mức độ tách biệt và độ chặt của các cụm. Trong khi đó, ARI, NMI và Purity giúp đánh giá xem cấu trúc cụm có liên hệ với nhãn **HeartDisease** hay không.
- Nếu các cụm có tỉ lệ **HeartDisease = Yes** khác nhau rõ rệt, điều này cho thấy một số nhóm dữ liệu có thể chứa các đặc điểm sức khỏe liên quan nhiều hơn đến nguy cơ bệnh tim. Ngược lại, nếu hai nhãn **No** và **Yes** bị trộn lẫn trong hầu hết các cụm, điều đó cho thấy cấu trúc cụm tự nhiên của dữ liệu chưa phản ánh rõ ràng nhãn bệnh tim.
- Nhìn chung, DBSCAN trong báo cáo này đóng vai trò là công cụ phân tích khám phá dữ liệu. Kết quả phân cụm giúp bổ sung góc nhìn về cấu trúc dữ liệu, nhưng việc dự đoán **HeartDisease** vẫn cần được thực hiện bằng các mô hình phân loại có giám sát như KNN, Logistic Regression và Soft Margin SVM.



Hình 2.16: Tỷ lệ nhân `HeartDisease` trong từng cụm DBSCAN

2.3 Phương pháp thí nghiệm phân loại

2.3.1 Lựa chọn mô hình

Trong nghiên cứu này, nhóm sử dụng ba mô hình phân loại gồm KNN, Logistic Regression và Soft Margin SVM để dự đoán biến mục tiêu `HeartDisease`.

- **KNN** được dùng như một mô hình cơ bản dựa trên khoảng cách giữa các mẫu dữ liệu.
- **Logistic Regression** được dùng như một mô hình phân loại tuyến tính có khả năng ước lượng xác suất thuộc lớp `HeartDisease = Yes`.
- **Soft Margin SVM** được sử dụng nhằm tìm siêu phẳng phân tách hai lớp với khoảng cách lề lớn nhất.

Các mô hình được huấn luyện trên ba dạng dữ liệu: dữ liệu gốc sau tiền xử lý (**RAW**), dữ liệu giảm chiều bằng PCA và dữ liệu giảm chiều bằng LDA. Đồng thời, nghiên cứu đánh giá các mô hình trên nhiều tỷ lệ chia train/test gồm 80/20, 70/30 và 60/40. Cách thiết kế này giúp so sánh hiệu quả giữa mô hình dựa trên khoảng cách và các mô hình tuyến tính, cũng như đánh giá ảnh hưởng của giảm chiều dữ liệu đến chất lượng phân loại.

2.3.2 Kịch bản thí nghiệm

Để đánh giá ảnh hưởng của dạng biểu diễn dữ liệu và tỷ lệ chia train/test, nghiên cứu xây dựng các kịch bản thí nghiệm dựa trên ba loại dữ liệu đầu vào và ba cách chia dữ liệu khác nhau. Các thí nghiệm được thực hiện nhằm so sánh hiệu quả phân loại giữa dữ liệu gốc sau tiền xử lý, dữ liệu giảm chiều bằng PCA và dữ liệu giảm chiều bằng LDA.

Ba loại dữ liệu đầu vào Với mỗi cách chia dữ liệu, các mô hình được huấn luyện và đánh giá trên ba phiên bản đặc trưng khác nhau:

1. **Dữ liệu gốc sau tiền xử lý (RAW):** sử dụng trực tiếp ma trận đặc trưng sau khi đã hoàn thành các bước làm sạch dữ liệu, xử lý ngoại lệ, chuẩn hóa các cột số và mã hóa các biến phân loại. Đây là bộ dữ liệu giữ lại đầy đủ các đặc trưng sau tiền xử lý và được dùng làm mốc so sánh với các dữ liệu đã giảm chiều.
2. **Dữ liệu sau PCA (PCA):** áp dụng PCA trên tập huấn luyện sau tiền xử lý với cấu hình:

$$n_components = 0.90.$$

Điều này có nghĩa là PCA tự động chọn số lượng thành phần chính sao cho tổng phương sai được giữ lại đạt ít nhất 90%. Theo kết quả thực nghiệm trong bài toán này, với dữ liệu sau tiền xử lý gồm 25 đặc trưng, PCA cần 6 thành phần chính để giữ được khoảng 91.35% phương sai. Dữ liệu sau PCA được dùng để đánh giá xem việc giảm chiều có ảnh hưởng như thế nào đến hiệu quả của các mô hình phân loại.

3. **Dữ liệu sau LDA (LDA):** áp dụng LDA trên tập huấn luyện sau tiền xử lý. Do bài toán `HeartDisease` là bài toán phân loại nhị phân gồm hai lớp `No` và `Yes`, số chiều tối đa sau LDA là:

$$C - 1 = 2 - 1 = 1.$$

Vì vậy, dữ liệu sau LDA chỉ gồm một đặc trưng mới duy nhất, ký hiệu là LD_1 . Trục LD_1 được xây dựng nhằm tối đa hóa khả năng phân biệt giữa hai lớp, do đó được sử dụng để so sánh với dữ liệu gốc và dữ liệu PCA.

Ba tỉ lệ chia train/test Mỗi loại dữ liệu đầu vào trên được thử nghiệm dưới ba kịch bản chia train/test khác nhau:

- **Chia 80/20:** 80% dữ liệu được dùng để huấn luyện và 20% dữ liệu được dùng để kiểm tra.
- **Chia 70/30:** 70% dữ liệu được dùng để huấn luyện và 30% dữ liệu được dùng để kiểm tra.
- **Chia 60/40:** 60% dữ liệu được dùng để huấn luyện và 40% dữ liệu được dùng để kiểm tra.

Trong tất cả các trường hợp, tham số `stratify = y` trong hàm `train_test_split` được sử dụng để giữ tỉ lệ hai lớp `HeartDisease = No` và `HeartDisease = Yes` tương đối ổn định giữa tập huấn luyện và tập kiểm tra. Điều này đặc biệt quan trọng vì dữ liệu có hiện tượng mất cân bằng lớp, trong đó lớp `No` chiếm đa số so với lớp `Yes`.

Ngoài ra, các phép biến đổi dữ liệu như chuẩn hóa, PCA và LDA đều được học (`fit`) trên tập huấn luyện, sau đó mới được áp dụng (`transform`) cho tập kiểm tra tương ứng. Cách thực hiện này giúp tránh hiện tượng rò rỉ thông tin (*data leakage*), đảm bảo rằng tập kiểm tra không tham gia vào quá trình học các tham số tiền xử lý hoặc giảm chiều.

Với mỗi tổ hợp giữa loại dữ liệu đầu vào và tỉ lệ chia train/test, các mô hình phân loại KNN, Logistic Regression và Soft Margin SVM được huấn luyện và đánh giá. Kết quả thu được được sử dụng để so sánh hiệu quả giữa các mô hình, đánh giá ảnh hưởng của giảm chiều dữ liệu và xem xét độ ổn định của mô hình dưới các tỉ lệ chia dữ liệu khác nhau.

2.3.3 Phương pháp đánh giá mô hình

Hiệu năng của các mô hình phân loại gồm KNN, Logistic Regression và Soft Margin SVM được đánh giá bằng các độ đo chuẩn trong bài toán phân loại nhị phân. Do biến mục tiêu **HeartDisease** gồm hai lớp **No** và **Yes**, trong đó lớp **Yes** được xem là lớp dương, các độ đo đánh giá được sử dụng bao gồm:

- **Ma trận nhầm lẫn** (*Confusion Matrix*): biểu diễn số lượng dự đoán đúng và sai của mô hình theo từng lớp, gồm bốn thành phần: True Positive (TP), True Negative (TN), False Positive (FP) và False Negative (FN).

- **Accuracy**: đo tỉ lệ dự đoán đúng trên toàn bộ tập kiểm tra:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}.$$

- **Precision**: đo trong số các mẫu được dự đoán là có bệnh, có bao nhiêu mẫu thật sự thuộc lớp có bệnh:

$$Precision = \frac{TP}{TP + FP}.$$

- **Recall**: đo trong số các mẫu thật sự có bệnh, mô hình phát hiện đúng được bao nhiêu mẫu:

$$Recall = \frac{TP}{TP + FN}.$$

- **F1-Score**: là trung bình điều hòa giữa Precision và Recall:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}.$$

- **ROC-AUC**: là diện tích dưới đường cong ROC, phản ánh khả năng phân biệt hai lớp của mô hình khi thay đổi ngưỡng quyết định. Giá trị ROC-AUC càng gần 1 cho thấy mô hình càng có khả năng phân tách tốt giữa hai lớp **No** và **Yes**.

- **Overfit Gap**: được tính bằng hiệu giữa Accuracy trên tập huấn luyện và Accuracy trên tập kiểm tra:

$$Overfit\ Gap = Accuracy_{train} - Accuracy_{test}.$$

Chỉ số này được sử dụng để đánh giá mức độ chênh lệch hiệu năng giữa tập train và test. Nếu khoảng chênh lệch lớn, mô hình có thể có dấu hiệu overfitting.

Do dữ liệu **HeartDisease** có hiện tượng mất cân bằng lớp, trong đó số mẫu thuộc lớp **No** lớn hơn đáng kể so với lớp **Yes**, chỉ số Accuracy không đủ để đánh giá toàn diện hiệu năng mô hình. Một mô hình có thể đạt Accuracy cao bằng cách dự đoán phần lớn mẫu thuộc lớp **No**, nhưng vẫn phát hiện kém các trường hợp thật sự mắc bệnh tim.

Vì vậy, trong nghiên cứu này, các chỉ số Precision, Recall, F1-Score và ROC-AUC được xem xét cùng với Accuracy. Đặc biệt, Recall của lớp **Yes** có ý nghĩa quan trọng vì nó phản ánh khả năng mô hình phát hiện đúng các cá nhân có nguy cơ mắc bệnh tim. Ngoài ra, F1-Score giúp cân bằng giữa Precision và Recall, còn ROC-AUC cho biết khả năng phân biệt hai lớp dưới nhiều ngưỡng quyết định khác nhau.

Các độ đo trên được tính cho từng mô hình, từng dạng dữ liệu đầu vào (**RAW**, **PCA**, **LDA**) và từng tỉ lệ chia train/test (80/20, 70/30, 60/40). Việc đánh giá theo nhiều kịch bản giúp so sánh mức độ ổn định, khả năng tổng quát hóa và hiệu quả xử lý dữ liệu mất cân bằng của từng mô hình phân loại.

CHƯƠNG 3

So sánh và đánh giá kết quả thực nghiệm

3.1 Tổng quan các thí nghiệm

Dựa trên khung kiến thức đã nêu ở chương 2, chương này trình bày và phân tích kết quả thực nghiệm trên bộ dữ liệu Heart Disease 2020. Sau khi dữ liệu được làm sạch, loại bỏ trùng lặp, xử lý ngoại lệ bằng capping, chuẩn hóa các cột số và mã hóa các biến phân loại, nhóm tiến hành đánh giá mô hình theo hai hướng chính: phân loại bệnh tim và hồi quy trên điểm số dự đoán.

Trong bài toán phân loại, nhóm sử dụng ba mô hình:

- **K-Nearest Neighbors (KNN):** mô hình phi tham số, phân loại dựa trên độ gần giữa các mẫu dữ liệu.
- **Logistic Regression:** mô hình phân loại tuyến tính, ước lượng xác suất một mẫu thuộc lớp có bệnh tim.
- **Linear Support Vector Machine (Soft Margin SVM):** mô hình phân loại tuyến tính theo nguyên lý cực đại hóa lề, có sử dụng soft-margin để xử lý dữ liệu không phân tách tuyến tính hoàn toàn.

Các mô hình được đánh giá trên ba dạng dữ liệu đầu vào:

- **RAW:** dữ liệu gốc sau tiền xử lý, chuẩn hóa các biến số và mã hóa các biến phân loại.
- **PCA:** dữ liệu sau khi giảm chiều bằng PCA, giữ lại tối thiểu 90% phương sai. Trong báo cáo hiện tại, PCA cần 6 thành phần chính để bảo toàn mức thông tin này.
- **LDA:** dữ liệu sau khi giảm chiều bằng Linear Discriminant Analysis. Do bài toán có hai lớp, LDA chỉ tạo ra 1 thành phần phân biệt.

Mỗi mô hình được đánh giá với ba tỉ lệ chia dữ liệu:

80/20, 70/30, 60/40.

Trong tất cả các trường hợp, dữ liệu được chia có phân tầng theo nhãn `HeartDisease` để giữ ổn định tỉ lệ hai lớp giữa tập huấn luyện và tập kiểm tra.

Các độ đo đánh giá gồm Accuracy, Precision, Recall, F1-score, ROC-AUC và Overfit Gap. Ngoài bảng chỉ số, notebook cũng trực quan hóa kết quả bằng ma trận nhầm lẫn, đường cong ROC-AUC, biểu đồ PCA, biểu đồ LDA, biểu đồ Overfit Gap và biểu đồ hồi quy score. Do bộ dữ liệu bị mất cân bằng lớp, trong đó số mẫu không mắc bệnh tim lớn hơn nhiều so với số mẫu mắc bệnh tim, nhóm ưu tiên phân tích Recall, F1-score và ROC-AUC thay vì chỉ dựa vào Accuracy.

3.2 Kết quả phân loại trên dữ liệu gốc đã tiền xử lý

3.2.1 Bảng kết quả

Bảng 3.1 trình bày kết quả của ba mô hình trên dữ liệu RAW. Đây là dữ liệu đã trải qua toàn bộ quá trình tiền xử lý nhưng chưa giảm chiều, do đó được xem là mốc tham chiếu chính.

Mô hình	Split	Test Acc	Gap	Precision	Recall	F1	AUC
KNN	80/20	0.9045	0.0950	0.3194	0.0509	0.0878	0.7690
Logistic Regression	80/20	0.7431	0.0012	0.2275	0.7696	0.3512	0.8324
Soft Margin SVM	80/20	0.7381	0.0009	0.2256	0.7808	0.3501	0.8323
KNN	70/30	0.9049	0.0946	0.3435	0.0583	0.0997	0.7633
Logistic Regression	70/30	0.7427	0.0021	0.2271	0.7689	0.3507	0.8324
Soft Margin SVM	70/30	0.7376	0.0021	0.2247	0.7773	0.3486	0.8322
KNN	60/40	0.9046	0.0948	0.3155	0.0480	0.0833	0.7617
Logistic Regression	60/40	0.7426	0.0035	0.2272	0.7694	0.3508	0.8321
Soft Margin SVM	60/40	0.7370	0.0039	0.2240	0.7760	0.3477	0.8320

Bảng 3.1: Kết quả phân loại trên dữ liệu RAW

3.2.2 Nhận xét

Trên dữ liệu RAW, Logistic Regression và Soft Margin SVM đạt hiệu quả tốt nhất về ROC-AUC, đều xấp xỉ 0.83. Đây là mức cao nhất trong các thí nghiệm phân loại, cho thấy dữ liệu gốc sau tiền xử lý vẫn giữ lại nhiều thông tin hữu ích cho việc dự đoán bệnh tim.

KNN có Accuracy cao nhất, khoảng 0.90, nhưng Recall rất thấp, chỉ khoảng 0.05. Điều này cho thấy mô hình chủ yếu dự đoán đúng lớp đa số là No, nhưng bỏ sót nhiều mẫu thuộc lớp Yes. Trong bài toán y tế, Recall thấp là hạn chế nghiêm trọng vì mô hình có thể bỏ qua nhiều người thực sự có nguy cơ mắc bệnh tim. Đường cong ROC cũng cho thấy KNN có AUC thấp hơn Logistic Regression và Soft Margin SVM.

Logistic Regression và Soft Margin SVM có Accuracy thấp hơn KNN, nhưng Recall cao hơn rất nhiều, dao động khoảng 0.77–0.78. Điều này phù hợp hơn với mục tiêu sàng lọc bệnh tim, vì mô hình cần ưu tiên phát hiện đúng người có bệnh.

3.3 Kết quả phân loại trên dữ liệu sau PCA

3.3.1 Bảng kết quả

Bảng 3.2 trình bày kết quả của các mô hình trên dữ liệu sau PCA. Trong báo cáo hiện tại, PCA giữ lại 90% phương sai và cần 6 thành phần chính.

Mô hình	Split	Test Acc	Gap	Precision	Recall	F1	AUC
KNN	80/20	0.9039	0.0955	0.3147	0.0539	0.0920	0.7528
Logistic Regression	80/20	0.7088	0.0033	0.2039	0.7650	0.3219	0.8073
Soft Margin SVM	80/20	0.6996	0.0038	0.2003	0.7771	0.3186	0.8073
KNN	70/30	0.9050	0.0945	0.3077	0.0413	0.0729	0.7430
Logistic Regression	70/30	0.7100	0.0035	0.2035	0.7587	0.3210	0.8071
Soft Margin SVM	70/30	0.7013	0.0033	0.2006	0.7729	0.3186	0.8071
KNN	60/40	0.9064	0.0930	0.3600	0.0465	0.0824	0.7497
Logistic Regression	60/40	0.7102	0.0029	0.2045	0.7636	0.3226	0.8077
Soft Margin SVM	60/40	0.7009	0.0032	0.2010	0.7767	0.3194	0.8078

Bảng 3.2: Kết quả phân loại trên dữ liệu PCA giữ lại 90% phương sai

3.3.2 Nhận xét

Sau khi áp dụng PCA, ROC–AUC của Logistic Regression và Soft Margin SVM giảm từ khoảng 0.832 xuống khoảng 0.807. Điều này cho thấy quá trình giảm chiều đã làm mất một phần thông tin có ích cho phân loại. Tuy nhiên, Recall của hai mô hình tuyến tính vẫn duy trì ở mức cao, khoảng 0.76–0.78.

KNN vẫn giữ Accuracy cao nhưng Recall tiếp tục rất thấp. Điều này cho thấy PCA chưa khắc phục được hạn chế chính của KNN trong bài toán dữ liệu mất cân bằng.

Về mặt ý nghĩa, PCA giúp rút gọn không gian đặc trưng và hỗ trợ trực quan hóa cấu trúc dữ liệu. Tuy nhiên, vì PCA là phương pháp không giám sát, nó chỉ tối ưu theo phương sai của dữ liệu chứ không tối ưu trực tiếp khả năng phân tách hai lớp **HeartDisease**. Do đó, việc giảm chiều bằng PCA làm mô hình nhẹ hơn nhưng không nhất thiết làm tăng chất lượng phân loại.

3.4 Kết quả phân loại trên dữ liệu sau LDA

3.4.1 Bảng kết quả

Bảng 3.3 trình bày kết quả của các mô hình trên dữ liệu sau LDA. Vì bài toán chỉ có hai lớp, LDA giảm dữ liệu về một chiều duy nhất.

Mô hình	Split	Test Acc	Gap	Precision	Recall	F1	AUC
KNN	80/20	0.8882	0.1113	0.2646	0.1336	0.1775	0.7417
Logistic Regression	80/20	0.7732	-0.0002	0.2413	0.7043	0.3594	0.8246
Soft Margin SVM	80/20	0.7800	0.0003	0.2447	0.6880	0.3610	0.8246
KNN	70/30	0.8892	0.1103	0.2923	0.1594	0.2063	0.7407
Logistic Regression	70/30	0.7722	0.0015	0.2405	0.7052	0.3587	0.8246
Soft Margin SVM	70/30	0.7791	0.0019	0.2442	0.6900	0.3607	0.8246
KNN	60/40	0.8858	0.1136	0.2528	0.1351	0.1760	0.7389
Logistic Regression	60/40	0.7717	0.0020	0.2406	0.7081	0.3591	0.8248
Soft Margin SVM	60/40	0.7783	0.0027	0.2443	0.6945	0.3615	0.8248

Bảng 3.3: Kết quả phân loại trên dữ liệu LDA 1D

3.4.2 Nhận xét

LDA cho kết quả đáng chú ý vì chỉ sử dụng một chiều dữ liệu nhưng Logistic Regression và Soft Margin SVM vẫn đạt ROC–AUC khoảng 0.824–0.825, gần với kết quả trên dữ liệu RAW. Điều này cho thấy LDA đã tìm được một trục chiếu có khả năng tách biệt tương đối tốt giữa hai lớp. Biểu đồ phân phối LD1 giúp quan sát trực tiếp mức độ dịch chuyển giữa nhóm không mắc bệnh và nhóm mắc bệnh.

Tuy nhiên, Recall trên dữ liệu LDA thấp hơn so với dữ liệu RAW. Điều này là hợp lý vì khi nén dữ liệu về một chiều, một phần thông tin chi tiết từ các đặc trưng ban đầu bị mất đi.

KNN trên LDA có Recall cao hơn so với RAW và PCA nhưng vẫn thấp hơn nhiều so với Logistic Regression và Soft Margin SVM. Đồng thời, Overfit Gap của KNN trên LDA là lớn nhất, trên 0.11, cho thấy mô hình vẫn có hiện tượng học quá sát dữ liệu huấn luyện.

3.5 So sánh tổng hợp giữa các mô hình

3.5.1 Bảng các mô hình có ROC–AUC cao nhất

Mô hình	Dữ liệu	Split	Test Acc	Recall	F1	AUC
Logistic Regression	RAW	80/20	0.7431	0.7696	0.3512	0.8324
Logistic Regression	RAW	70/30	0.7427	0.7689	0.3507	0.8324
Soft Margin SVM	RAW	80/20	0.7381	0.7808	0.3501	0.8323
Soft Margin SVM	RAW	70/30	0.7376	0.7773	0.3486	0.8322
Logistic Regression	RAW	60/40	0.7426	0.7694	0.3508	0.8321
Soft Margin SVM	RAW	60/40	0.7370	0.7760	0.3477	0.8320
Logistic Regression	LDA	60/40	0.7717	0.7081	0.3591	0.8248
Soft Margin SVM	LDA	60/40	0.7783	0.6945	0.3615	0.8248


Bảng 3.4: Các cấu hình mô hình có ROC–AUC cao nhất

3.5.2 Bảng đánh giá overfit

Mô hình	Dữ liệu	Split	Train Acc	Test Acc	Gap	AUC
KNN	LDA	60/40	0.9994	0.8858	0.1136	0.7389
KNN	LDA	80/20	0.9995	0.8882	0.1113	0.7417
KNN	LDA	70/30	0.9995	0.8892	0.1103	0.7407
KNN	PCA	80/20	0.9995	0.9039	0.0955	0.7528
KNN	RAW	80/20	0.9995	0.9045	0.0950	0.7690
KNN	RAW	60/40	0.9994	0.9046	0.0948	0.7617

Bảng 3.5: Các cấu hình có Overfit Gap lớn nhất

3.5.3 Ma trận nhầm lẫn



Hình 3.1: Ma trận nhầm lẫn của KNN, Logistic Regression và Soft Margin SVM trên dữ liệu RAW với tỉ lệ 80/20

Nhận xét:

Ma trận nhầm lẫn cho thấy KNN dự đoán đúng nhiều mẫu thuộc lớp **No**, do đó đạt Accuracy cao. Tuy nhiên, mô hình phát hiện rất ít mẫu thuộc lớp **Yes**, thể hiện qua Recall thấp. Điều này cho thấy KNN có xu hướng thiên về lớp đa số và bỏ sót nhiều trường hợp mắc bệnh tim.

Logistic Regression và Soft Margin SVM có số lượng dự đoán đúng lớp **Yes** cao hơn KNN. Mặc dù Accuracy tổng thể thấp hơn, hai mô hình này phù hợp hơn với bài toán y tế vì giảm được số trường hợp mắc bệnh nhưng bị dự đoán nhầm là không mắc bệnh.

Nhìn chung, trong bài toán dự đoán bệnh tim, Logistic Regression và Soft Margin SVM đáng tin cậy hơn KNN nếu ưu tiên khả năng phát hiện người có nguy cơ mắc bệnh.

3.5.4 Nhận xét tổng hợp

Từ các bảng kết quả, có thể thấy Logistic Regression và Soft Margin SVM là hai mô hình ổn định nhất. Cả hai mô hình đều có ROC–AUC cao trên dữ liệu RAW và LDA, đồng thời Overfit Gap rất nhỏ. Điều này cho thấy hai mô hình tuyến tính có khả năng khái quát tốt trên bộ dữ liệu đã tiền xử lý. Kết quả này cũng phù hợp với đường cong ROC–AUC được vẽ trong notebook, trong đó Logistic Regression và Soft Margin SVM nằm cao hơn đường baseline ngẫu nhiên và cao hơn KNN.

KNN có Accuracy cao nhưng không phù hợp làm mô hình chính cho bài toán này vì Recall thấp và Overfit Gap cao. Accuracy cao của KNN chủ yếu đến từ việc dự đoán tốt lớp đa số **No**, trong khi khả năng phát hiện lớp **Yes** còn hạn chế. Vì vậy, KNN trong báo cáo này phù hợp hơn với vai trò mô hình cơ bản để kiểm thử, không phải mô hình tối ưu cuối cùng.

Dữ liệu RAW cho kết quả phân loại tốt nhất. PCA giúp giảm chiều nhưng làm giảm nhẹ ROC–AUC. LDA cho kết quả khá tốt dù chỉ còn một chiều, chứng tỏ trực LDA đã giữ được nhiều thông tin phân biệt giữa hai lớp. Tuy nhiên, nếu mục tiêu chính là tối ưu hiệu năng dự đoán, dữ liệu RAW vẫn là lựa chọn phù hợp nhất trong báo cáo hiện tại.

3.6 Hồi quy trên điểm số dự đoán

3.6.1 Mục tiêu

Theo yêu cầu của bài toán, nhóm lựa chọn mô hình thuộc Nhóm 2 và Nhóm 3, sau đó dựa vào giá trị score của mô hình để chuyển bài toán phân loại sang hồi quy. Cụ thể, báo cáo sử dụng Logistic Regression thuộc Nhóm 2 và Soft Margin SVM thuộc Nhóm 3 để tạo biến mục tiêu liên tục.

Với Logistic Regression, score được chọn là xác suất dự đoán lớp có bệnh:

$$s_{\text{Logistic}}(\mathbf{x}) = P(y = 1 \mid \mathbf{x}).$$

Với Soft Margin SVM, score được chọn là giá trị hàm quyết định:

$$s_{\text{SVM}}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b.$$


Hai loại score trên là giá trị liên tục, do đó có thể được xem như biến mục tiêu mới cho bài toán hồi quy. Sau đó, nhóm dùng Linear Regression và Ridge Regression để học lại mối quan hệ giữa dữ liệu đầu vào và score này.

3.6.2 Bảng kết quả hồi quy

Score nguồn	Dữ liệu đầu vào	Mô hình hồi quy	MAE	RMSE	R^2
Logistic probability score	Original processed features	Linear Regression	0.0461	0.0566	0.9548
Logistic probability score	Original processed features	Ridge Regression	0.0461	0.0566	0.9548
Logistic probability score	PCA 1/3 dimensions	Linear Regression	0.0635	0.0824	0.9042
Logistic probability score	PCA 1/3 dimensions	Ridge Regression	0.0635	0.0824	0.9042
Soft Margin SVM decision score	Original processed features	Linear Regression	0.0000	0.0000	1.0000
Soft Margin SVM decision score	Original processed features	Ridge Regression	0.0000	0.0000	1.0000
Soft Margin SVM decision score	PCA 1/3 dimensions	Linear Regression	0.0788	0.1171	0.9587
Soft Margin SVM decision score	PCA 1/3 dimensions	Ridge Regression	0.0788	0.1171	0.9587

Bảng 3.6: Kết quả hồi quy trên score của Logistic Regression và Soft Margin SVM

3.6.3 Trực quan hóa hồi quy score



Hình 3.2: So sánh score thực tế và score dự đoán của các mô hình hồi quy

3.6.4 Nhận xét

Kết quả hồi quy score cho thấy Linear Regression và Ridge Regression đều đạt R^2 rất cao. Với Logistic probability score trên dữ liệu gốc, R^2 đạt 0.9548, chứng tỏ mô hình hồi quy tuyến tính có thể xấp xỉ tốt xác suất đầu ra của Logistic Regression. Biểu đồ actual–predicted cho phép quan sát mức độ các điểm dự đoán bám sát đường lý tưởng, trong khi biểu đồ residual cho thấy phân phối sai số còn lại của mô hình.

Với Soft Margin SVM decision score trên dữ liệu gốc, $R^2 = 1.0000$. Nguyên nhân là score của Soft Margin SVM có dạng tuyến tính:

$$s_{\text{SVM}}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b.$$

Trong khi đó, Linear Regression cũng học một hàm tuyến tính theo đầu vào. Vì vậy, mô hình hồi quy có thể tái tạo gần như chính xác score do Soft Margin SVM sinh ra.

Khi giảm dữ liệu còn khoảng một phần ba số chiều bằng PCA, R^2 giảm so với dữ liệu gốc. Điều này cho thấy quá trình giảm chiều làm mất một phần thông tin cần thiết để tái tạo score. Tuy nhiên, R^2 vẫn lớn hơn 0.90, chứng tỏ dữ liệu sau giảm chiều vẫn giữ lại phần lớn cấu trúc quyết định của mô hình phân loại.

3.7 Kết luận chương

Qua các thí nghiệm, nhóm rút ra các kết luận chính:

- Logistic Regression và Soft Margin SVM là hai mô hình phân loại phù hợp nhất trong báo cáo hiện tại.
- KNN có ý nghĩa như một mô hình cơ bản để kiểm thử, nhưng không phù hợp làm mô hình chính do Recall thấp và có dấu hiệu overfit.
- Dữ liệu RAW sau tiền xử lý cho kết quả tốt nhất vì giữ lại đầy đủ thông tin đặc trưng.
- PCA giúp giảm số chiều và hỗ trợ trực quan hóa, nhưng làm giảm nhẹ hiệu năng phân loại.
- LDA cho thấy khả năng rút gọn dữ liệu tốt trong bài toán hai lớp, đặc biệt khi cần trực quan hóa hoặc mô hình đơn giản.
- Trong phần hồi quy score, Linear Regression và Ridge Regression tái tạo tốt score của Logistic Regression và Soft Margin SVM, đặc biệt là SVM score do bản chất tuyến tính của hàm quyết định.