

Đánh giá và so sánh các thuật toán phân loại trong việc nhận diện sớm bệnh tim mạch

Tiền xử lý, giảm chiều, phân cụm, phân loại và hồi quy score

Hoàng Danh Dũng (23000103)

Nguyễn Hữu Dũng (23000104)

Trường Đại học Khoa học Tự nhiên - ĐHQGHN

Ngày 23 tháng 5 năm 2026

Nội dung báo cáo

- 1 Tổng quan về bài toán
- 2 Tiền xử lý dữ liệu
- 3 Giảm chiều và phân cụm
- 4 Mô hình phân loại
- 5 Kết quả thực nghiệm
- 6 Hồi quy score
- 7 Kết luận

1. Tổng quan về bài toán

- **Đặt vấn đề:** Bệnh tim mạch (CVDs) là nguyên nhân gây tử vong hàng đầu thế giới. Việc chẩn đoán truyền thống tốn kém và thường phát hiện muộn
- **Mục tiêu đề tài:**
 - Xây dựng mô hình phân loại nhị phân dự báo sớm nguy cơ mắc bệnh
 - So sánh hiệu năng giữa **KNN**, **SVM** và **Logistic Regression**
 - Đánh giá tác động của kỹ thuật giảm chiều **PCA** và **LDA**
- **Câu hỏi:** Phương pháp giảm chiều và thuật toán nào hỗ trợ tốt hơn cho bài toán phân loại y tế?

Điểm cần giải quyết

Bài toán không chỉ cần dự đoán đúng nhiều mẫu, mà còn phải hạn chế bỏ sót người có bệnh trong nhóm Yes.

Cấu trúc dữ liệu

- Số bản ghi ban đầu: 319,795.
- Số cột ban đầu: 18.
- Số đặc trưng đầu vào: 17.
- Số biến mục tiêu: 1.
- Sau khi loại bỏ trùng lặp: 301,717 bản ghi.

Nhóm biến chính


- Biến số: BMI, PhysicalHealth, MentalHealth, SleepTime.
- Biến Yes/No: Smoking, Stroke, Asthma,...
- Biến thứ tự: AgeCategory, GenHealth.
- Biến danh mục: Race, Diabetic, Sex.

Ý nghĩa

Việc phân nhóm kiểu dữ liệu giúp chọn đúng kỹ thuật xử lý: cột số cần chuẩn hóa, biến thứ tự cần giữ quan hệ thứ bậc, còn biến danh mục cần one-hot.

Mất cân bằng lớp trong dữ liệu

- Sau khi loại bỏ trùng lặp:
 - Lớp No: khoảng 274,456 mẫu.
 - Lớp Yes: khoảng 27,261 mẫu.
- Tỷ lệ chênh lệch xấp xỉ 10 : 1.
- Nếu mô hình luôn dự đoán No, Accuracy vẫn có thể cao nhưng không phát hiện được người mắc bệnh.



Phân bố biến HeartDisease

Hệ quả đánh giá

Accuracy không đủ tin cậy. Cần ưu tiên **Recall**, **F1-score** và **ROC-AUC**, đặc biệt cho lớp Yes.


2. Kiểm tra dữ liệu ban đầu

- Kiểm tra:
 - số dòng, số cột;
 - tên cột và kiểu dữ liệu;
 - số lượng missing values;
 - số bản ghi trùng lặp;
 - phân bố biến mục tiêu.
- Bộ dữ liệu không có missing values, nhưng có các bản ghi trùng lặp hoàn toàn.
- Việc loại bỏ trùng lặp giúp giảm nguy cơ mô hình học lặp lại cùng một mẫu quá nhiều lần.

Mục đích kiểm tra ban đầu

Bước này giúp xác định dữ liệu có đủ sạch để phân tích tiếp hay cần xử lý lỗi trước khi chia train/test.

Trực quan hóa dữ liệu số ban đầu



Histogram và boxplot các cột số ban đầu

- Các cột số được quan sát gồm BMI, PhysicalHealth, MentalHealth, SleepTime.
- Histogram giúp nhìn phân phối tổng thể của từng biến.
- Boxplot giúp phát hiện giá trị ngoại lệ trước khi capping.
- Đây là cơ sở để chọn xử lý outlier bằng ngưỡng phân vị.
- Nếu phân phối lệch mạnh, các thuật toán dựa trên khoảng cách có thể bị ảnh hưởng.

Outlier và cách xác định

- Outlier là các giá trị nằm quá xa phần lớn dữ liệu.
- Các cột số được kiểm tra:

BMI, PhysicalHealth, MentalHealth, SleepTime

- Notebook dùng ngưỡng phân vị:

$$P_1 = Q_{0.01}, \quad P_{99} = Q_{0.99}$$

- Một giá trị được xem là outlier nếu:


$$x < P_1 \quad \text{hoặc} \quad x > P_{99}$$

Cách hiểu

Outlier ở đây là giá trị cực đoan theo phân vị, không nhất thiết là dữ liệu sai; vì vậy nhóm chọn capping thay vì xóa.

Boxplot trước khi capping

Pre-Capping Data (Gốc - Trước xử lý)



- Các điểm nằm xa hộp dữ liệu thể hiện những giá trị cực đoan.
- BMI và SleepTime có số lượng outlier đáng chú ý theo ngưỡng 1%-99%.
- PhysicalHealth và MentalHealth có miền giá trị hợp lệ từ 0 đến 30 nên không vượt ngưỡng phân vị.

Boxplot trước xử lý outlier

Thống kê outlier

Cột	Ngưỡng 1%	Ngưỡng 99%	outlier_count	Tỉ lệ
BMI	17.76	48.82	5,966	0.019773
PhysicalHealth	0.00	30.00	0	0.000000
MentalHealth	0.00	30.00	0	0.000000
SleepTime	3.00	12.00	2,338	0.007749
Tổng	–	–	8,304	–


- BMI có nhiều outlier nhất, cho thấy có các giá trị BMI quá thấp hoặc quá cao.
- SleepTime có một lượng outlier đáng kể ở các giá trị ngủ quá ít hoặc quá nhiều.
- PhysicalHealth và MentalHealth không có outlier theo ngưỡng 1%-99% vì ngưỡng trùng với miền giá trị hợp lệ 0 đến 30.

Capping outlier

- Dùng capping thay vì xóa dòng dữ liệu.
- Công thức:

$$x_{new} = \max(P_1, \min(x, P_{99}))$$

- Nếu giá trị nhỏ hơn ngưỡng 1%, thay bằng ngưỡng 1%.
- Nếu giá trị lớn hơn ngưỡng 99%, thay bằng ngưỡng 99%.



Boxplot sau capping

Lý do chọn capping

Capping giảm ảnh hưởng của giá trị cực đoan nhưng vẫn giữ lại bản ghi, phù hợp hơn việc xóa mẫu trong dữ liệu y tế.

Sau capping, phân phối bớt cực đoan hơn, giúp các bước chuẩn hóa và mô hình nhạy với khoảng cách ổn định hơn.

Chia train/test

Kịch bản	Tỉ lệ	Train	Test
1	80/20	241,373	60,344
2	70/30	211,201	90,516
3	60/40	181,030	120,687

- Sử dụng `stratify=y` để giữ tỉ lệ No/Yes tương đối ổn định.
- Chia train/test trước khi chuẩn hóa và mã hóa giúp tránh dùng thông tin từ test trong quá trình fit.
- Ba tỉ lệ giúp đánh giá độ ổn định của mô hình khi thay đổi lượng dữ liệu huấn luyện.

Điểm quan trọng

Nếu chuẩn hóa trước khi chia dữ liệu, thông tin thống kê của tập test có thể rò rỉ vào tập train và làm kết quả đánh giá lạc quan hơn thực tế.

- Báo cáo hiện tại chuẩn hóa riêng các cột số:

BMI, PhysicalHealth, MentalHealth, SleepTime

- Sử dụng StandardScaler:

$$x' = \frac{x - \mu}{\sigma}$$

- Scaler được fit trên tập train:

scaler.fit(X_{train})

- Tập test chỉ được transform:

scaler.transform(X_{test})

- Cách làm này giữ đúng nguyên tắc không rò rỉ dữ liệu.
- Bước này đặc biệt quan trọng với KNN, SVM, Logistic Regression và DBSCAN vì các mô hình này chịu ảnh hưởng bởi thang đo đặc trưng.

Mã hóa biến phân loại

- Sau khi chuẩn hóa cột số, mã hóa các biến còn lại.
- Các nhóm mã hóa:
 - Yes/No $\rightarrow$ 0/1.
 - Sex: Female/Male $\rightarrow$ 0/1.
 - AgeCategory: mã hóa theo thứ tự nhóm tuổi.
 - GenHealth: mã hóa theo thứ tự mức sức khỏe.
 - Race, Diabetic: one-hot encoding.

3. PCA: giảm chiều không giám sát

- PCA chỉ dùng ma trận đặc trưng X , không dùng nhãn HeartDisease.
- Mục tiêu là tìm các trục mới sao cho phương sai dữ liệu được giữ lại nhiều nhất.
- Trong bài toán, PCA được fit trên tập train đã tiền xử lý.
- Với:

$$n_components = 0.90$$

PCA tự chọn số thành phần chính để giữ ít nhất 90% phương sai.


- Kết quả hiện tại:

$$n_{90} = 6$$

Ý nghĩa

PCA giúp rút gọn dữ liệu nhưng không dùng nhãn, nên thành phần chính giữ nhiều phương sai chưa chắc là thành phần tách bệnh tốt nhất.


PCA: explained variance



Phương sai giải thích của các thành phần PCA

- Đường tích lũy cho biết tổng lượng thông tin được giữ lại.
- Ngưỡng 90% đạt được tại 6 thành phần chính.
- PCA được dùng để tạo bộ dữ liệu giảm chiều cho các mô hình phân loại.
- Khi giảm chiều, cần chấp nhận đánh đổi giữa tốc độ và lượng thông tin bị mất.

PCA: trực quan hóa các cặp thành phần



- Các cặp PC giúp quan sát cấu trúc dữ liệu sau khi chiếu xuống không gian thấp hơn.
- Hai lớp No/Yes vẫn chồng lấn đáng kể, nên PCA không tạo ranh giới phân loại rõ ràng.

Nhận xét chính

PCA hữu ích cho trực quan hóa, nhưng vì hai lớp còn chồng lấn nên vẫn cần mô hình phân loại có giám sát ở bước sau.

LDA: giảm chiều có giám sát

- LDA dùng cả đặc trưng X và nhãn y .
- Mục tiêu là tìm trục chiếu làm tăng khoảng cách giữa hai lớp và giảm độ phân tán trong từng lớp.
- Với bài toán có C lớp, số chiều tối đa sau LDA là:

$$C - 1$$

- Vì bài toán HeartDisease có hai lớp:


$$2 - 1 = 1$$

nên LDA chỉ tạo ra một thành phần LD1.

Khác biệt với PCA

LDA tối ưu hướng chiếu theo nhãn lớp, vì vậy phù hợp hơn PCA khi mục tiêu là tăng khả năng phân biệt No và Yes.

LDA: phân phối LD1



Phân phối dữ liệu sau LDA

- LDA tạo một trục LD1 tối ưu hơn cho phân tách hai lớp.
- Lớp Yes có xu hướng dịch sang vùng giá trị LD1 cao hơn.
- Vẫn có vùng chồng lấn, nên cần mô hình phân loại để đưa ra quyết định cuối cùng.

So sánh PCA và LDA

Tiêu chí	PCA	LDA
Loại phương pháp	Không giám sát	Có giám sát
Dữ liệu sử dụng	Chỉ dùng X	Dùng cả X và y
Mục tiêu	Giữ phương sai lớn nhất	Tăng khả năng tách lớp
Số chiều trong bài	6 thành phần để giữ 90% phương sai	1 chiều vì có 2 lớp
Vai trò	Giảm chiều và trực quan hóa	Tạo trục phân biệt lớp

Kết luận so sánh

PCA phù hợp để giữ thông tin tổng thể, còn LDA phù hợp khi muốn tạo biểu diễn phục vụ phân loại.

DBSCAN: Mục tiêu phân cụm

- DBSCAN là thuật toán phân cụm không giám sát dựa trên mật độ.
- Khi phân cụm, bỏ biến mục tiêu HeartDisease.
- Thuật toán chỉ dùng các đặc trưng đầu vào đã tiền xử lý.
- Sau khi có cụm, nhãn HeartDisease mới được dùng để đánh giá:
 - cụm nào có tỉ lệ Yes cao hơn;
 - cụm tự nhiên có liên hệ với bệnh tim hay không;
 - ARI, NMI, Purity giữa cụm và nhãn thật.

Lưu ý

DBSCAN không dùng để dự đoán bệnh tim trực tiếp, mà dùng để khám phá cấu trúc nhóm tự nhiên của dữ liệu.

Vì là học không giám sát, kết quả cụm chỉ nên dùng để bổ sung góc nhìn phân tích, không thay thế mô hình phân loại.

DBSCAN: eps và min_samples

- **eps**: bán kính lân cận quanh một điểm.
- **min_samples**: số điểm tối thiểu trong vùng eps để một điểm trở thành điểm lõi.
- Đặt:

$$\text{min_samples} = 20$$

- Dữ liệu phân cụm được giảm về PCA 2D để giảm chi phí và trực quan hóa.
- Thử nhiều giá trị eps:

0.15, 0.20, 0.25, 0.30, 0.35, 0.40, 0.50, 0.60

- Giá trị được chọn:

$$\text{best_eps} = 0.20$$

- Nếu eps quá nhỏ, nhiều điểm bị xem là noise; nếu eps quá lớn, các cụm dễ bị gộp lại.

DBSCAN: kết quả phân cụm


Cụm	Số mẫu
Cluster 0	49,813
Cluster 1	32
Noise	155
Tổng	50,000

- Cluster 0 chiếm phần lớn dữ liệu.
- Noise ratio thấp:

$$155/50000 \approx 0.0031$$

- ARI và NMI thấp, cho thấy cụm không trùng khớp mạnh với nhãn bệnh tim.
- Đây là kết quả hợp lý vì DBSCAN không dùng nhãn khi tạo cụm.
- Cluster 0 lớn cho thấy phần lớn dữ liệu nằm trong một vùng mật độ chung sau khi chiếu PCA 2D.


DBSCAN: trực quan hóa cụm



- Việc nhãn Yes/No còn trộn lẫn cho thấy phân cụm tự nhiên chưa tách rõ bệnh tim.
- Nhãn chỉ dùng để giải thích sau phân cụm, không dùng trong lúc DBSCAN tạo cụm.

Cụm DBSCAN trên không gian PCA 2D

DBSCAN: tỉ lệ nhãn trong từng cụm



Heatmap tỉ lệ HeartDisease theo cụm

- Heatmap cho biết tỉ lệ No/Yes trong từng cụm.
- Noise có tỉ lệ Yes cao hơn các cụm chính, nhưng số lượng điểm noise nhỏ.
- Không nên xem cụm là nhãn bệnh; cụm chỉ là nhóm mẫu gần nhau theo đặc trưng đầu vào.
- Nếu muốn dự đoán bệnh tim, vẫn cần dùng mô hình phân loại có giám sát.

4. Ba mô hình phân loại trong báo cáo

- Báo cáo hiện tại đánh giá ba mô hình:
 - ① **KNN**: mô hình phi tham số dựa trên khoảng cách.
 - ② **Logistic Regression**: mô hình tuyến tính dự đoán xác suất.
 - ③ **Soft Margin SVM**: mô hình tuyến tính cực đại hóa lề.
- Mỗi mô hình được chạy trên:

RAW, PCA, LDA

- Mỗi dạng dữ liệu được chạy với ba split:

80/20, 70/30, 60/40

Cách so sánh

Nhóm so sánh cả chất lượng dự đoán và mức độ overfit để chọn mô hình có khả năng khái quát tốt, không chỉ nhìn một chỉ số riêng lẻ.

- KNN phân loại một mẫu mới dựa trên các điểm láng giềng gần nhất.
- Báo cáo sử dụng:
 - `n_neighbors = 15`
 - `weights = distance`
 - khoảng cách Minkowski với $p = 2$
- Ưu điểm:
 - đơn giản, dễ hiểu;
 - không cần giả định dạng ranh giới.
- Hạn chế:
 - nhạy với khoảng cách;
 - dễ thiên về lớp đa số;
 - chi phí dự đoán lớn khi dữ liệu nhiều.
- Trong bài này, KNN đóng vai trò mô hình cơ bản để kiểm thử hơn là mô hình tối ưu cuối cùng.

Logistic Regression

- Logistic Regression mô hình hóa xác suất một mẫu thuộc lớp Yes:

$$P(y = 1|x) = \frac{1}{1 + e^{-(w^T x + b)}}$$

- Đây là mô hình tuyến tính, phù hợp làm baseline cho phân loại nhị phân.
- Báo cáo sử dụng:
 - `class_weight = balanced`
 - regularization L2
 - `C = 1.0`
 - `max_iter = 1000`
- `class_weight=balanced` giúp giảm ảnh hưởng của mất cân bằng lớp.
- Mô hình này dễ diễn giải hơn vì đầu ra là xác suất lớp Yes.

Soft Margin SVM

- Soft Margin SVM tìm siêu phẳng phân tách hai lớp với khoảng cách lề lớn nhất.
- Hàm quyết định:

$$f(x) = w^T x + b$$

- Dấu của $f(x)$ quyết định nhãn dự đoán; độ lớn của $f(x)$ thể hiện mức tự tin tương đối.
- Báo cáo sử dụng:
 - LinearSVC
 - `class_weight = balanced`
 - `C = 1.0`
 - `max_iter = 5000`
- Đây là Linear Soft-Margin SVM vì cho phép một số điểm nằm sai phía hoặc trong vùng lề.
- Soft Margin SVM phù hợp khi dữ liệu sau mã hóa có nhiều đặc trưng và cần một ranh giới tuyến tính ổn định.

Các độ đo đánh giá phân loại

- **Accuracy:**

$$\frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision:**

$$\frac{TP}{TP + FP}$$

- **Recall:**

$$\frac{TP}{TP + FN}$$

- **F1-score:**

$$2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

- **ROC-AUC:** khả năng phân biệt hai lớp ở nhiều ngưỡng quyết định.

Chú ý

Accuracy cao nhưng Recall thấp là dấu hiệu mô hình dự đoán tốt lớp đa số nhưng bỏ sót nhiều ca bệnh.

Vì sao ưu tiên Recall?

- Trong bài toán bệnh tim, lỗi nghiêm trọng nhất là:

False Negative

tức người có bệnh nhưng bị dự đoán là không bệnh.

- Recall cao giúp giảm số ca bệnh bị bỏ sót:

$$Recall = \frac{TP}{TP + FN}$$

- Precision thấp nghĩa là có nhiều cảnh báo nhầm, nhưng trong bài toán sàng lọc y tế, cảnh báo nhầm thường ít nguy hiểm hơn bỏ sót bệnh.
- Vì vậy, nhóm ưu tiên mô hình có Recall và ROC-AUC tốt.
- Đây là lý do Logistic Regression và Soft Margin SVM được đánh giá cao hơn KNN dù Accuracy của KNN lớn hơn.

5. Kết quả trên dữ liệu RAW

Bảng: So sánh kết quả các mô hình phân loại trên dữ liệu RAW

Mô hình	Split	Train Acc	Test Acc	Gap	Precision	Recall	F1-score	Train AUC	Test AUC
KNN	80/20	0.9995	0.9045	0.0950	0.3194	0.0509	0.0878	1.0000	0.7690
Logistic Regression	80/20	0.7442	0.7431	0.0012	0.2275	0.7696	0.3512	0.8370	0.8324
Soft Margin SVM	80/20	0.7389	0.7381	0.0009	0.2256	0.7808	0.3501	0.8369	0.8323
KNN	70/30	0.9995	0.9049	0.0946	0.3435	0.0583	0.0997	1.0000	0.7633
Logistic Regression	70/30	0.7449	0.7427	0.0021	0.2271	0.7689	0.3507	0.8377	0.8324
Soft Margin SVM	70/30	0.7397	0.7376	0.0021	0.2247	0.7773	0.3486	0.8375	0.8322
KNN	60/40	0.9994	0.9046	0.0948	0.3155	0.0480	0.0833	1.0000	0.7617
Logistic Regression	60/40	0.7461	0.7426	0.0035	0.2272	0.7694	0.3508	0.8388	0.8321
Soft Margin SVM	60/40	0.7408	0.7370	0.0039	0.2240	0.7760	0.3477	0.8386	0.8320

Nhận xét: RAW giữ đầy đủ đặc trưng sau tiền xử lý, nên Logistic Regression và Soft Margin SVM đạt AUC tốt nhất.

Nhận xét dữ liệu RAW

- KNN đạt Accuracy khoảng 0.90, nhưng Recall chỉ khoảng 0.05.
- Điều này cho thấy KNN dự đoán tốt lớp đa số No, nhưng bỏ sót nhiều mẫu Yes.
- Logistic Regression và Soft Margin SVM đạt AUC khoảng 0.832.
- Recall của hai mô hình tuyến tính khoảng 0.77–0.78, phù hợp hơn với mục tiêu sàng lọc bệnh tim.
- Overfit Gap của Logistic Regression và Soft Margin SVM rất nhỏ, cho thấy khả năng khái quát tốt.

Kết quả trên dữ liệu PCA 90%

Bảng: So sánh kết quả các mô hình phân loại trên dữ liệu PCA

Mô hình	Split	Train Acc	Test Acc	Gap	Precision	Recall	F1-score	Train AUC	Test AUC
KNN	80/20	0.9995	0.9039	0.0955	0.3147	0.0539	0.0920	1.0000	0.7528
Logistic Regression	80/20	0.7122	0.7088	0.0033	0.2039	0.7650	0.3219	0.8122	0.8073
Soft Margin SVM	80/20	0.7034	0.6996	0.0038	0.2003	0.7771	0.3186	0.8122	0.8073
KNN	70/30	0.9995	0.9050	0.0945	0.3077	0.0413	0.0729	1.0000	0.7430
Logistic Regression	70/30	0.7134	0.7100	0.0035	0.2035	0.7587	0.3210	0.8130	0.8071
Soft Margin SVM	70/30	0.7046	0.7013	0.0033	0.2006	0.7729	0.3186	0.8130	0.8071
KNN	60/40	0.9994	0.9064	0.0930	0.3600	0.0465	0.0824	1.0000	0.7497
Logistic Regression	60/40	0.7131	0.7102	0.0029	0.2045	0.7636	0.3226	0.8135	0.8077
Soft Margin SVM	60/40	0.7041	0.7009	0.0032	0.2010	0.7767	0.3194	0.8135	0.8078

Nhận xét: PCA giúp mô hình nhẹ hơn, nhưng AUC giảm vì PCA không trực tiếp tối ưu cho phân tách nhãn Yes.

Nhận xét dữ liệu PCA 90%

- PCA giúp rút gọn dữ liệu và giảm chi phí tính toán.
- Tuy nhiên PCA không dùng nhãn, nên các thành phần chính không nhất thiết tối ưu cho phân loại.
- Logistic Regression và Soft Margin SVM vẫn duy trì Recall cao.
- AUC giảm nhẹ so với RAW, cho thấy quá trình giảm chiều làm mất một phần thông tin phân loại.
- KNN vẫn có Accuracy cao nhưng Recall thấp, nên chưa phù hợp làm mô hình chính.

Kết quả trên dữ liệu LDA 1D

Bảng: So sánh kết quả các mô hình phân loại trên dữ liệu LDA


Mô hình	Split	Train Acc	Test Acc	Gap	Precision	Recall	F1-score	Train AUC	Test AUC
KNN	80/20	0.9995	0.8882	0.1113	0.2646	0.1336	0.1775	1.0000	0.7417
Logistic Regression	80/20	0.7729	0.7732	-0.0002	0.2413	0.7043	0.3594	0.8300	0.8246
Soft Margin SVM	80/20	0.7803	0.7800	0.0003	0.2447	0.6880	0.3610	0.8300	0.8246
KNN	70/30	0.9995	0.8892	0.1103	0.2923	0.1594	0.2063	1.0000	0.7407
Logistic Regression	70/30	0.7737	0.7722	0.0015	0.2405	0.7052	0.3587	0.8307	0.8246
Soft Margin SVM	70/30	0.7809	0.7791	0.0019	0.2442	0.6900	0.3607	0.8307	0.8246
KNN	60/40	0.9994	0.8858	0.1136	0.2528	0.1351	0.1760	1.0000	0.7389
Logistic Regression	60/40	0.7737	0.7717	0.0020	0.2406	0.7081	0.3591	0.8317	0.8248
Soft Margin SVM	60/40	0.7810	0.7783	0.0027	0.2443	0.6945	0.3615	0.8317	0.8248

Nhận xét: LDA chỉ còn 1 chiều nhưng vẫn giữ được trục phân biệt lớp, nên AUC đạt khoảng 0.825.


Nhận xét dữ liệu LDA 1D

- LDA dùng nhằm để tìm trục phân biệt, nên dù chỉ còn một chiều vẫn đạt AUC cao.
- AUC của Logistic Regression và Soft Margin SVM trên LDA thấp hơn RAW nhưng cao hơn PCA.
- Recall giảm so với RAW vì dữ liệu bị nén mạnh về một chiều.
- KNN cải thiện Recall so với RAW/PCA nhưng vẫn thấp hơn nhiều so với hai mô hình tuyến tính.
- LDA hữu ích khi cần mô hình rất gọn hoặc trực quan hóa phân phối theo một trục.

Ma trận nhầm lẫn và ROC-AUC



Ma trận nhầm lẫn RAW 80/20



Đường cong ROC-AUC RAW 80/20

- KNN bỏ sót nhiều mẫu Yes, nên Recall thấp.
- Logistic Regression và Soft Margin SVM có AUC cao hơn, thể hiện khả năng phân biệt hai lớp tốt hơn.
- Trong ma trận nhầm lẫn, cần chú ý số FN vì đây là số ca bệnh bị bỏ sót.

Đánh giá overfit

- Overfit Gap được tính bằng:

$$\text{Train Accuracy} - \text{Test Accuracy}$$

- KNN có Train Accuracy gần 1.0 nhưng Test Accuracy thấp hơn rõ rệt.
- Một số gap lớn nhất:
 - KNN LDA 60/40: gap 0.1136.
 - KNN LDA 80/20: gap 0.1113.
 - KNN RAW 80/20: gap 0.0950.
 - KNN PCA 80/20: gap 0.0955.
- Logistic Regression và Soft Margin SVM có gap rất nhỏ, thường dưới 0.004.

Kết luận

KNN có dấu hiệu học quá sát tập train, còn Logistic Regression và Soft Margin SVM ổn định hơn khi chuyển sang tập test.

6. Chuyển phân loại sang hồi quy score

- Theo yêu cầu bài toán, nhóm chọn mô hình Nhóm 2 và Nhóm 3:
 - Logistic Regression.
 - Soft Margin SVM.
- Thay vì dự đoán nhãn rời rạc, ta lấy score liên tục làm biến mục tiêu mới.
- Logistic score:

$$s_{\text{Logistic}}(x) = P(y = 1|x)$$

- SVM score:

$$s_{\text{SVM}}(x) = w^T x + b$$

- Hai mô hình hồi quy được dùng để học lại score:

Linear Regression, Ridge Regression

- Dữ liệu đầu vào gồm bản gốc đã xử lý và PCA còn khoảng 1/3 số chiều:

25 chiều gốc $\rightarrow$ 9 chiều PCA

- Như vậy, bài toán hồi quy ở đây không dự đoán nhãn bệnh trực tiếp mà dự đoán lại score do mô hình phân loại tạo ra.

Kết quả hồi quy score


Score nguồn	Input	MAE	RMSE	R^2
Logistic	Original	0.0461	0.0566	0.9548
Logistic	PCA 1/3	0.0635	0.0824	0.9042
SVM	Original	0.0000	0.0000	1.0000
SVM	PCA 1/3	0.0788	0.1171	0.9587

Linear Regression và Ridge Regression cho kết quả gần như giống nhau trong thí nghiệm này.

Nhận xét

Score trên dữ liệu gốc dễ học lại hơn score trên PCA 1/3 vì dữ liệu giảm chiều đã mất một phần thông tin.

Trực quan hóa hồi quy score



Score thực tế và score dự đoán

- Mỗi điểm biểu diễn một mẫu trong tập test.
- Điểm càng gần đường chéo lý tưởng thì hồi quy càng tái tạo score tốt.
- SVM score dễ tái tạo hơn vì bản chất là hàm tuyến tính theo đầu vào.
- Hình này giúp kiểm tra trực quan mức độ sai lệch giữa score thật và score dự đoán.

Giải thích vì sao R^2 cao

- Các score được sinh ra từ mô hình tuyến tính.
- SVM decision score có dạng:

$$s_{SVM}(x) = w^T x + b$$

- Linear Regression cũng học một hàm tuyến tính, nên có thể tái tạo SVM score gần như chính xác trên dữ liệu gốc.
- Vì vậy:

$$R^2 = 1.0000$$

với SVM score trên original processed features.

- Khi dùng PCA 1/3, một phần thông tin bị nén, nên sai số tăng và R^2 giảm.

7. Kết luận tổng hợp

- 1 Báo cáo đã thực hiện đầy đủ các bước: tiền xử lý, giảm chiều, phân cụm, phân loại và hồi quy score.
- 2 Dữ liệu có mất cân bằng lớp rõ rệt, nên Recall và ROC-AUC quan trọng hơn Accuracy.
- 3 Outlier được thống kê rõ ràng; tổng cộng có 8,304 giá trị outlier theo ngưỡng 1%-99%.
- 4 Logistic Regression và Soft Margin SVM là hai mô hình ổn định nhất.
- 5 KNN có Accuracy cao nhưng Recall thấp và có dấu hiệu overfit.
- 6 Dữ liệu RAW cho AUC tốt nhất; PCA giảm nhẹ hiệu năng; LDA 1D vẫn giữ khả năng phân biệt tốt.

Đề xuất hướng phát triển

- Tối ưu ngưỡng phân loại để cân bằng Precision và Recall.
- Thử các kỹ thuật xử lý mất cân bằng lớp như SMOTE hoặc undersampling.
- So sánh thêm với Random Forest, Gradient Boosting hoặc XGBoost.
- Phân tích feature importance để tăng khả năng giải thích mô hình.
- Kiểm thử trên các bộ dữ liệu y tế khác để đánh giá khả năng khái quát.

TRÂN TRỌNG CẢM ƠN!

Q&A